

Statistiques

dr Sarah DENDIEVEL

ICHEC

Année académique 2026-2027



1. Statistiques descriptives

- ① Que sont les statistiques ?
- ② Les variables
- ③ Fréquences cumulées et courbe cumulative

2. Mesures numériques : cas discret

- ① Mesures de position
- ② Mesures de dispersion

3. Mesures numériques : cas continu

- ① Mesures de position
- ② Mesures de dispersion

1. Statistiques descriptives

- ① Que sont les statistiques ?
- ② Les variables
 - ① Variables qualitatives
 - ② Variables quantitatives
- ③ Fréquences cumulées et courbe cumulative

1.1. Que sont les statistiques ?

La *statistique* est définie comme l'art et la science de la collecte, de l'analyse, de la présentation et de l'interprétation des données.

L'étude des statistiques est généralement divisée en deux catégories:

- ① les statistiques descriptives
- ② les statistiques inférentielles

Les *statistiques descriptives* sont des méthodes d'organisation, de synthèse et de présentation données de manière informative.

Les *statistiques inférentielles* sont des méthodes utilisées pour estimer une propriété d'une population sur la base d'un échantillon.

1.1. Que sont les statistiques ?

La plupart des informations statistiques dans les journaux télévisés, magazines, rapports d'entreprise et autres publications se composent de données qui sont résumées et présentées sous une forme facile à comprendre par tout lecteur.

Ces résumés de données sont souvent présentés sous forme:

- ① tabulaire
- ② graphique
- ③ numérique

Ce sont des statistiques descriptives.

1.1. Que sont les statistiques ?

Exemple. Quatre indicateurs sont utilisés pour suivre l'évolution de l'épidémie coronavirus (COVID-19) : cas confirmés, nouvelles hospitalisations de cas COVID-19 confirmés en laboratoire, occupation des unités de soins intensifs (USI) et décès. (Source: *COVID-19 - Bulletin épidémiologique du 14 septembre 2020*, covid-19.sciensano.be)

1. Statistiques présentées sous forme de tableau.

Nombre de patients	Au total	Moyenne journalière durant l'avant-dernière période de 7 jours	Moyenne journalière durant la dernière période de 7 jours	Évolution
Cas confirmés de COVID-19	93 455	479,1	680,6*	+42%
Décédés***	9 925	3,3	2,4*	-26%
En hôpital	4 973	2,4	2,1	-12%
En maison de repos	4 842	0,9	0,3	-67%
Admis à l'hôpital	19 313****	17,0	30,3**	+78%

*Du 4 septembre au 10 septembre (données des 3 derniers jours non consolidées).

**Du 7 septembre au 13 septembre.


***Décès toutes localisations incluses.

****Nombre d'hospitalisations depuis le 15 mars (date à partir de laquelle >99% des hôpitaux notifient) en raison d'une pathologie COVID-19, avec une confirmation de laboratoire au moment de la déclaration/du rapportage et qui n'ont pas été référées par un autre hôpital. Les patients ayant été admis en raison d'une pathologie autre et ayant été testés positifs dans un contexte de dépistage ne sont pas inclus dans ce décompte.


1.1. Que sont les statistiques ?

2. Statistiques présentées sous forme graphique.

Evolution des nouveaux cas confirmés



Evolution des nouvelles admissions de cas COVID-19 confirmés en laboratoire à l'hôpital



Evolution du nombre de patients en USI



Evolution du nombre de décès



1.1. Que sont les statistiques ?

3. Statistiques présentées sous forme numérique.

2. Description de l'épidémie à partir du 22 juin 2020

Nous présentons les données à partir de la semaine du 22 juin, semaine pendant laquelle le nombre de cas diagnostiqués était à son niveau le plus bas. La description de l'épidémie depuis le 15 mars est disponible en fin de rapport.

2.1. DISTRIBUTION ET ÉVOLUTION DES CAS DE COVID-19

Au cours de la période du 4 septembre au 10 septembre, 4 764 nouveaux cas ont été diagnostiqués. Parmi ces 4 764 nouveaux cas, 2 393 (50%) étaient rapportés en Flandre, 1 259 (26%) en Wallonie, et 1 111 (23%) à Bruxelles. Données non disponibles ou résidence à l'étranger pour 1 cas (0%).

Le nombre de nouveaux cas est donné sous forme d'*effectif* (c'est-à-dire en nombre de cas pour chaque modalité) et sous forme de *fréquence* (c'est-à-dire en pourcentage du nombre de cas pour chaque modalité).

1.1. Que sont les statistiques ?

Une *population* est l'ensemble de tous les éléments d'intérêt dans une étude particulière. Une enquête qui collecte des données sur l'ensemble d'une population est un *recensement*.

De nombreuses situations nécessitent des informations sur un grand groupe d'éléments mais en général les données ne peuvent être collectées que sur une petite partie du groupe d'éléments considérés.

Un *échantillon* est un sous-ensemble de la population. Une enquête réalisée en collectant des données sur échantillon est un *sondage*.

Les éléments d'une population ou d'un échantillon s'appellent des *individus*.

1.2. Les variables

Une *variable* est une caractéristique que l'on étudie sur les individus d'un échantillon.

Une variable est *quantitative* si elle est représentée par un nombre ou se prête à des calculs numériques. Elle peut prendre différentes *valeurs*.

Une variable est *qualitative* si elle n'est pas quantitative. Elle ne prend pas des valeurs, on parle de *modalités*.

Exemples :

- le nombre de frères et soeurs des étudiants inscrits dans une école bruxelloise,
- l'âge des étudiants inscrits au Master Business Analyst,
- la couleur préféré des étudiants de cette classe, ...

1.2. Les variables

Une variable quantitative est *discrète* si elle peut prendre un nombre fini de valeurs ou un nombre infini dénombrable de valeurs (c'est-à-dire que l'on peut énumérer les valeurs)

♡ Astuces ♡

1. Une variable quantitative est *discrète* si on peut énumérer les valeurs qu'elle peut prendre
2. En anglais, on demanderait « *how many ?* »

Une variable quantitative est *continue* si elle peut prendre un nombre infini non dénombrable de valeurs (c'est-à-dire que l'on ne peut pas énumérer toutes les valeurs ; il y a des intervalles).

♡ Astuces ♡

1. Une variable quantitative est *continue* si elle peut prendre toutes les valeurs comprises entre deux nombres
2. En anglais, on demanderait « *how much ?* »

1.2. Les variables

Une variable qualitative est *nominale* si ses modalités sont distinctes les unes des autres mais qu'il n'y a pas de possibilité d'ordre (ou de calcul entre elles).

Une variable qualitative est *ordinaire* si ses modalités peuvent être hiérarchisées entre elles (mais il n'y a aucun sens à les additionner, ou à les multiplier).

Notations :

- 1 Données qualitatives et quantitatives : lettre majuscule
Exemple : $X, Y, \dots$
- 2 Les observations : lettre en minuscule
Exemple : x_1, x_2, x_3 , si la variable X a 3 valeurs ou modalités

1.2. Les variables

2.1. Variables qualitatives

La *distribution des effectifs d'une variable qualitative* est un tableau qui résume les données en indiquant le nombre (*l'effectif*) de chaque modalité. L'*effectif total* est le nombre d'individus de l'échantillon.

A chaque modalité x_i de la variable X , on associe l'effectif, noté n_i . Si les effectifs sont notés $n_1, n_2, \dots$ on notera l'effectif total par la lettre n (même lettre que les effectifs mais sans indice) :

$$n = n_1 + n_2 + \dots + n_N = \sum_{i=1}^N n_i$$

où N est le nombre de modalités distinctes.


♡ Astuces ♡

Vérifiez votre tableau : l'effectif total est-il bien égal à la somme des effectif de chaque modalité ?

1.2. Les variables

2.1. Variables qualitatives


Distribution des effectifs sous forme de *diagramme en bâtons (verticaux)*



1.2. Les variables

2.1. Variables qualitatives


Distribution des effectifs sous forme de *diagramme en bâtons (horizontaux)*



1.2. Les variables

2.1. Variables qualitatives

Distribution des effectifs sous forme de *camembert*




On trace un cercle pour l'ensemble des données et chaque part du camembert est proportionnelle à l'effectif.

1.2. Les variables

2.1. Variables qualitatives

Distribution des effectifs sous forme de *diagramme en points*



On trace une série de points au lieu des bandes verticales utilisés pour les diagramme en bâtons.

1.2. Les variables

2.1. Variables qualitatives

La *fréquence* d'une modalité est la proportion d'individus de celle-ci :

$$\text{Fréquence d'une modalité} = \frac{\text{Effectif de la modalité}}{\text{Effectif total}}$$

Notation mathématique :

$$f_i = \frac{n_i}{n}$$

La *distribution statistique d'une variable qualitative* est un tableau qui associe la fréquence à chaque modalité de cette variable.

♡ Astuces ♡

Vérifiez votre distribution : la somme des fréquences est-elle bien égale à 1 ?

1.2. Les variables

2.2. Variables quantitatives

La *distribution des effectifs d'une variable quantitative* est un tableau ordonné dans l'ordre croissant qui associe l'effectif à chaque valeur (ou classes de valeurs distinctes) que peut prendre la variable.

Exemple. On a interrogé un groupe d'étudiants sur leur nombre de frères et soeurs. On a obtenu les valeurs suivantes :

0	0	0	0	0	1	1	1	1	1	1	1	1	1	1	1
2	2	2	2	2	2	2	2	2	2	2	2	3	3	3	3
4	4	5	6	7	8	13									

Structurons les données étape par étape.

- On définit la variable X : « le nombre de frères et soeurs d'un groupe d'étudiants interrogés ».

1.2. Les variables

2.2. Variables quantitatives

- On associe chaque valeur distincte à une notation, par ordre croissant : $x_1 = 0$, $x_2 = 1$, $x_3 = 2$, $x_4 = 3$, $x_5 = 4$, $x_6 = 5$, $x_7 = 6$, $x_8 = 7$, $x_9 = 8$ et $x_{10} = 13$.
- On relève les effectifs correspondants : $n_1 = 5$, $n_2 = 11$, $n_3 = 12$, $n_4 = 4$, $n_5 = 2$, $n_6 = 1$, $n_7 = 1$, $n_8 = 1$, $n_9 = 1$ et $n_{10} = 1$.

Distribution des effectifs de X :

X	Effectif n_i
$x_1 = 0$	$n_1 = 5$
$x_2 = 1$	$n_2 = 11$
$x_3 = 2$	$n_3 = 12$
$x_4 = 3$	$n_4 = 4$
$x_5 = 4$	$n_5 = 2$

X	Effectif n_i
$x_6 = 5$	$n_6 = 1$
$x_7 = 6$	$n_7 = 1$
$x_8 = 7$	$n_8 = 1$
$x_9 = 8$	$n_9 = 1$
$x_{10} = 13$	$n_{10} = 1$

L'effectif total est

$$n = \sum_{i=1}^{10} n_i = 5 + 11 + 12 + 4 + 2 + 1 + 1 + 1 + 1 + 1 = 39$$

1.2. Les variables

2.2. Variables quantitatives

La *fréquence* d'une valeur (ou classe) est la proportion d'individus de celle-ci :

$$\text{Fréquence d'une valeur (ou classe)} = \frac{\text{Effectif de la valeur (ou classe)}}{\text{Effectif total}}$$

Notation mathématique :

$$f_i = \frac{n_i}{n}$$

La *distribution statistique d'une variable quantitative* est un tableau ordonné dans l'ordre croissant qui associe la fréquence à chaque valeur (ou classe) de cette variable.

♡ *Astuces* ♡

Vérifiez votre distribution : la somme des fréquences est-elle bien égale à 1 ?


1.2. Les variables

2.2. Variables quantitatives

On peut représenter la distribution des effectifs et des fréquences d'une variable quantitative continue sous forme d'un *histogramme* : nous indiquons les classes par ordre croissant sur l'axe horizontal, et nous traçons des rectangles, de base égale à la longueur de la classe et de hauteur calculée de telle sorte que l'aire du rectangle soit proportionnelle aux effectifs ou aux fréquences.

Exemple. Histogramme des fréquences de la variable Y : « Nombre d'heures passées à étudier pour la préparation d'un examen de statistique. »

Classes de Y	Fréquence
$[5, 90[$	0.37
$[90, 110[$	0.15
$[110, 145[$	0.48




1.2. Les variables

2.2. Variables quantitatives

En regroupant les valeurs autrement, on obtient un histogramme différent.

Classes de Y	Fréquence
[5, 70[	0.11
[70, 90[	0.26
[90, 110[	0.15
[110, 130[	0.15
[130, 145[	0.33



La forme des histogrammes est sensible au choix des classes. Si la longueur des classes est trop grande, nous n'en retirons aucune information pertinente sur les données. Si la longueur des classes est trop petite, l'histogramme est illisible.

1.3. Fréquences cumulées et courbe cumulative

La *fréquence cumulée* d'une valeur (ou classe) est la proportion de valeurs inférieure ou égale à celle-ci.

Notation mathématique

$$\begin{aligned} F_i &= f_1 + f_2 + \dots + f_i = \sum_{k=1}^i f_k \\ &= F_{i-1} + f_i \end{aligned}$$

La *distribution des fréquences cumulées d'une variable quantitative* est un tableau ordonné dans l'ordre croissant qui associe la fréquence cumulée à chaque valeur (ou classe) de cette variable.

1.3. Fréquences cumulées et courbe cumulative


Représentation graphique. On peut représenter la distribution des fréquences cumulées d'une variable quantitative discrète sous la forme d'*un graphique en paliers ou en escalier*. Celui-ci s'appelle la *courbe cumulative* ou la *courbe des fréquences cumulées*.

Procédure de construction

1. On trace une demi-droite horizontale de $-\infty$ jusqu'à la première valeur observée x_1 .
2. On représente le point (x_i, F_i) dans le plan, pour $i = 1, \dots, N$
3. On trace un segment horizontal vers la droite à partir de (x_i, F_i) , pour $i = 1, \dots, N - 1$; ce segment a pour longueur $x_{i+1} - x_i$.
4. Au point (x_N, F_N) , on trace une demi-droite horizontale, à partir de celui-ci et jusqu'à l'infini.

1.3. Fréquences cumulées et courbe cumulative

Exemple. Courbe cumulative de la variable X : « Le nombre de frères et soeurs d'un groupe d'étudiants interrogés ».



1.3. Fréquences cumulées et courbe cumulative

Représentation graphique. On peut représenter la distribution des fréquences cumulées d'une variable quantitative continue : c'est la courbe cumulative ou la *courbe des fréquences cumulées* (ou *polygône des fréquences cumulées*).


Procédure de construction

1. On trace une demi-droite de $-\infty$ à la borne inférieure de la première classe et on fait correspondre un point d'ordonnée 0 en celle-ci.
2. A la borne supérieure de chaque classe, on fait correspondre un point d'ordonnée égale à la fréquence cumulée.
3. On relie les points deux à deux par des segments de droite.
4. On trace une demi-droite au point d'ordonnée 1 à la borne supérieure de la dernière classe, vers $+\infty$.

1.3. Fréquences cumulées et courbe cumulative

Exemple. Courbe cumulative de la variable Y : « Nombre d'heures passées à étudier pour la préparation d'un examen de statistique », groupée en 5 classes.

Classes de Y	Fréq. Cum.
$[5, 70[$	0.11
$[70, 90[$	0.37
$[90, 110[$	0.52
$[110, 130[$	0.67
$[130, 145[$	1



2. Mesures numériques : cas discret

① Mesures de position

- ① Mode
- ② Moyenne
- ③ Médiane
- ④ Quartiles

② Mesures de dispersion

- ① Ecart interquartile
- ② Etendue
- ③ Boîte à moustache
- ④ Variance
- ⑤ Ecart-type

2.1. Mesures de position

1. Mode

Le *mode* est la valeur observée qui a la plus grande fréquence (ou le plus grand effectif). On le note M .

Dans certains cas, la fréquence la plus élevée peut être égale pour deux valeurs de la variable. Dans ce cas, la distribution est *bimodale*. De façon générale, si la fréquence la plus élevée est observée pour plusieurs valeurs, la distribution est *plurimodale*.

Exemple. La série statistique : 0, 1, 1, 2, 3, 5, 5 de deux modes : $M_1 = 1$ et $M_2 = 5$ puisque l'effectif le plus élevé est 2 pour ces deux valeurs.

2.1. Mesures de position

1. Mode

Avantages du mode.

- Le mode n'est pas influencé par les valeurs extrêmes.
- Le mode est facile à déterminer.
- Le mode convient pour tout type de variable : qualitatives ou quantitatives.


Inconvénients du mode.

- Lorsqu'il y a plusieurs modes, il est difficile d'utiliser ceux-ci car une liste de plusieurs modes n'est pas particulièrement utile pour décrire la centralité des données.
- Le mode ne tient pas compte de toutes les valeurs de la variable et peut correspondre à une valeur qui n'est pas centrale.

2.1. Mesures de position

1. Mode

Exemple. Les deux variables suivantes ont le même mode mais elles sont très différentes : la première a des valeurs extrêmes (le mode n'en tient pas compte), pour la deuxième le mode n'est pas central.



2.1. Mesures de position

2. Moyenne

Mesure de centralité/position : la moyenne (notation : $\bar{x}$)

La *moyenne* (échantillon) est la somme de toutes les valeurs observées de l'échantillon divisée par l'effectif total :

$$\text{Moyenne} = \frac{\text{Somme de toutes les valeurs de l'échantillon}}{\text{Effectif total}}$$

Mathématiquement, si n est l'effectif total et y_i est la i -ème observation alors, la moyenne de l'échantillon est

$$\begin{aligned}\bar{y} &= \frac{y_1 + y_2 + \dots + y_n}{n} \\ &= \frac{1}{n} \sum_{i=1}^n y_i\end{aligned}$$

2.1. Mesures de position

2. Moyenne

Mathématiquement, si n est l'effectif total, x_i est la i -ème valeur distincte, n_i est l'effectif de x_i et N est le nombre d'observations distinctes alors, la moyenne de l'échantillon est

$$\begin{aligned}\bar{X} &= \frac{n_1x_1 + n_2x_2 + \dots + n_Nx_N}{n} \\ &= \frac{1}{n} \sum_{i=1}^N n_i x_i\end{aligned}$$

ou, si f_i est la fréquence de x_i ,

$$\begin{aligned}\bar{X} &= f_1x_1 + f_2x_2 + \dots + f_Nx_N \\ &= \sum_{i=1}^N f_i x_i\end{aligned}$$

2.1. Mesures de position

2. Moyenne

Avantages de la moyenne.

- La moyenne convient pour les variables quantitatives.
- La moyenne prend en compte toutes les valeurs observées.
- La moyenne est unique.

Inconvénients de la moyenne.

- La moyenne n'est pas définie pour les variables qualitatives.
- La moyenne est influencée par les valeurs extrêmes.

Autres caractéristiques de la moyenne.

- On peut considérer la moyenne comme le centre de gravité des données.
- La somme des écarts de chaque valeur à la moyenne est égale à zéro :

$$\sum_{i=1}^n (x_i - \bar{x}) = 0$$

2.1. Mesures de position

3. Médiane

La distribution des fréquences cumulées permet de déterminer la médiane : la *médiane* est la valeur de la variable correspondant à la fréquence cumulée de 50% ou la première valeur pour laquelle la fréquence cumulée est supérieure à 50%.

2.1. Mesures de position

3. Médiane

Avantages de la médiane.

- La médiane n'est pas influencée par les valeurs extrêmes. Par conséquent, elle reste une bonne mesure de centralité même dans le cas où de telles valeurs sont observées.
- La médiane convient pour les variables quantitatives et qualitatives ordinales.

Inconvénients de la médiane.

- La médiane n'est pas définie pour les variables qualitatives nominales.


Autres caractéristiques de la médiane.

- La médiane ne dépend que de l'ordre des valeurs de la variable.
- Deux distributions peuvent être très différentes mais avoir la même médiane.

2.1. Mesures de position

3. Médiane


Exemple. Les deux variables suivantes ont la même médiane, $m = 2$, mais elles sont différentes. Les valeurs extrêmes de la première n'influencent pas celle-ci.



2.1. Mesures de position

3. Médiane

- Lorsqu'une distribution a la même forme des deux côtés du centre la distribution, on dit que c'est une distribution *symétrique*. Dans ce cas, le mode, la médiane et la moyenne sont situées au centre et sont égaux.




Dans cet exemple, le mode $M = 40$, la médiane $m = 40$ et la moyenne $\bar{x} = 40$. N'importe laquelle de ces mesures est une bonne mesure de centralité de la distribution dans le cas symétrique.

2.1. Mesures de position

3. Médiane

- Une distribution est *asymétrique à droite* (ou *asymétrique positive*) si la moyenne est plus grande que le mode et la médiane.




Dans cet exemple, le mode $M = 20$, la médiane $m = 30$ et la moyenne $\bar{x} = 33$. La moyenne est supérieure aux deux autres mesures puisqu'elle est influencée par les grandes valeurs extrêmes. Dans ce cas-ci, la médiane est plus représentative de la centralité des données.

2.1. Mesures de position

3. Médiane

- Elle est *asymétrique à gauche* (ou *asymétrique négative*) si la moyenne est plus petite que le mode et la médiane.



Dans cet exemple, le mode $M = 60$, la médiane $m = 50$ et la moyenne $\bar{x} = 47$. La moyenne est inférieure aux deux autres mesures puisqu'elle est influencée par les petites valeurs extrêmes. Dans ce cas-ci, la médiane est plus représentative de la centralité des données.

2.1. Mesures de position

4. Quartiles

Les *quartiles* divisent les données en 4 parts contenant (environ) 25% des données :

- Le premier quartile Q_1 est la valeur en dessous de laquelle se trouvent 25% des observations.
- Le deuxième quartile Q_2 est la valeur en dessous de laquelle se trouvent 50% des observations.
- Le troisième quartile Q_3 est la valeur en dessous de laquelle se trouvent 75% des observations.

Si on dispose de la distribution des fréquences cumulées :

- Q_1 est la première valeur pour laquelle la fréquence cumulée est supérieure ou égale à 25%.
- Q_3 est la première valeur pour laquelle la fréquence cumulée est supérieure ou égale à 75%.

2.2. Mesures de dispersion

1. Ecart interquartile

L'*écart interquartile*, noté I_Q , d'une série statistique est la différence entre le troisième quartile et le premier quartile :

$$\text{Ecart interquartile} = Q_3 - Q_1$$

Cette mesure de dispersion contient les 50% des données les plus centrales. Elle n'est donc pas influencée par les valeurs extrêmes.

L'*étendue* d'une série statistique est la différence entre la valeur maximale et la valeur minimale de cette série statistique :

$$\text{Etendue} = \text{Max des valeurs} - \text{Min des valeurs}$$

Cette mesure est très sensible aux valeurs extrêmes.

2.2. Mesures de dispersion

3. Boîte à moustaches

Le *diagramme en boîte* ou *la boîte à moustache* (ou *boxplot*, en anglais) est une boîte rectangulaire mettant en évidence les cinq paramètres suivants d'une série statistique : le minimum, le 1er quartile, le 2ème quartile, le 3ème quartile et le maximum.

Construction de la boîte à moustache (idée de base)

1. Tracer une droite graduée et choisir une unité.
2. Tracer un rectangle, dont la longueur est égale à l'écart interquartile, allant de Q_1 à Q_3 . C'est *la boîte*.
Tracer un trait vertical au niveau de la médiane. Ce trait coupe la boîte en 2 parties représentant chacune 25% des données.
3. Tracer un segment allant du minimum jusqu'à la boîte (en Q_1) et un segment allant de la boîte (en Q_3) jusqu'au maximum. Ce sont *les moustaches*.

2.2. Mesures de dispersion

3. Boîte à moustaches

Dans la pratique, les moustaches ne s'étendent pas toujours jusqu'au minimum et au maximum.

Construction de la boîte à moustache en pratique : avec détection des valeurs extrêmes

On calcule les bornes suivantes :

- Borne inférieure : $Q_1 - 1.5 \times I_Q$
- Borne supérieure : $Q_3 + 1.5 \times I_Q$

Les moustaches s'étendent alors jusqu'à la plus petite et à la plus grande observation situées à l'intérieur de ces bornes.

Les observations situées en dehors de ces bornes sont représentées individuellement par des points ou des astérisques. Elles sont appelées *valeurs extrêmes* ou *valeurs aberrantes*.

2.2. Mesures de dispersion

3. Boîte à moustaches

Il existe même deux niveaux de valeurs atypiques :

- les valeurs aberrantes modérées sont représentées par des cercles ou points ;
- les valeurs aberrantes extrêmes sont représentées par des astérisques : on les détermine grâce aux limites $Q_1 - 3I_Q$ et $Q_3 + 3I_Q$

La boîte à moustache résume visuellement quelques indicateurs de position et de dispersion.

Dans la pratique, celle-ci est généralement utilisée pour comparer deux séries statistiques.

Remarque : lorsqu'un point apparaît dans la boîte à moustache, il s'agit d'une représentation de la moyenne sur l'échantillon étudié.

2.2. Mesures de dispersion

4. Variance

Mesure de dispersion : la variance (notation : s^2)

Si y_i est la i -ème valeur observée d'une série statistique et n est la taille de l'échantillon, alors la *variance-échantillon* de cette série est définie par

$$s^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$$

La *variance-échantillon* à partir d'un tableau des fréquences est définie par

$$s^2 = \sum_{i=1}^N (x_i - \bar{x})^2 f_i$$

où x_i est la i -ème valeur (distincte), f_i est sa fréquence et N est le nombre d'observations distinctes de l'échantillon.

2.2. Mesures de dispersion

4. Variance

La variance est une mesure de dispersion qui utilise l'ensemble des valeurs observées.

En pratique :

- à partir des données individuelles, on utilise la formule

$$s^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2$$

- à partir de la distribution des fréquences, on utilise la formule

$$s^2 = \sum_{i=1}^N f_i x_i^2 - \bar{x}^2$$

2.2. Mesures de dispersion

4. Variance

Exemple. Considérons la série statistique : 5, 29, 34, 5, 59, 59, 88 ayant pour moyenne-échantillon $\bar{y} = 39.857$.

- A partir de la définition :

$$\begin{aligned}s^2 &= \frac{1}{7} \sum_{i=1}^7 (y_i - \bar{y})^2 \\&= \frac{1}{7} \left((5 - \bar{y})^2 + (29 - \bar{y})^2 + (34 - \bar{y})^2 + (5 - \bar{y})^2 \right. \\&\quad \left. + (59 - \bar{y})^2 + (59 - \bar{y})^2 + (88 - \bar{y})^2 \right)\end{aligned}$$

Puisque $\bar{y} = 39.857$, nous obtenons :

$$\begin{aligned}s^2 &= \frac{1}{7} \left((-34.857)^2 + (-10.857)^2 + (-5.857)^2 + (-34.857)^2 \right. \\&\quad \left. + (19.143)^2 + (19.143)^2 + (48.143)^2 \right) \\&= 804.693\end{aligned}$$

2.2. Mesures de dispersion

4. Variance

- A partir de la formule alternative pour les données individuelles :

$$\begin{aligned}s^2 &= \frac{1}{7} \sum_{i=1}^7 y_i^2 - \bar{y}^2 \\&= \frac{1}{7} (5^2 + 29^2 + 34^2 + 5^2 + 59^2 + 59^2 + 88^2) - \bar{y}^2 \\&= \frac{1}{7} (25 + 841 + 1156 + 25 + 3481 + 3481 + 7744) - \bar{y}^2 \\&= \frac{1}{7} \times 16753 - (39.857)^2 \\&= 2393.286 - 1588.580 \\&= 804.710\end{aligned}$$

2.2. Mesures de dispersion

4. Variance

- A partir de la définition qui utilise les fréquences :
 - Il faut d'abord calculer les fréquences :

X	Fréquence f_i
$x_1 = 5$	$f_1 = 2/7$
$x_2 = 29$	$f_2 = 1/7$
$x_3 = 34$	$f_3 = 1/7$
$x_4 = 59$	$f_4 = 2/7$
$x_5 = 88$	$f_5 = 1/7$

- Puisqu'il y a 5 valeurs distinctes, $N = 5$ et nous obtenons, à partir de la définition :

$$s^2 = \sum_{i=1}^5 (x_i - \bar{x})^2 f_i$$

2.2. Mesures de dispersion

4. Variance

$$\begin{aligned}s^2 &= (5 - \bar{x})^2 \times \frac{2}{7} + (29 - \bar{x})^2 \times \frac{1}{7} + (34 - \bar{x})^2 \times \frac{1}{7} \\&\quad + (59 - \bar{x})^2 \times \frac{2}{7} + (88 - \bar{x})^2 \times \frac{1}{7} \\&= (-34.857)^2 \times \frac{2}{7} + (-10.857)^2 \times \frac{1}{7} + (-5.857)^2 \times \frac{1}{7} \\&\quad + (19.143)^2 \times \frac{2}{7} + (48.143)^2 \times \frac{1}{7} \\&= 804.694\end{aligned}$$

2.2. Mesures de dispersion

4. Variance

- A partir de la formule alternative qui utilise les fréquences :
 $s^2 = \sum_{i=1}^5 f_i x_i^2 - \bar{x}^2$, nous reprenons le tableau pour calculer $f_i x_i^2$ pour chaque valeur :

X	Fréquence f_i	$f_i x_i^2$
$x_1 = 5$	$f_1 = 2/7$	$f_1 x_1^2 = 7.143$
$x_2 = 29$	$f_2 = 1/7$	$f_2 x_2^2 = 120.143$
$x_3 = 34$	$f_3 = 1/7$	$f_3 x_3^2 = 165.143$
$x_4 = 59$	$f_4 = 2/7$	$f_4 x_4^2 = 994.571$
$x_5 = 88$	$f_5 = 1/7$	$f_5 x_5^2 = 1106.286$

On obtient :

$$\begin{aligned}s^2 &= 7.143 + 120.143 + 165.143 + 994.571 + 1106.286 - (39.857)^2 \\ &= 804.706\end{aligned}$$

2.2. Mesures de dispersion

5. Ecart-type

La variance est une mesure de dispersion autour de la moyenne en termes de carrés des écarts. Pour obtenir une mesure dans la même unité que celle des valeurs observées, on définit l'écart-type.

L'*écart-type* d'une série statistique est définie par

$$s = \sqrt{s^2}$$

où s^2 est la variance de la série.

Exemple. L'écart-type de la série statistique : 5, 29, 34, 5, 59, 59, 88 ayant pour variance $s^2 = 804.71$ est

$$s = \sqrt{s^2} = \sqrt{804.71} = 28.368$$

3. Mesures numériques : cas continu

① Mesures de positionn

- ① Mode approché
- ② Moyenne approché
- ③ Médiane approchée
- ④ Quartiles approchés

② Mesures de dispersion

- ① Ecart interquartile approché
- ② Etendue
- ③ Boîte à moustache
- ④ Variance approchée
- ⑤ Ecart-type approché

3.1. Mesures de position

1. Mode approché

*La classe modale est celle qui a la plus grande fréquence.
Par convention, le mode M est le centre de la classe modale.*

Exemple. La classe modale de variable Y : « Nombre d'heures passées à étudier pour la préparation d'un examen de statistique », groupée en 5 classes, est $[130, 145[$ car elle correspond à la classe qui a la plus grande fréquence. Par convention, le mode est le centre de cette classe, c'est-à-dire : $M = \frac{130+145}{2} = 137.5$

Interprétation de la classe modale : « Dans l'échantillon prélevé, on a observé le plus souvent des étudiants qui étudient entre 130 et 145 heures pour préparer un examen de statistique. »

Interprétation du mode : « Dans l'échantillon prélevé, on a observé le plus souvent des étudiants qui étudient environ 138 heures pour préparer un examen de statistique. »

3.1. Mesures de position

2. Moyenne approchée

A partir d'un tableau classé d'une variable X , si n est l'effectif total, c_i est le centre de la i -ème classe, n_i est l'effectif de la i -ème classe et k est le nombre de classes alors, la *moyenne approchée* (échantillon) est

$$\begin{aligned}\bar{x}_a &= \frac{n_1 c_1 + n_2 c_2 + \dots + n_k c_k}{n} \\ &= \frac{1}{n} \sum_{i=1}^k n_i c_i\end{aligned}$$

et si f_i est la fréquence de la i -ème classe, alors

$$\begin{aligned}\bar{x}_a &= f_1 c_1 + f_2 c_2 + \dots + f_k c_k \\ &= \sum_{i=1}^k f_i c_i\end{aligned}$$

3.1. Mesures de position

3. Médiane approchée

La *classe médiane* correspond à la première classe pour laquelle la fréquence cumulée est supérieure ou égale à 50%.

Par convention, la *médiane approchée* est déterminée par interpolation linéaire* :

$$m_a = L_2 + l_m \left(\frac{0.5 - F_2^*}{f_m} \right)$$

où :

- L_2 est la borne inférieure de la classe médiane,
- F_2^* est la fréquence cumulée en L_2 (celle de la classe précédant la classe médiane ou 0% si L_2 est la 1^{ère} classe),
- f_m est la fréquence de la classe médiane,
- l_m est la longueur de la classe médiane.

*L'*interpolation linéaire* permet d'estimer une valeur comprise entre deux points donnés en utilisant une fonction affine (=une droite) et qui passe par ces deux points.

3.1. Mesures de position

4. Quartiles approchés

La *classe* contenant Q_1 , le *premier quartile*, correspond à la première classe pour laquelle la fréquence cumulée est supérieure ou égale à 25%.

La *classe* contenant Q_3 , le *troisième quartile*, correspond à la première classe pour laquelle la fréquence cumulée est supérieure ou égale à 75%.

Par convention, le k -ème *quartile approché* est déterminé par interpolation linéaire, $k = 1, 2, 3$:

$$Q_{k,a} = L_k + I_{Q_k} \left(\frac{\frac{k}{4} - F_k^*}{f_{Q_k}} \right)$$

- où :
- L_k est la borne inférieure de la classe qui contient Q_k ,
 - F_k^* est la fréquence cumulée en L_k (celle de la classe précédant la classe contenant Q_k ou 0% si L_k est la 1^{ère} classe),
 - f_{Q_k} est la fréquence de la classe qui contient Q_k ,
 - I_{Q_k} est la longueur de la classe qui contient Q_k ,

3.2. Mesures de dispersion

1. Ecart interquartile approché

L'*écart interquartile approché* d'une série statistique groupée en classe, noté $I_{Q,a}$, est la différence entre le troisième quartile approché et le premier quartile approché :

$$\text{Ecart interquartile approché} = Q_{3,a} - Q_{1,a}$$

Exemple. L'écart interquartile de la variable Y : « Nombre d'heures passées à étudier pour la préparation d'un examen de statistique », est

$$I_{Q,a} = Q_{3,a} - Q_{1,a} = 133.64 - 80.77 = 52.87$$

Interprétation : « Environ 50% des temps d'étude observés pour la préparation d'un examen de statistique par les étudiants sont entre 80.77 heures et 133.64 heures, donc ces temps sont dispersés sur une longueur qui vaut 52 heures et 52 minutes. »

3.2. Mesures de dispersion

2. Etendue

L'*étendue*, notée E , d'une série statistique groupée en classe par ordre croissante est la différence entre la borne supérieure de la dernière classe et la borne inférieure de la première classe.

Exemple. L'étendue de la variable Y : « Nombre d'heures passées à étudier pour la préparation d'un examen de statistique », est de

$$E = 145 - 5 = 140$$


Interprétation : « Les temps d'étude observés pour la préparation d'un examen de statistique par les étudiants sont entre 5 et 145 heures donc ces temps sont dispersés sur une longueur qui vaut 140 heures. »

3.2. Mesures de dispersion

3. Boîte à moustache

La boîte à moustache se construit de façon similaire à celles des variables quantitatives discrètes, en utilisant les quantiles approchés.

Exemple. La boîte à moustache de la variable Y : « Nombre d'heures passées à étudier pour la préparation d'un examen de statistique », est



3.2. Mesures de dispersion

4. Variance approchée

Si c_i est le centre de la i -ème classe d'une variable quantitative continue X , f_i est la fréquence de la i -ème classe et k est le nombre de classes, alors la *variance approchée* est définie par

$$s_a^2 = \sum_{i=1}^k f_i (c_i - \bar{x}_a)^2$$

En pratique :

$$s_a^2 = \sum_{i=1}^k f_i c_i^2 - \bar{x}_a^2$$

3.2. Mesures de dispersion

5. Ecart-type approché

L'*écart-type approché* est défini par

$$s_a = \sqrt{s_a^2}$$

où s_a^2 est la variance approchée de la variable quantitative continue.

♣ La variance et l'écart-type sont les paramètres de dispersion les plus utilisés et sont, avec la moyenne, les paramètres principaux utilisés en inférence statistique (voir deuxième partie du cours)

La notation $\sum$

Le symbole de sommation $\sum$ s'utilise lorsque l'on veut exprimer une somme de termes qui est longue ou pour une formule générale par exemple.

Si n est un nombre entier positif et qu'on additionne n termes x_i , $x_1 + x_2 + \dots + x_{n-1} + x_n$, on écrit :

$$x_1 + x_2 + \dots + x_{n-1} + x_n = \sum_{i=1}^n x_i$$

Le « i » est un *indice de sommation*, c'est l'indice des « x_i » que l'on peut choisir de façon arbitraire ; et « $i = 1$ » signifie que l'on commence la somme avec x_1 et que l'on additionne tous les suivantes jusqu'à arriver à $i = n$; le n étant indiqué au-dessus du symbole de sommation.

La notation $\sum$

Exemples.

1. $x_1 + x_2 + x_3$ s'écrit : $\sum_{i=1}^3 x_i$

2. $x_1 + x_2 + x_3 + x_4 + x_5 + x_6$ s'écrit : $\sum_{i=1}^6 x_i$

Remarques.

- Ce symbole est une notation et suit les mêmes propriétés que la somme de nombres.
- Il est possible de commencer l'indice en un autre nombre, par exemple :

$$\sum_{i=4}^6 x_i = x_4 + x_5 + x_6$$

mais dans cette UE, nous sommes essentiellement dans le cas où i commence à 1.

Exemples :

1. Les puissances :

$$\sum_{i=1}^3 x_i^2 = x_1^2 + x_2^2 + x_3^2$$

Lorsqu'un nombre est élevé à une certaine puissance, elle est effectuée en priorité.

2. La place des parenthèses est importante :

$$\sum_{i=1}^3 (x_i - \bar{x})^2 = (x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + (x_3 - \bar{x})^2$$

On effectue d'abord ce qui est entre parenthèses avant d'additionner les termes.

La notation $\sum$

3. L'absence de parenthèses :

$$\sum_{i=1}^3 x_i^2 - \bar{x}^2 = (x_1^2 + x_2^2 + x_3^2) - \bar{x}^2$$

Puisque $\bar{x}^2$ n'est pas dans une parenthèse après le symbole de sommation, cela signifie qu'il ne fait pas partie de la somme des 3 termes de $\sum_{i=1}^3 x_i^2$, on effectue donc d'abord cette somme et puis on continue avec les termes hors de la notation du symbole de sommation.

4. Les facteurs multiplicatifs :

$$\sum_{i=1}^3 \frac{x_i}{5} = \frac{x_1}{5} + \frac{x_2}{5} + \frac{x_3}{5} = \frac{1}{5} (x_1 + x_2 + x_3) = \frac{1}{5} \sum_{i=1}^3 x_i$$

On peut mettre en évidence un facteur commun aux termes de la somme.