

Statistiques : Exercices et Solutions

Mathématiques pour Business Analysts - Professeur : dr Sarah DENDIEVEL

ICHEC Brussels Management School

1. On a interrogé un groupe d'étudiants sur leur couleur primaire ou secondaire préférée : 4 étudiants ont choisi le violet, 4 étudiants ont choisi le rouge, 3 étudiants ont choisi l'orange, 2 étudiants ont choisi le jaune, 9 étudiants ont choisi le vert et 15 étudiants ont choisi le bleu.
 - (a) Définissez une variable qui convient au contexte qui nous intéresse.
 - (b) Quelle est la nature de cette variable? Justifiez.
 - (c) Donnez à chaque modalité une notation appropriée.
 - (d) Combien de modalités distinctes cette variable possède-t-elle?
 - (e) Donnez la distribution des effectifs.
 - (f) Quel est l'effectif total?
 - (g) Donnez la distribution statistique (ou des fréquences) en notation décimale (arrondie au 100ème).

2. On a interrogé un groupe d'étudiants sur leur nombre de frères et sœurs. On a obtenu les valeurs suivantes :

0	0	0	0	0	1	1	1	1	1	1	1	1	1	1	1
2	2	2	2	2	2	2	2	2	2	2	2	3	3	3	3
4	4	5	6	7	8	13									

Arrondissez vos calculs au 1000ème.

- (a) Définissez une variable qui convient au contexte qui nous intéresse.
- (b) Quelle est la nature de cette variable? Justifiez.
- (c) Donnez à chaque modalité une notation appropriée.
- (d) Combien de modalités distinctes cette variable possède-t-elle?
- (e) Donnez la distribution des effectifs et sa représentation sous forme de diagramme en bâtons (verticaux).

- (f) Quel est l'effectif total?
 - (g) Donnez la distribution statistique (ou des fréquences) en notation décimale et sa représentation sous forme de diagramme en bâtons (verticaux).
 - (h) Donnez une interprétation de f_4 (c'est-à-dire traduisez cette valeur en langage courant par une phrase en français, dans le contexte dont il est question).
 - (i) Donnez la distribution des fréquences cumulées.
 - (j) Donnez une interprétation de F_4 .
 - (k) Représentation la courbe cumulative.
 - (l) Déterminez le mesures de position : mode, médiane, quartiles. Donnez une interprétation pour chacune de ces mesures.
 - (m) Calculez la moyenne-échantillon de 3 façons différentes. Donnez une interprétation de cette mesure.
 - (n) Déterminez les mesures de dispersion : écart interquartile, étendue et donnez une interprétation de ces mesures.
 - (o) Représentez la boîte à moustache en précisant les mesures utilisées pour sa représentation.
 - (p) Déterminez les mesures de dispersion : variance-échantillon, écart-type-échantillon.
3. Un supermarché reçoit 50 caissettes comprenant chacune 9 pêches. Le nombre de pêches abîmées dans chacune des caissettes est décrit dans le tableau suivant.

0	0	0	0	0	0	0	0	0	0
0	1	1	1	1	1	1	1	1	1
1	2	2	2	2	2	2	3	3	3
4	4	4	5	5	5	5	5	6	6
6	6	7	7	7	8	8	8	9	9

Arrondissez vos calculs au 100ème.

- (a) Définissez une variable qui convient au contexte qui nous intéresse.
- (b) Quelle est la nature de cette variable? Justifiez.
- (c) Donnez la distribution des effectifs de cette variable et tracez le diagramme en bâtons de celle-ci.
- (d) Donnez la distribution statistique de cette variable et tracez le diagramme en bâtons de celle-ci.
- (e) Donnez une interprétation de f_7 .
- (f) Donnez le tableau des fréquences cumulées de cette variable et tracez la courbe cumulative.

- (g) Donnez une interprétation de F_7 .
- (h) Déterminez les mesures de centralité suivantes : mode, médiane, moyenne-échantillon. Justifiez et interprétez chacune de celles-ci.
- (i) Déterminez les mesures de position suivantes : premier, deuxième et troisième quartiles. Justifiez et interprétez chacune de celles-ci.
- (j) Déterminez les mesures de dispersion suivantes : étendue et écart interquartile. Justifiez et interprétez chacune de celles-ci.
- (k) Dessinez la boîte à moustache de cette série statistique.
- (l) Déterminez la variance-échantillon et l'écart-type-échantillon. Justifiez vos calculs.

4. Dans cet exercice, arrondissez les calculs au 100ème. Indiquez toutes les formules utilisées et détaillez vos calculs.

Le Quidditch est un sport mixte de balle, issu de l'univers imaginaire de J. K. Rowling pour la saga Harry Potter. Dans ce sport, deux équipes s'affrontent, chacune étant formée de sept joueurs chevauchant des balais volants. Un fan de Quidditch a noté à chaque match, X : «le nombre de *souafles* rattrapés par son gardien de Quidditch préféré, Ron Weasley». (Le souafle est une balle, d'une taille comparable à celle d'un ballon de football.) Il a obtenu la distribution des effectifs suivante :

Valeurs de X	5	8	12	14	15	18	20
Effectifs	6	10	7	15	20	4	4

- (a) Quelle est la nature de cette variable X ? Justifiez.
- (b) Calculez la moyenne de X et donnez-en une interprétation. Justifiez.
- (c) Donnez la distribution des fréquences cumulées (F_i) de X et représentez, *en vert*, sa courbe cumulative.
- (d) Donnez une interprétation de F_3 .
- (e) Déterminez le premier quartile de X . Justifiez et interprétez dans ce contexte.
- (f) Représentez la boîte à moustache de X en précisant les mesures utilisées pour sa représentation.
- (g) Calculez la variance-échantillon et l'écart-type-échantillon. Justifiez vos calculs.

5. Dans cet exercice, arrondissez les calculs au 100ème. Indiquez toutes les formules utilisées et détaillez vos calculs.

Face à la flambée des prix de l'énergie, de nombreux Belges redoutent de ne pas arriver à payer leurs factures. Une majorité de Belges affirme avoir modifié certains comportements, notamment en utilisant moins d'électricité, de gaz, d'eau ou de combustible de chauffage. Le but de cette analyse est d'étudier le comportement des Belges concernant la température à laquelle ils ont chauffé leur habitation, durant l'automne 2022. Les données collectées, relatives à X : «la température (en degrés Celsius) réglée sur le thermostat de leur habitation», auprès d'un certain nombre de personnes sont reprises dans le tableau ci-dessous.

- (a) Complétez le tableau de données.

X	Effectifs	Fréquences	Fréquences cumulées
$[14, 17[$	19		
$[17, 18[$	31		
$[18, 19[$	28		
$[19, 20[$	27		
$[20, 21[$	15		
$[21, 24[$	5		

- (b) Quelle est la nature de cette variable ? Justifiez.
- (c) Représentez la courbe cumulative. Déduisez-en approximativement la médiane et donnez-en une interprétation dans ce contexte.
- (d) Interprétez F_5 .
- (e) Calculez la moyenne-échantillon approchée et donnez-en une interprétation dans son contexte.
- (f) Quel est le mode approché de la variable X ? Justifiez et interprétez celui-ci dans son contexte.
- (g) Calculez le premier quartile approché de X . Interprétez celui-ci dans ce contexte.

6. Dans cet exercice, arrondissez les calculs au 100ème. Indiquez toutes les formules utilisées et détaillez vos calculs.

Le tableau suivant donne la distribution de la variable X qui représente le temps par semaine (en heures) que les étudiants passent à faire la cuisine.

Temps	Effectif n_i
$[0, 5[$	63
$[5, 10[$	49
$[10, 15[$	19
$[15, 20[$	31

- (a) Quelle est la nature de cette variable? Justifiez.
- (b) Donnez la distribution statistique de cette variable et tracez son histogramme.
- (c) Donnez la distribution des fréquences cumulées de X et tracez la courbe cumulative.
- (d) Déterminez : mode, médiane, moyenne-échantillon, premier quartile et troisième quartile approché(e). Justifiez et interprétez chacune de celles-ci.
- (e) Dessinez la boîte à moustache de cette série statistique.
- (f) Déterminez la variance-échantillon et l'écart-type-échantillon approchée.
7. On considère l'expérience aléatoire qui consiste en jeter un dé à 6 faces qui est bien équilibré et numéroté de 1 à 6. On définit les événements G : «le résultat est impair» et H : «le résultat est inférieur ou égal à 2».
- (a) Donnez l'ensemble fondamental associé à cet expérience aléatoire.
- (b) On jette le dé et on observe 1. L'événement G se réalise-t-il? Justifiez.
- (c) Donnez les événements G et H sous forme mathématique (en utilisant la notation ensembliste).
- (d) Donnez l'événement complémentaire de G et l'événement complémentaire de H .
- (e) Donnez les événements :
- $G \cap H$
 - $G \cup H$
 - G^c
 - $\overline{H}$
 - $\overline{G \cup H}$
 - $\overline{G \cap H}$

vii. $(G \cap H) \cup \overline{G \cap H}$

- (f) Donnez la probabilité de H en précisant la méthode utilisée pour la calcul pour celle-ci.
- (g) Calculez la probabilité de $\overline{G \cap H}$.
8. Une expérience aléatoire qui a pour ensemble fondamental $\Omega = \{E_1, E_2, E_3\}$ a été répétée 50 fois. On a observé 20 fois E_1 , 13 fois E_2 et 17 fois E_3 .
- (a) Quelle est la probabilité de chacun des événements ?
- (b) Quelle méthode de calcul des probabilités avez-vous utilisée ? Justifiez.
9. Une expérience aléatoire a pour ensemble fondamental $\Omega = \{E_1, E_2, E_3, E_4\}$ où chaque événement est équiprobable.
- (a) Quelle est la probabilité de E_2 ?
- (b) Vérifiez que les conditions de base de probabilités sont satisfaites.
- (c) Quelle est la probabilité d'observer « E_1 ou E_3 » ?
- (d) Quelle d méthode de calcul des probabilités avez-vous utilisée ? Justifiez.
10. Un business analyst a attribué de manière subjective les probabilités suivantes aux quatre résultats d'une expérience aléatoire : $P(A_1) = 0.10$, $P(A_2) = 0.15$, $P(A_3) = 0.40$ et $P(A_4) = 0.20$. Est-il correct d'attribuer de telles probabilités ? Justifiez.
11. Soient A et B des événements tels que $P(A) = 1/3$, $P(B) = 1/2$ et $P(A \cap B) = 1/4$. Calculez et justifiez vos étapes de calculs :
- (a) $P(\overline{A})$
- (b) $P(\overline{B})$
- (c) $P(\overline{A \cap B})$
- (d) $P(A \cup B)$
- (e) $P(\overline{A \cup B})$
12. Soient A et B des événements tels que $P(A) = 0.42$, $P(B) = 0.65$ et $P(A \cup B) = 0.78$. Calculez :
- (a) $P(\overline{A})$
- (b) $P(\overline{B})$
- (c) $P(\overline{A \cup B})$

(d) $P(A \cap B)$

(e) $P(\overline{A \cap B})$

13. Une entreprise envoie une campagne marketing. On dispose des données :

	Achat (A)	Pas d'achat ($\bar{A}$)	Total
A cliqué (C)	120	80	200
N'a pas cliqué ($\bar{C}$)	180	620	800
Total	300	700	1000

- (a) Quelle est la probabilité qu'un client ait cliqué sur l'e-mail ?
- (b) Quelle est la probabilité qu'un client n'ait pas acheté ?
- (c) Quelle est la probabilité qu'un client ait cliqué «et» acheté ?
- (d) Quelle est la probabilité qu'un client n'ait pas cliqué mais ait acheté ?
- (e) Quelle est la probabilité qu'un client réalise un achat sachant qu'il a cliqué ?
- (f) Quelle est la probabilité qu'un client ne réalise pas d'achat sachant qu'il a cliqué ?
- (g) Quelle est la probabilité qu'un client réalise un achat sachant qu'il n'a pas cliqué ?
- (h) Le clic est-il un bon indicateur d'achat d'après ces données ?
- (i) Un client qui a cliqué est-il plus susceptible d'acheter qu'un client pris au hasard ?

14. Dans une entreprise, on considère les événements suivants : A : «un employé suit une formation en analyse de données» et B : «un employé parle couramment l'anglais». On sait que $P(A) = 0.40$ et $P(B) = 0.65$). Les événements sont supposés indépendants. Quelle est la probabilité qu'un employé suive une formation en analyse de données et parle couramment l'anglais ?

15. *Pour cet exercice, avant toute chose : définissez les notations de manière complète et précise pour les événements dont vous calculez les probabilités.*

Une étude de marché a révélé que parmi 400 familles interrogées, 300 possédaient un smartphone, 140 un ordinateur à écran tactile, et 80 familles possédaient les deux types d'appareil. Quelle est la probabilité qu'une famille interrogée au hasard parmi ces 400 familles :

- (a) possède un ordinateur à écran tactile ?
- (b) possède un smartphone ?
- (c) possède un ordinateur à écran tactile et un smartphone ?
- (d) possède un ordinateur à écran tactile ou un smartphone ?

16. Un fast-food propose des hamburgers avec un, deux ou trois steaks hachés. Soit X la variable aléatoire égale au nombre de steaks hachés commandé par un client choisi au hasard. On dispose des probabilités de X : $P(X = 1) = 0.4$, $P(X = 2) = 0.5$ et $P(X = 3) = 0.1$.

(a) Calculez et interprétez en français dans le langage courant dans le contexte dont il est question :

- i. $P(X < 2)$.
- ii. $P(X \leq 2)$.
- iii. $P(X < 1)$.
- iv. $P(X < 2 \text{ ou } X > 2)$.

(b) Donner la distribution de la fonction de répartition de X .

(c) Calculez l'espérance de X . Interprétez.

(d) Calculez la variance et l'écart-type de X . Arrondissez au 1000ème.

17. On considère la variable aléatoire X ayant pour loi :

$X = x$	$P(X = x)$
0	0.0467
1	0.1866
2	0.3110
3	0.2765
4	0.1382
5	0.0369
6	0.0041

(a) Représentez le diagramme en bâtons de la loi de X .

(b) Donnez distribution de la fonction de répartition de X .

(c) Représentez graphiquement $F(x)$, la fonction de répartition de X .

18. Soit X une v.a. continue distribuée uniformément entre 1 et 1.5.

(a) Écrivez la fonction de densité de probabilité $f(x)$ de cette v.a. et tracez son graphe.

(b) Calculez $P(X = 1.25)$

(c) Calculez $P(1 \leq X \leq 1.25)$

(d) Calculez $P(1.2 < X < 1.5)$

19. Considérons $Z \sim \mathcal{N}(0, 1)$ et $\Phi(z)$ sa fonction de répartition. Utilisez la table de la loi normale pour calculer les probabilités suivantes, en justifiant toutes les étapes de vos calculs :

- (a) $\Phi(1.93)$
- (b) $\Phi(2.22)$
- (c) $\Phi(-1.65)$
- (d) $\Phi(-1)$
- (e) $\Phi(-3.48)$
- (f) $P(Z > -1)$
- (g) $P(Z \geq -1)$
- (h) $P(Z > 0.5)$
- (i) $P(-1 \leq Z \leq 0.51)$
- (j) $P(0.24 < Z < 1.87)$

20. Considérons $Z \sim \mathcal{N}(0, 1)$ et $\Phi(z)$ sa fonction de répartition. Utilisez la table de la loi normale pour déterminer z tel que :

- (a) $P(Z \leq z) = 0.7734$
- (b) $P(Z \leq z) = 0.9573$
- (c) $P(Z \leq z) = 0.514$
- (d) $P(Z \leq z) = 0.3124$
- (e) $P(Z \leq z) = 0.1357$

21. Soit $X \sim \mathcal{N}(10, 0.16)$

- (a) Complétez : $X \sim \mathcal{N}(10, 0.16) \Rightarrow Z = \dots \sim \mathcal{N}(1, 0)$
- (b) Calculez $P(X \leq 12)$
- (c) Calculez $P(X \leq 8)$
- (d) Calculez $P(8 \leq X \leq 12)$

22. Soit $X \sim \mathcal{N}(\mu, \sigma^2)$

- (a) Complétez : $X \sim \mathcal{N}(\dots, \dots) \Rightarrow Z = \frac{X-11}{3.2} \sim \mathcal{N}(1, 0)$
- (b) Calculez $P(X \leq 13)$
- (c) Calculez $P(X \leq 10)$
- (d) Calculez $P(X \geq 12)$

23. Soit $X \sim \mathcal{N}(5; 8)$. Calculez la probabilité que X soit compris entre 2.53 (inclus) et 7.98 (exclu). Arrondissez au 10000ème. Esquissez graphiquement X et la probabilité calculée.

24. Soit $X \sim \mathcal{N}(4; 7)$. Calculez la probabilité que X soit compris entre 2.94 (exclu) et 6.25 (inclus). Arrondissez au 10000ème. Esquissez graphiquement X et la probabilité calculée.

25. On considère une variable aléatoire $X \sim \mathcal{N}(-2; 9)$. Calculez la probabilité que X soit comprise entre -2.54 (inclus) et -0.1 (exclu). Arrondissez au 10000ème. Esquissez graphiquement X et la probabilité calculée.

Pour l'inférence statistique, définissez vos notations, précisez la statistique utilisée et les conditions d'applications, développez vos calculs et interprétez l'intervalle obtenu par une phrase en français, dans le contexte dont il est question.

26. Le revenu des habitants d'une ville est une v.a. $\mathcal{N}(\mu, \sigma^2)$, où $\sigma = 2000$ (euros). On dispose d'un E.A.S. de 100 habitants. Construisez un intervalle de confiance pour la moyenne des revenus des habitants de cette ville, au niveau de signification $\alpha = 0.05$. On dispose du revenu moyen calculé sur cette échantillon : 7348 euros.

27. La durée des achats dans un grand magasin suit une distribution $\mathcal{N}(\mu, 256)$. On prélève un E.A.S. de 64 personnes parmi les clients en effectuant leurs achats dans ce magasin. La moyenne des durées des achats mesurée sur cet échantillon est de 33 minutes. Déterminez un intervalle de confiance pour la moyenne des durées des achats de l'ensemble des clients fréquentant ce grand magasin :
- (a) au niveau de signification $\alpha = 0.05$.
 - (b) au niveau de signification $\alpha = 0.01$.
 - (c) Comparez les intervalles obtenus aux points (a) et (b). Commentez.
28. Les notes en statistiques des étudiants d'une classe suivent une loi normale. On prélève un E.A.S. de 4 notes (sur 100 points) : 64, 66, 89, 77. Calculez un I.C. pour la moyenne des notes en statistique de toute la classe, au niveau de signification $\alpha = 0.05$.
29. On prélève un E.A.S de 50 individus des hommes en Belgique et on s'intéresse à leur taille. On obtient la moyenne-échantillon $\bar{X} = 50$ et l'écart-type corrigé échantillon $s' = 8.2$. Déterminez un I.C. au niveau de signification $\alpha = 0.05$.
30. On s'intéresse au poids des alevins (petits poissons) d'une population. On prélève un échantillon de 45 alevins. La moyenne observée de cet échantillon est de 8.24 grammes (gr) et $s' = 3$ gr. On travaillera au niveau de signification $\alpha = 5\%$.
- (a) Déterminez un I.C. pour le poids moyen des alevins de la population.
 - (b) Combien faudrait-il contrôler d'alevins pour que l'I.C. du poids moyen soit déterminé avec une amplitude de 1gr au maximum.

Arrondissez vos calculs au 10 000ème pour les exercices qui suivent.

31. On considère le problème de test $H_0 : \mu = 20 \leftrightarrow H_1 : \mu < 20$. Un échantillon de 50 individus fournit une moyenne de 19.4. L'écart-type population est 2.
- (a) Déterminez la valeur de la statistique de test sous H_0 .
 - (b) Quelle est la p-valeur.
 - (c) En utilisant $\alpha = 5\%$, quelle est votre conclusion ?

32. Le gérant d'une concession automobile envisage un nouveau plan de primes destiné à augmenter le volume des ventes. Actuellement, le volume moyen des ventes est de 14 automobiles par mois. Le manager souhaite mener une étude pour voir si le nouveau plan de bonus augmente volume des ventes. Pour collecter des données sur le plan, un échantillon de vendeurs sera autorisé à vendre dans le cadre du nouveau plan de bonus pendant une période d'un mois.
- (a) Écrivez un test d'hypothèse pour cette situation.
 - (b) Commentez la conclusion lorsque H_0 ne peut pas être rejeté.
 - (c) Commentez la conclusion lorsque H_0 peut être rejeté.
33. L'étiquette d'une bouteille de 3 litres de jus d'orange indique que le jus d'orange contient en moyenne 1 gramme de graisse ou moins. Répondez aux questions suivantes pour un test d'hypothèse qui pourrait être utilisé pour tester la véracité de l'indication sur l'étiquette.
- (a) Ecrivez un test d'hypothèse pour cette situation.
 - (b) Quelle est l'erreur de type I dans cette situation? Quelles sont les conséquences de cette erreur?
 - (c) Quelle est l'erreur de type II dans cette situation? Quelles sont les conséquences de cette erreur?
34. Une nouvelle méthode de production sera mise en œuvre si un test d'hypothèse soutient comme conclusion que la nouvelle méthode réduit le coût horaire moyen d'exploitation.
- (a) Écrivez un test hypothèses approprié si le coût moyen pour le projet actuel la méthode de production est de 220 euros l'heure.
 - (b) Quelle est l'erreur de type I dans cette situation? Quelles sont les conséquences de cette erreur?
 - (c) Quelle est l'erreur de type II dans cette situation? Quelles sont les conséquences de cette erreur?
35. En 2019 tous les indicateurs étaient au vert pour les vacanciers belges ! Durant l'été 2019, ils étaient 65 % à partir en vacances. Se relaxer, se retrouver en famille ou avec des amis, découvrir de nouvelles cultures, voici les principales intentions des vacanciers belges en 2019 en plus de s'évader un peu plus longtemps que les années précédentes. 78 % des vacanciers belges sont restés en Europe. La France était en 2019, la principale destination étrangère pour nos compatriotes (32%), suivie

par l'Espagne (19%) et l'Italie (11%). 15% des Belges ont choisi en 2019 de passer leurs vacances en Belgique. Le budget vacances moyen des Belges pour l'été 2019 se chiffrait à 2238 euros par famille. En 2019, le vacancier belge avait tendance à rallonger ses vacances pour atteindre une moyenne de 9.1 nuitées.

Crise de Covid-19 oblige, les Belges vont-ils rogner en 2020 sur leurs réservations pour partir en vacances ? Ceux qui avaient néanmoins décidé de partir, vont-ils diminuer leurs dépenses pendant les vacances de 2020 ? Une enquête a été menée en Belgique pour sonder les intentions des Belges concernant leurs vacances d'été 2020.

On travaillera avec un niveau de signification de 5%.

Les données collectées donnent lieu aux résultats suivants : $\sum_{i=1}^{45} x_i = 90639$ et $\sum_{i=1}^{45} x_i^2 = 209949834.9$

- (a) Peut-on affirmer que le budget moyen des Belges pour les vacances d'été 2020 est inférieur à celui de l'été 2019 ? (Quelles sont les hypothèses à tester ? Quelle est la loi de la statistique de test sous H_0 ? Quelle est la règle de rejet de ce test ? Quelle est la décision à l'issue de cet procédure ?) Commentez.
 - (b) Donnez l'intervalle de confiance pour le budget moyen des Belges pour les vacances d'été 2020.
36. On considère le test d'hypothèse $H_0 : p = 0.75 \leftrightarrow H_1 : p < 0.75$, où p est une proportion population. On dispose d'un échantillon de taille 300. On travaillera au niveau de signification $\alpha = 0.05$. Calculez les p-valeurs pour les résultats suivantes et donnez une conclusion : (a) $\hat{p} = 0.68$; (b) $\hat{p} = 0.72$; (c) $\hat{p} = 0.7$; (d) $\hat{p} = 0.77$.
37. Une étude réalisée par un groupe d'analystes a révélé que 64 % des acheteurs dans les supermarchés trouvent que les marques du distributeur sont aussi bonnes que les grandes marques. Pour déterminer si ce résultat s'applique à son propre produit, le fabricant d'une marque connue de ketchup a demandé à un échantillon d'acheteurs s'ils pensaient que le ketchup du supermarché était aussi bon que le ketchup de leur marque.
- (a) Formuler les hypothèses d'un test pour déterminer si le pourcentage de acheteurs de supermarchés qui trouvent que le ketchup du supermarché est aussi bon que le ketchup de marque connue est différente de 64 %.
 - (b) La marque connue a récolté un échantillon de 100 acheteurs et indique que 52 parmi eux affirment que la marque du supermarché est aussi bonne que la marque connue. Quelle est la p-valeur dans ce cas ?
 - (c) Pour un niveau de signification $\alpha = 0.05$, déduisez une conclusion à partir de votre réponse à la question (b).
 - (d) Le fabricant de la marque connue de ketchup devrait-il se réjouir de cette conclusion ? Justifiez.

38. La veille d'un match de football de ligue des champions de l'UEFA, une enquête révèle que 22% des téléspectateurs envisagent de regarder une nouvelle émission de divertissement sur une chaîne de télévision belge qui commencera quelques jours plus tard. Juste avant le match de football, lors de la mi-temps du match de football, et juste après le match, la chaîne diffuse des publicités pour cette nouvelle émission. Le lendemain du match de football, un échantillon de 1532 téléspectateurs est interrogé et 414 d'entre eux déclarent envisager de regarder la nouvelle émission de divertissement.

- (a) Donner une estimation ponctuelle de la proportion de téléspectateurs qui envisagent de regarder la nouvelle émission de divertissement, après diffusion des publicités.
- (b) Déterminez si l'intention de regarder la nouvelle émission de divertissement a significativement augmenté après avoir la diffusion des publicités. Formuler un test d'hypothèse approprié, calculez la p-valeur et donnez votre conclusion.
- (c) Pourquoi de telles études sont-elles utiles aux entreprises et aux agences de publicité ?

Solutions

1. Etude statistique sur la couleur primaire ou secondaire préférée d'un groupe d'étudiants

- (a) On définit la variable X : «la couleur primaire ou secondaire préférée du groupe d'étudiants interrogés».
- (b) Il s'agit d'une variable qualitative puisqu'il ne s'agit de pas valeurs numériques avec lesquels on va effectuer des calculs numériques et elle est nominale puisqu'il n'y a pas d'ordre dans les couleurs.
- (c) On associe chaque modalité à une notation : $x_1 = \text{«violet»}$, $x_2 = \text{«rouge»}$, $x_3 = \text{«orange»}$, $x_4 = \text{«jaune»}$, $x_5 = \text{«vert»}$, $x_6 = \text{«bleu»}$.
- (d) On a observé 6 modalités distinctes. Le nombre de modalités est noté $N = 6$.
- (e) La distribution des effectifs de la variable X :

X	Effectif n_i
$x_1 = \text{violet}$	$n_1 = 4$
$x_2 = \text{rouge}$	$n_2 = 4$
$x_3 = \text{orange}$	$n_3 = 3$
$x_4 = \text{jaune}$	$n_4 = 2$
$x_5 = \text{vert}$	$n_5 = 9$
$x_6 = \text{bleu}$	$n_6 = 15$

- (f) L'effectif total de l'échantillon pour la variable X est :

$$\begin{aligned}n &= n_1 + n_2 + n_3 + n_4 + n_5 + n_6 \\&= 4 + 4 + 3 + 2 + 9 + 15 \\&= 37\end{aligned}$$

- (g) Donnez la distribution statistique de la variable X est, en notation décimale arrondie au 100ème :


X	Fréquence f_i
$x_1 = \text{violet}$	$f_1 = 0.11$
$x_2 = \text{rouge}$	$f_2 = 0.11$
$x_3 = \text{orange}$	$f_3 = 0.08$
$x_4 = \text{jaune}$	$f_4 = 0.05$
$x_5 = \text{vert}$	$f_5 = 0.24$
$x_6 = \text{bleu}$	$f_6 = 0.41$

2. Étude statistique sur le nombre de frères et sœurs d'un groupe d'étudiants

- (a) On définit la variable X : « le nombre de frères et sœurs d'un groupe d'étudiants interrogés ».
- (b) Il s'agit d'une variable quantitative car elle se prête à des calculs numériques et elle est discrète car elle prend un nombre fini de valeurs.
- (c) On associe chaque valeur distincte à une notation, par ordre croissant : $x_1 = 0$, $x_2 = 1$, $x_3 = 2$, $x_4 = 3$, $x_5 = 4$, $x_6 = 5$, $x_7 = 6$, $x_8 = 7$, $x_9 = 8$ et $x_{10} = 13$.
- (d) Il y a 10 modalités distinctes, on peut préciser que les modalités sont des « valeurs ».
- (e) La distribution des effectifs de la variable X :

X	Effectif n_i
$x_1 = 0$	$n_1 = 5$
$x_2 = 1$	$n_2 = 11$
$x_3 = 2$	$n_3 = 12$
$x_4 = 3$	$n_4 = 4$
$x_5 = 4$	$n_5 = 2$
$x_6 = 5$	$n_6 = 1$
$x_7 = 6$	$n_7 = 1$
$x_8 = 7$	$n_8 = 1$
$x_9 = 8$	$n_9 = 1$
$x_{10} = 13$	$n_{10} = 1$

Représentation graphique :




(f) L'effectif total est

$$\begin{aligned}
 n &= \sum_{i=1}^{10} n_i \\
 &= 5 + 11 + 12 + 4 + 2 + 1 + 1 + 1 + 1 + 1 \\
 &= 39
 \end{aligned}$$

(g) La distribution statistique de la variable X est :

X	Fréquence f_i
$x_1 = 0$	$f_1 = 0.128$
$x_2 = 1$	$f_2 = 0.282$
$x_3 = 2$	$f_3 = 0.307$
$x_4 = 3$	$f_4 = 0.102$
$x_5 = 4$	$f_5 = 0.051$
$x_6 = 5$	$f_6 = 0.026$
$x_7 = 6$	$f_7 = 0.026$
$x_8 = 7$	$f_8 = 0.026$
$x_9 = 8$	$f_9 = 0.026$
$x_{10} = 13$	$f_{10} = 0.026$
	Total : 1

Représentation graphique :




(h) Environ 10% des étudiants interrogés ont 3 frères et soeurs.

(i) La distribution des fréquences cumulées de la variable X est :

X	Fréquence cumulée F_i
$x_1 = 0$	$F_1 = 0.128$
$x_2 = 1$	$F_2 = 0.410$
$x_3 = 2$	$F_3 = 0.717$
$x_4 = 3$	$F_4 = 0.819$
$x_5 = 4$	$F_5 = 0.870$
$x_6 = 5$	$F_6 = 0.896$
$x_7 = 6$	$F_7 = 0.922$
$x_8 = 7$	$F_8 = 0.948$
$x_9 = 8$	$F_9 = 0.974$
$x_{10} = 13$	$F_{10} = 1$

(j) Environ 82% des étudiants interrogées ont 3 frères et soeurs ou moins de 3 frères et soeurs.

(k) Courbe cumulative de la variable X



(l) (1) Le mode est $M = 2$ car il correspond à la valeur la plus fréquente : $f_3 = 0.307$ est la plus grande fréquence de la distribution statistique de X .

Interprétons cette valeur. Dans l'échantillon composé de 39 étudiants, on a observé le plus souvent que les individus ont 2 frères ou sœurs.

(2) La médiane de la variable X est $m = x_3 = 2$ car $F_2 = 0.410 < 0.5$ et $F_3 = 0.717 > 0.5$. Autrement dit, 2 est la première valeur pour laquelle la fréquence cumulée est supérieure à 50% :

X	Fréquence cumulée F_i
$x_1 = 0$	$F_1 = 0.128 < 50\%$
$x_2 = 1$	$F_2 = 0.410 < 50\%$
$x_3 = 2$	$F_3 = 0.717 > 50\%$
$\vdots$	$\vdots$

Interprétons cette valeur. Dans l'échantillon composé de 39 étudiants, environ la moitié à moins de 2 frères et sœurs et environ la moitié à plus de 2 frères et sœurs.

(3) Le premier quartile est $Q_1 = x_2 = 1$ car

- $F_1 = 0.128 < 0.25$
- $F_2 = 0.410 > 0.25$

donc x_2 est la première valeur pour laquelle la fréquence cumulée est supérieure ou égale à 25%.

Interprétation : dans l'échantillon composé de 39 étudiants, environ 25% des individus ont un nombre inférieur ou égal à 1 frère ou 1 sœur et environ 75% des individus ont un nombre supérieur ou égal à 1 frère ou 1 sœur . Le deuxième quartile est $Q_2 = x_3 = 2$ c'est la médiane (dont avons déjà discuté). Le troisième quartile est $Q_3 = x_4 = 3$ car :

- $F_3 = 71.7\% < 75\%$
- $F_4 = 0.819 = 81.9\% > 75\%$ donc $x_4 = 3$ est la première valeur pour laquelle la fréquence cumulée est supérieure ou égale à 75%.

Interprétation : dans l'échantillon composé de 39 étudiants, environ 75% des individus ont un nombre inférieur ou égal à 3 frères et sœurs et environ 25% des individus ont un nombre supérieur ou égal à 3 frères et sœurs.

(m) - Première méthode : la *moyenne-échantillon* est la somme de toutes les valeurs observées de l'échantillon divisée par l'effectif total :

$$\text{Moyenne-échantillon} = \frac{\text{Somme de toutes les valeurs de l'échantillon}}{\text{Effectif total}}$$

Somme de toutes les valeurs de l'échantillon

$$= 0+0+0+0+0+1+1+1+1+1+1+1+1+1+1+1+2+2+2+2+2+2+2+2+2+2+2+2+3+3+3+3+4+4+5+6+7+8+13 = 94$$

Par ailleurs, comme l'effectif total est 39, on obtient :

$$\text{Moyenne-échantillon} = \frac{94}{39} = 2.41$$

- Deuxième méthode (la formule faisant intervenir les effectifs) :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^N n_i x_i = \frac{n_1 x_1 + n_2 x_2 + \dots + n_N x_N}{n}$$

Puisqu'il y a 10 valeurs distinctes, $N = 10$ et on calcule chaque terme de la forme $n_i x_i$:

X	Effectif n_i	$n_i x_i$
$x_1 = 0$	$n_1 = 5$	$n_1 x_1 = 0$
$x_2 = 1$	$n_2 = 11$	$n_2 x_2 = 11$
$x_3 = 2$	$n_3 = 12$	$n_3 x_3 = 24$
$x_4 = 3$	$n_4 = 4$	$n_4 x_4 = 12$
$x_5 = 4$	$n_5 = 2$	$n_5 x_5 = 8$
$x_6 = 5$	$n_6 = 1$	$n_6 x_6 = 5$
$x_7 = 6$	$n_7 = 1$	$n_7 x_7 = 6$
$x_8 = 7$	$n_8 = 1$	$n_8 x_8 = 7$
$x_9 = 8$	$n_9 = 1$	$n_9 x_9 = 8$
$x_{10} = 13$	$n_{10} = 1$	$n_{10} x_{10} = 13$

Par ailleurs, comme l'effectif total est $n = 39$, on obtient :

$$\begin{aligned}
 \bar{x} &= \frac{n_1 x_1 + n_2 x_2 + \dots + n_{10} x_{10}}{39} \\
 &= \frac{0 + 11 + 24 + 12 + 8 + 5 + 6 + 7 + 8 + 13}{39} \\
 &= 2.41
 \end{aligned}$$

- Troisième méthode (la formule faisant intervenir les fréquences) :

$$\bar{x} = \sum_{i=1}^N f_i x_i = f_1 x_1 + f_2 x_2 + \dots + f_N x_N$$

Puisqu'il y a 10 valeurs distinctes, $N = 10$ et on calcule chaque terme de la forme $f_i x_i$:

X	Fréquence f_i	$f_i x_i$
$x_1 = 0$	$f_1 = 0.128$	$f_1 x_1 = 0$
$x_2 = 1$	$f_2 = 0.282$	$f_2 x_2 = 0.282$
$x_3 = 2$	$f_3 = 0.307$	$f_3 x_3 = 0.614$
$x_4 = 3$	$f_4 = 0.102$	$f_4 x_4 = 0.306$
$x_5 = 4$	$f_5 = 0.051$	$f_5 x_5 = 0.204$
$x_6 = 5$	$f_6 = 0.026$	$f_6 x_6 = 0.130$
$x_7 = 6$	$f_7 = 0.026$	$f_7 x_7 = 0.156$
$x_8 = 7$	$f_8 = 0.026$	$f_8 x_8 = 0.182$
$x_9 = 8$	$f_9 = 0.026$	$f_9 x_9 = 0.208$
$x_{10} = 13$	$f_{10} = 0.026$	$f_{10} x_{10} = 0.338$

Par ailleurs, comme l'effectif total est $n = 39$, on obtient :

$$\begin{aligned}
 \bar{x} &= f_1 x_1 + f_2 x_2 + \dots + f_N x_N \\
 &= 0 + 0.282 + 0.614 + 0.306 + 0.204 + 0.130 + 0.156 + 0.182 + 0.208 + 0.338 \\
 &= 2.42
 \end{aligned}$$

- Une interprétation pour la valeur $\bar{x} = 2.42$ est : En moyenne, les d'étudiants interrogés ont 2.42 frères et soeurs.

(n) - L'écart interquartile d'une série statistique est la différence entre le troisième quartile et le premier quartile :

$$\text{Ecart interquartile} = Q_3 - Q_1 = 3 - 1 = 2.$$

Interprétation : dans l'échantillon composé de 39 étudiants, environ 50% des individus ont entre 1 et 3 frères et soeurs, donc ces observations sont dispersées sur une longueur de 2.

- L'étendue d'une série statistique est la différence entre la valeur maximale et la valeur minimale de cette série statistique :

$$\begin{aligned}
 \text{Etendue} &= \text{Max des valeurs} - \text{Min des valeurs} \\
 &= 13 - 0 \\
 &= 13
 \end{aligned}$$

Interprétation : dans l'échantillon composé de 39 étudiants, le nombre de frères et de soeurs

est entre 0 et 13 donc ces observations sont dispersées sur une longueur qui vaut 13.

- (o) Pour la boîte à moustache nous avons d'abord besoin des 3 quartiles : $Q_1 = 1$, $Q_3 = 3$, $m = Q_2 = 2$.

Construction de la partie « rectangle » de la boîte à moustache :

- On trace un rectangle allant de $Q_1 = 1$ jusque $Q_3 = 3$ de longueur $I_Q = 2$.
- On trace un trait vertical au niveau de $m = Q_2 = 2$.

Pour déterminer s'il y a des valeurs extrêmes, on calcule les bornes suivantes :

- Borne inférieure : $Q_1 - 1.5 \times I_Q = 1 - 1.5 \times 2 = -2$
- Borne supérieure : $Q_3 + 1.5 \times I_Q = 3 + 1.5 \times 2 = 6$

Construction de la partie « moustaches » et « valeurs extrêmes » de la boîte à moustache :

- La moustache à gauche s'étend jusque 0 puisque est la plus petite valeur observée dans l'intervalle $[-2, 6]$.
- La plus grande valeur observée dans l'intervalle $[0; 6]$ est 6 donc la moustache de droite s'étend jusqu'à 6.

En dehors de la boîte, il reste dès lors les observations 7, 8 et 13. On calcule :

$$Q_1 - 3I_Q = 1 - 3 \times 2 = -5 \text{ et } Q_3 + 3I_Q = 3 + 3 \times 2 = 9$$

Remarquons que 0 est la plus petite valeur observée et que étant donné le contexte, les nombres négatifs ne sont pas des observations possibles. Il reste donc à déterminer comment se situent les observations en dehors de la boîte à moustache par rapport à $Q_3 + 3I_Q = 9$:

- Il y a deux valeurs entre 6 (l'extrémité de la moustache droite) et 9 : les valeurs 7 et 8 qui sont légèrement en dehors. Nous les symbolisons par un point ($\circ$)
- Il reste $13 > 9$, c'est à dire que 13 est supérieur à $3I_Q$ au-delà de la moustache à droite. Nous symbolisons celui-ci par un astérisque (*).

Nous obtenons finalement :



(p) - La variance-échantillon peut se calculer de différentes façon, dans cet exercice, vous avez le choix. Je choisis d'utiliser la suivante :

$$s^2 = \sum_{i=1}^N f_i x_i^2 - \bar{x}^2$$

Reprenons la distribution statistique de X pour calculer $f_i x_i^2$ pour chaque valeur :

X	Fréquence f_i	$f_i x_i^2$
$x_1 = 0$	$f_1 = 0.128$	$f_1 x_1^2 = 0$
$x_2 = 1$	$f_2 = 0.282$	$f_2 x_2^2 = 0.282$
$x_3 = 2$	$f_3 = 0.307$	$f_3 x_3^2 = 1.228$
$x_4 = 3$	$f_4 = 0.102$	$f_4 x_4^2 = 0.918$
$x_5 = 4$	$f_5 = 0.051$	$f_5 x_5^2 = 0.816$
$x_6 = 5$	$f_6 = 0.026$	$f_6 x_6^2 = 0.65$
$x_7 = 6$	$f_7 = 0.026$	$f_7 x_7^2 = 0.936$
$x_8 = 7$	$f_8 = 0.026$	$f_8 x_8^2 = 1.274$
$x_9 = 8$	$f_9 = 0.026$	$f_9 x_9^2 = 1.664$
$x_{10} = 13$	$f_{10} = 0.026$	$f_{10} x_{10}^2 = 4.394$

Comme $N = 10$ et la moyenne-échantillon est $\bar{x} = 2.42$, on obtient :

$$\begin{aligned}
 s^2 &= \sum_{i=1}^{10} f_i x_i^2 - (2.42)^2 \\
 &= 0 + 0.282 + 1.228 + 0.918 + 0.816 + 0.650 + 0.936 + 1.274 + 1.664 + 4.394 - 5.856 \\
 &= 6.306
 \end{aligned}$$


- L'écart-type de la variable X est

$$s = \sqrt{s^2} = \sqrt{6.306} = 2.511$$

3. Etude statistique sur le nombre de pêches abîmées de caissettes dans un supermarché


- (a) Définissons la variable X : «le nombre de pêches abîmées dans chacune des caissettes».
- (b) X est une variable quantitative car elle se prête à des calculs numériques et elle est discrète car elle prend un nombre fini de valeurs.
- (c) La distribution des effectifs de X est :

X	Effectif n_i
0	11
1	10
2	6
3	3
4	3
5	5
6	4
7	3
8	3
9	2



- (d) La distribution statistique de X est :

X	Fréquence f_i
$x_1 = 0$	$f_1 = 0.22$
$x_2 = 1$	$f_2 = 0.2$
$x_3 = 2$	$f_3 = 0.12$
$x_4 = 3$	$f_4 = 0.06$
$x_5 = 4$	$f_5 = 0.06$
$x_6 = 5$	$f_6 = 0.1$
$x_7 = 6$	$f_7 = 0.08$
$x_8 = 7$	$f_8 = 0.06$
$x_9 = 8$	$f_9 = 0.06$
$x_{10} = 9$	$f_{10} = 0.04$



- (e) $f_7 = 0.08$ est la fréquence de $x_7 = 6$ ce qui signifie dans ce contexte : dans l'échantillon de caissettes composées chacune de 9 pêches, 8% des caissettes ont 6 pêches abîmées.

(f) Le tableau des fréquences cumulées de X est

X	Fréquences cumulées F_i
$x_1 = 0$	$F_1 = 0.22$
$x_2 = 1$	0.42
$x_3 = 2$	0.54
$x_4 = 3$	0.6
$x_5 = 4$	0.66
$x_6 = 5$	0.76
$x_7 = 6$	$F_7 = 0.84$
$x_8 = 7$	0.9
$x_9 = 8$	0.96
$x_{10} = 9$	1

La courbe cumulative est représentée à la fin de cet exercice.

(g) $F_7 = 0.84$ est la fréquence cumulée en $x_7 = 6$ ce qui signifie dans ce contexte : dans l'échantillon de caissettes composées chacune de 9 pêches, 84% des caissettes ont 6 pêches abîmées ou moins de 6 pêches abîmées.

(h) Mesures de centralité :

i. Le mode est de $M = 0$ car il correspond à l'effectif le plus élevé, $n_1 = 11$.

Interprétation : on a observé le plus souvent des caissettes sans pêches abîmées.


ii. La médiane est $x_3 = 2$ car $F_2 = 0.42 < 0.50$ et $0.50 < F_3 = 0.54$

Interprétation : 50% des caisses observées ont un nombre pêches abîmées inférieur ou égal à 2 pêches et 50% des caisses observées ont un nombre pêches abîmées supérieur ou égal à 2 pêches.

iii. La moyenne-échantillon est $\bar{x} = \sum_{i=1}^{10} f_i x_i$. On utilise la distribution statistique de X pour calculer les 10 termes de $\bar{x}$:

X	Fréquence f_i	$f_i x_i$
0	0.22	0
1	0.2	0.2
2	0.12	0.24
3	0.06	0.18
4	0.06	0.24
5	0.1	0.5
6	0.08	0.48
7	0.06	0.42
8	0.06	0.48
9	0.04	0.36

Courbe cumulative de X :



4. Etude statistique sur le nombre de souafles rattrapés par Ron Weasley

- (a) X est une variable quantitative car elle se prête à des calculs numériques et elle est discrète car elle prend un nombre fini de valeurs.
- (b) Puisqu'il y a 7 valeurs distinctes, $N = 7$ et on calcule chaque terme de la forme $n_i x_i$:

X	Effectif n_i	$n_i x_i$
$x_1 = 5$	$n_1 = 6$	$n_1 x_1 = 30$
$x_2 = 8$	$n_2 = 10$	$n_2 x_2 = 80$
$x_3 = 12$	$n_3 = 17$	$n_3 x_3 = 84$
$x_4 = 14$	$n_4 = 15$	$n_4 x_4 = 210$
$x_5 = 15$	$n_5 = 20$	$n_5 x_5 = 300$
$x_6 = 18$	$n_6 = 4$	$n_6 x_6 = 72$
$x_7 = 20$	$n_7 = 4$	$n_7 x_7 = 80$
		Total : $\sum_{i=1}^7 n_i x_i = 856$

L'effectif total est $n = 6 + 10 + 17 + 15 + 20 + 4 + 4 = 66$. On obtient :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^7 n_i x_i = \frac{856}{66} = 12.97$$

En conclusion : en moyenne, Ron rattrape environ 13 souafles par match de Quidditch.

- (c) Pour donner la distribution des fréquences cumulées, nous calculons d'abord les fréquences :

X	Fréquences f_i	Fréquence cumulée F_i
$x_1 = 5$	0.09	$F_1 = 0.09$
$x_2 = 8$	0.15	$F_2 = 0.24$
$x_3 = 12$	0.11	$F_3 = 0.35$
$x_4 = 14$	0.23	$F_4 = 0.58$
$x_5 = 15$	0.30	$F_5 = 0.88$
$x_6 = 18$	0.06	$F_6 = 0.94$
$x_7 = 20$	0.06	$F_7 = 1$
	Total : 1	

(d) La proportion de matchs pour lesquels Ron Weasley a rattrapé 12 souafles ou moins est de 35%.

(e) $Q_1 = 12$ car c'est la valeur de X qui correspond à la première fréquence cumulée supérieure ou égale à 25%.

Interprétation : Durant environ 25% des matchs, Ron rattrape 12 souafles ou moins de 12 souafles.

(f) Pour construire la boîte à moustache, nous avons besoins des 5 paramètres suivants :

- i. 5, la valeur minimale observée
- ii. 20, la valeur maximale observée
- iii. les quartiles : $Q_1 = 12$ (justification voir (d)), $Q_2 = 14$ car c'est la valeur de X qui correspond à la première fréquence cumulée supérieure ou égale à 50%, et $Q_3 = 15$ car c'est la valeur de X qui correspond à la première fréquence cumulée supérieure ou égale à 75%.

(g) Variance-échantillon :

X	Fréquences f_i	$f_i x_i^2$
$x_1 = 5$	0.09	2.25
$x_2 = 8$	0.15	9.60
$x_3 = 12$	0.11	15.84
$x_4 = 14$	0.23	45.08
$x_5 = 15$	0.30	67.5
$x_6 = 18$	0.06	19.44
$x_7 = 20$	0.06	24
	Total : 1	Total : $\sum_{i=1}^7 f_i x_i^2 = 183.71$

$$\begin{aligned}
 s_X^2 &= \sum_{i=1}^7 f_i x_i^2 - \bar{x}^2 \\
 &= 183.71 - 12.97^2 \\
 &= 15.49
 \end{aligned}$$

$$s_X = \sqrt{s_X^2} = 3.94$$


5. Étude statistique sur la température à laquelle les belges ont chauffé leur habitation durant l'automne 2022

(a) Tableau de données. L'effectif total : $19+31+28+27+15+5 = 125$

X	Effectifs	Fréquences	Fréquences cumulées
$[14, 17[$	19	$19/125 = 0.15$	0.15
$[17, 18[$	31	$31/125 = 0.25$	0.40
$[18, 19[$	28	$28/125 = 0.22$	0.62
$[19, 20[$	27	$27/125 = 0.22$	0.84
$[20, 21[$	15	$15/125 = 0.12$	0.96
$[21, 24[$	5	$5/125 = 0.04$	1

(b) Il s'agit d'une variable quantitative car elle se prête à des calculs numériques et elle est continue puisque qu'elle prend des valeurs dans des intervalles.

(c) Représentation de la courbe cumulative.



On observe une médiane qui semble être proche de 18.5. Environ 50% des belges interrogés ont réglé leur thermostat sur moins de 18.5 degrés et environ 50% des belges interrogés ont réglé leur thermostat sur plus de 18.5 degrés.

(d) $F_5 = 0.96$ correspond à la classe $[20, 21[$ de X ce qui signifie que 96% des belges interrogés ont réglé leur thermostat entre 20 et 21 degrés ou ont réglé leur thermostat sur moins de 20 degrés.

(e) Moyenne-échantillon approché :

X	Centres c_i	Fréquences f_i	$f_i c_i$
[14, 17[	15.5	0.15	2.33
[17, 18[	17.5	0.25	4.38
[18, 19[	18.5	0.22	4.07
[19, 20[	19.5	0.22	4.29
[20, 21[	20.5	0.12	2.46
[21, 24[	22.5	0.04	0.9

Il y a $N = 6$ classes donc :

$$\overline{x_a} = \sum_{i=1}^6 f_i c_i = 18.43$$

Les belges interrogés ont, en moyenne, réglé leur thermostat sur environ 18.4 degrés.

(f) La classe la plus fréquente est [17, 18[donc le mode approché est $M_a = 17.5$, le centre de cette classe.

La majorité des belges interrogés ont réglé leur thermostat sur environ 17.5 degrés.

(g) Le premier quartile approché est :

$$Q_{1,a} = L_1 + l_{Q_1} \left(\frac{0.25 - F_1^*}{f_{Q_1}} \right)$$

où L_1 est la borne inférieure de la classe qui contient Q_1 , donc $L_1 = 17$ car la classe dont la fréquence cumulée est la première supérieure ou égale à 25% est [17, 18[; l_{Q_1} est la longueur de cette classe, c'est-à-dire $l_{Q_1} = 18 - 17 = 1$; F_1^* est la fréquence cumulée en $L_1 = 17$, c'est-à-dire 0.15; f_{Q_1} est la fréquence de la classe [17, 18[, c'est-à-dire 0.25. Donc :

$$Q_{1,a} = 17 + 1 \left(\frac{0.25 - 0.15}{0.25} \right) = 17.4$$


Environ 25% des belges interrogés ont réglé leur thermostat sur moins de 17.4 degrés et environ 75% des belges interrogés ont réglé leur thermostat sur plus de 17.4 degrés.

6. Etude statistique sur le temps passé par les étudiants à faire la cuisine chaque semaine

- (a) Désignons par X la variable «temps par semaine (en heures) que les étudiants passent à faire la cuisine». Cette variable est quantitative car il faut mesurer le temps, qui se prête à des calculs numériques. Elle est continue car elle peut prendre un nombre infini non dénombrable de valeurs (le temps est une échelle continue : les classes sont des intervalles).
- (b) La distribution statistique de X est donnée dans le tableau :

Temps X	Fréquence f_i
$[0,5[$	0.39
$[5,10[$	0.30
$[10,15[$	0.12
$[15,20[$	0.19


Comme les classes ont toutes la même longueur et que l'aire des rectangles de l'histogramme doit être proportionnelle à la fréquence, on peut prendre comme hauteur h_i la fréquence de chacune des classes. En effet, il faut que $h_i = k \times \frac{f_i}{l_i}$ où k est une constante. Toutes les classes ont une longueur $l_i = 5$ donc en choisissant $k = 5$, on obtient $h_i = 5 \times \frac{f_i}{5} = f_i$, pour la i -ème classe.



- (c) La distribution des fréquences cumulées de X est donnée par :

Temps X	Fréquence cumulées F_i
$[0,5[$	0.39
$[5,10[$	0.69
$[10,15[$	0.81
$[15,20[$	1

Courbe cumulative



(d) Mesures de centralité :

- i. La classe modale est $[0, 5[$ car il correspond à l'effectif le plus élevé $n_1 = 63$. Par convention, le mode est de $M = 5/2 = 2.5$

Interprétation : on a observé le plus souvent des étudiants qui font la cuisine entre 0 et 5 heures par semaine.

- ii. La classe médiane est $[5, 10[$ car $F_1 = 0.39 < 0.50$ et $0.50 < F_2 = 0.69$

La médiane approchée est

$$m_a = L_2 + l_m \frac{(0.5 - F_1^*)}{f_m} = 5 + 5 \times \frac{(0.5 - 0.39)}{0.3} = 6.83$$

Interprétation : Environ 50% des étudiants observés font la cuisine en un temps inférieur ou égal à 6.83 heures par semaine et environ 50% des étudiants observés font la cuisine en un temps supérieur ou égal à 6.83 heures par semaine.

- iii. Moyenne -échantillon approchée.

Temps X	Fréquence f_i	Centre c_i	$f_i c_i$
$[0,5[$	0.39	2.5	0.98
$[5,10[$	0.30	7.5	2.25
$[10,15[$	0.12	12.5	1.5
$[15,20[$	0.19	17.5	3.34

$$\begin{aligned}
 \bar{x}_a &= \sum_{i=1}^4 f_i c_i \\
 &= 0.98 + 2.25 + 1.5 + 3.34 \\
 &= 8.07
 \end{aligned}$$

Interprétation : Les étudiants observés passent en moyenne environ 8.07 heures par semaine à faire la cuisine.

- iv. La classe du premier quartile Q_1 est $[0, 5[$ car $F_0 = 0 < 0.25$ et $0.25 < F_1 = 0.39$

Le premier quartile approché est

$$Q_{1,a} = L_1 + l_{Q_1} \frac{(0.25 - F_1^*)}{f_{Q_1}}$$

où $L_1 = 0$ est la borne inférieure de la classe $[0, 5[$; $l_{Q_1} = 5$ est la longueur de la classe $[0, 5[$, $F_1^* = 0$ est la fréquence cumulée en 0; et $f_{Q_1} = 0.39$ est la fréquence de la classe $[0, 5[$. On obtient :

$$Q_{1,a} = 0 + 5 \times \frac{(0.25 - 0)}{0.39} = 3.21$$

Interprétation : Environ 25% des étudiants observés font la cuisine en un temps inférieur ou égal à 3.21 heures par semaine et environ 75% des étudiants observés font la cuisine en un temps supérieur ou égal à 3.21 heures par semaine.

- v. La classe du troisième quartile Q_3 est $[10, 15[$ car $F_2 = 0.69 < 0.75$ et $0.75 < F_3 = 0.81$

Le troisième quartile approché est


$$Q_{3,a} = L_3 + l_{Q_3} \frac{(0.75 - F_3^*)}{f_{Q_3}}$$

où $L_3 = 10$ est la borne inférieure de la classe $[10, 15[$; $l_{Q_3} = 5$ est la longueur de la classe $[10, 15[$, $F_3^* = 0.69$ est la fréquence cumulée en 10; et $f_{Q_3} = 0.12$ est la fréquence de la classe $[10, 15[$. On obtient :

$$Q_{3,a} = 10 + 5 \times \frac{(0.75 - 0.69)}{0.12} = 12.5$$

Interprétation : Environ 75% des étudiants observés font la cuisine en un temps inférieur ou égal à 12.5 heures par semaine et environ 25% des étudiants observés font la cuisine en un temps supérieur ou égal à 12.5 heures par semaine.

- (e) Boîte à moustache : la borne inférieure du premier intervalle est 0 et la borne supérieure du dernier intervalle est 20 : ce sont les extrémités des «moustaches». Les quartiles approchés sont déterminés et justifiés à la sous-question précédente.



- (f) Mesures de dispersion : variance approché s_a^2 et écart-type approché s_a

Temps X	Fréquence f_i	Centre c_i	$f_i c_i^2$
$[0,5[$	0.39	2.5	2.44
$[5,10[$	0.30	7.5	16.88
$[10,15[$	0.12	12.5	18.75
$[15,20[$	0.19	17.5	58.19

On obtient :

$$\begin{aligned}
 s_a^2 &= \sum_{i=1}^4 f_i c_i^2 - \bar{x}_a^2 \\
 &= (2.44 + 16.88 + 18.75 + 58.19) - (8.07)^2 \\
 &= 96.26 - (8.07)^2 \\
 &= 31.14 \\
 s_a &= \sqrt{31.14} = 5.58
 \end{aligned}$$

7. Expérience aléatoire et événements

- (a) L'ensemble fondamental est $\Omega = \{1, 2, 3, 4, 5, 6\}$
- (b) Oui puisque 1 fait partie des événements élémentaires de G .
- (c) $G = \{1, 3, 5\}$ et $H = \{1, 2\}$

(d) $\overline{G} = \{2, 4, 6\}, \overline{H} = \{3, 4, 5, 6\}$

(e) Les événements sont :

i. $G \cap H = \{1\}$

ii. $G \cup H = \{1, 2, 3, 5\}$

iii. $G^c = \{2, 4, 6\}$

iv. $\overline{H} = \{3, 4, 5, 6\}$

v. $\overline{G \cup H} = \overline{\{1, 2, 3, 5\}} = \{4, 6\}$

vi. $\overline{G \cap H} = \overline{\{1\}} = \{2, 3, 4, 5, 6\}$

vii. $(G \cap H) \cup \overline{G \cap H} = \Omega$

(f) $P(H) = \frac{\#H}{\#\Omega} = \frac{2}{6} = \frac{1}{3}$, par la définition (méthode) classique puisque les événements sont équiprobables (on sait par hypothèse que le dé est bien équilibré).

(g) $P(\overline{G \cup H}) = \frac{\#(\overline{G \cup H})}{\#\Omega} = \frac{\#\{4, 6\}}{6} = \frac{2}{6} = \frac{1}{3}$

8. Définition des probabilités (1)

Les probabilités peuvent être données sous la forme décimale ou en pourcentage car il n'y a pas de consigne spécifique.

(a) $P(E_1) = \frac{20}{50} = \frac{2}{5} = 0.4 = 40\%$,

$P(E_2) = \frac{13}{50} = 0.26 = 26\%$

$P(E_3) = \frac{17}{50} = 0.34 = 34\%$

(b) Nous avons utilisé la méthode empirique des probabilités pour donner les réponses au point (a) car les probabilités sont déterminées à l'issue de la répétition d'une même expérience aléatoire.

9. Définition des probabilités (2)

(a) $P(E_2) = \frac{1}{4}$ car les événements sont équiprobables par hypothèse et il y a 4 événements dans l'ensemble fondamental.

(b) D'abord, remarquons que les événements ont tous la probabilité $P(E_i) = 1/4$, pour $i = 1, 2, 3, 4$, puisqu'ils sont équiprobables par hypothèse et qu'il y a 4 événements dans l'ensemble fondamental. Les conditions de bases sont satisfaites car (1) pour $i = 1, 2, 3, 4$, $P(E_i) = 1/4$ est compris entre 0 et 1 ; (2) la somme de tous les résultats possibles est égal à 1, en effet : $\sum_{i=1}^4 P(E_i) = 1/4 + 1/4 + 1/4 + 1/4 = 1$.

(c) $P(E_1 \text{ ou } E_3) = P(E_1 \cup E_3) = P(E_1) + P(E_3) - P(E_1 \cap E_3) = \frac{1}{4} + \frac{1}{4} - 0 = \frac{1}{2}$

(d) Nous avons utilisé la méthode classique des probabilités puisque les événements sont équiprobables par hypothèse.

10. Définition des probabilités (3)

On peut d'abord remarquer que (1) toutes les valeurs attribuées sont comprises entre 0 et 1 donc la première condition d'attribution de probabilités est satisfaite.

Ensuite, (2) il faut que la somme de tous les résultats possibles est égal à 1. Nous avons : $\sum_{i=1}^4 P(E_i) = 0.1 + 0.15 + 0.4 + 0.2 = 0.85 \neq 1$. Le business analyst n'a donc pas attribué de probabilités. Les résultats qu'il déduira de ces valeurs seront donc faux.

11. Propriétés des probabilités

Pour cet exercice, nous utilisons les propriétés des probabilités.

(a) La règle du complémentaire :

$$\begin{aligned} P(\overline{A}) &= 1 - P(A) \\ &= 1 - 1/3, \text{ par hypothèse} \\ &= 2/3, \text{ par simplification} \end{aligned}$$

(b) La règle du complémentaire :

$$\begin{aligned} P(\overline{B}) &= 1 - P(B) \\ &= 1 - 1/2, \text{ par hypothèse} \\ &= 1/2, \text{ par simplification} \end{aligned}$$

(c) La règle du complémentaire :

$$\begin{aligned} P(\overline{A \cap B}) &= 1 - P(A \cap B) \\ &= 1 - 1/4, \text{ par hypothèse} \\ &= 3/4, \text{ par simplification} \end{aligned}$$

(d) La loi d'addition :

$$\begin{aligned} P(A \cup B) &= P(A) + P(B) - P(A \cap B) \\ &= 1/3 + 1/2 - 1/4, \text{ par hypothèse} \\ &= (4 + 6 - 3)/12, \text{ par mise au même dénominateur} \\ &= 7/12, \text{ par simplification} \end{aligned}$$

(e) La règle du complémentaire :

$$\begin{aligned}P(\overline{A \cup B}) &= 1 - P(A \cup B) \\&= 1 - 7/12, \text{ par l'exercice (d)} \\&= 5/12, \text{ par simplification}\end{aligned}$$

12. Propriétés des probabilités

Pour cet exercice, nous utilisons les propriétés des probabilités.

(a) La règle du complémentaire :

$$\begin{aligned}P(\overline{A}) &= 1 - P(A) \\&= 1 - 0.42, \text{ par hypothèse} \\&= 0.58, \text{ par simplification}\end{aligned}$$

(b) La règle du complémentaire :

$$\begin{aligned}P(\overline{B}) &= 1 - P(B) \\&= 1 - 0.65, \text{ par hypothèse} \\&= 0.35, \text{ par simplification}\end{aligned}$$

(c) La règle du complémentaire :

$$\begin{aligned}P(\overline{A \cup B}) &= 1 - P(A \cup B) \\&= 1 - 0.78, \text{ par hypothèse} \\&= 0.22, \text{ par simplification}\end{aligned}$$

(d) La loi d'addition :

$$\begin{aligned}P(A \cap B) &= P(A) + P(B) - P(A \cup B) \\&= 0.42 + 0.65 - 0.78, \text{ par hypothèse} \\&= 0.29, \text{ par simplification}\end{aligned}$$

(e) La règle du complémentaire :

$$\begin{aligned}P(\overline{A \cap B}) &= 1 - P(A \cap B) \\&= 1 - 0.29, \text{ par l'exercice (d)} \\&= 0.71, \text{ par simplification}\end{aligned}$$

13. Campagne marketing

- (a) $P(C) = 200/1000 = 20\%$
- (b) $P(\bar{A}) = 700/1000 = 70\%$
- (c) $P(C \cap A) = 120/1000 = 12\%$
- (d) $P(\bar{C} \cap A) = 180/1000 = 18\%$
- (e) $P(A|C) = 120/200 = 60\%$
- (f) $P(\bar{A}|C) = 80/200 = 40\%$
- (g) $P(A|\bar{C}) = 180/800 = 22.5\%$
- (h) Oui. Les clients qui ont cliqué achètent davantage que les autres : $P(A|C) = 60\%$ contre $P(A|\bar{C}) = 22.5\%$. Le clic semble donc être un indicateur pertinent d'une intention d'achat.
- (i) Oui. La probabilité d'achat d'un client pris au hasard est : $P(A) = 300/1000 = 30\%$ alors que $P(A|C) = 60\%$. Un client ayant cliqué est donc deux fois plus susceptible d'acheter qu'un client pris au hasard.

14. **Compétences et formation.** Si A et B sont indépendants, $P(A \cap B) = P(A) \times P(B)$. Donc $P(A \cap B) = 0.40 \times 0.65 = 0.26$. La probabilité qu'un employé suive une formation en analyse de données et parle couramment l'anglais est de 26 %.

15. Etude de marché sur la possession d'appareils numériques

Définissons des notations pour les événements de cette étude de marché :

- A : «la famille interrogée possède un ordinateur à écran tactile»
- B : «la famille interrogée possède un ordinateur à écran tactile et un smartphone»
- C : «la famille interrogée possède un ordinateur à écran tactile ou un smartphone»
- D : «la famille interrogée possède un smartphone»

- (a) On cherche $P(A)$. Puisque 140 familles observées possèdent un ordinateur à écran tactile sur un total de 400 familles observées :

$$P(A) = \frac{140}{400} = 0.35$$

- (b) On cherche $P(D)$. Puisque 300 familles observées possédaient un smartphone sur un total de 400 familles observées :

$$P(D) = \frac{300}{400} = 0.75$$

- (c) On cherche $P(B)$. Puisque 80 familles observées possédaient les deux types d'appareil sur un total de 400 familles observées :

$$P(B) = \frac{80}{400} = 0.2$$

- (d) On cherche $P(C)$. Les données ne nous permettent pas décrire directement la réponse. Mais observons que $C = A \cup D$ donc $P(C) = P(A \cup D)$ et par la loi d'addition, nous avons :

$$P(C) = P(A \cup D) = P(A) + P(D) - P(A \cap D)$$

- $P(A) = 0.35$, par (a)

- $P(D) = 0.75$, par (b)

- $P(A \cap D)$ est la probabilité d'avoir les 2 types d'appareil, donc $A \cap D = B$ et $P(B) = 0.2$ par (c).

En conclusion : $P(C) = 0.35 + 0.75 - 0.2 = 0.9$

16. Etude du nombre de steaks hachés vendus par hamburger

- (a) Calculs et interprétations.

- i. $P(X < 2) = P(X = 1) = 0.4$: la probabilité qu'un client au hasard commande un hamburger avec 1 steak haché est de 40%.
- ii. $P(X \leq 2) = P(X = 1) + P(X = 2) = 0.9$: la probabilité qu'un client au hasard commande un hamburger avec 1 ou 2 steaks hachés est de 90%.
- iii. $P(X < 1) = 0$: la probabilité qu'un client au hasard commande un hamburger sans steak haché est nulle.
- iv. $P(X < 2 \text{ ou } X > 2) = P(X = 1) + P(X = 3) = 0.5$: la probabilité qu'un client achète un hamburger avec strictement moins de 2 steaks hachés ou strictement plus de 2 steaks hachés est de 50%.

- (b) Distribution de la fonction de répartition de X .

X	$P(X = x)$	$F(X) = P(X \leq x)$
1	0.4	0.4
2	0.5	0.9
3	0.1	1

- (c) Espérance de X :

X	$P(X = x)$	$xP(X = x)$
1	0.4	0.4
2	0.5	1
3	0.1	0.3

$$E(X) = \sum xP(X = x) = 0.4 + 1 + 0.3 = 1.7$$

En moyenne, les clients commandent un hamburger avec 1.7 steaks hachés (environ 2 steaks hachés).

(d) Variance et écart-type de X .


X	$P(X = x)$	$(x - E(X))^2$	$(x - E(X))^2 P(X = x)$
1	0.4	0.49	0.196
2	0.5	0.09	0.045
3	0.1	1.69	0.169

$$\text{Variance : } \sigma_X^2 = \text{Var}(X) = \sum (x - E(X))^2 P(X = x) = 0.196 + 0.045 + 0.169 = 0.41$$

$$\text{Ecart-type : } \sigma_X = \sqrt{0.41} \approx 0.6403$$

17. Représentations graphiques d'une loi de probabilité


(a) Diagramme en bâtons :



(b) Distribution de la fonction de répartition de X :

$X = x$	$F(x) = P(X \leq x)$
0	0.0467
1	$0.0467 + 0.1866 = 0.2333$
2	$0.2333 + 0.3110 = 0.5443$
3	$0.5443 + 0.2765 = 0.8208$
4	$0.8208 + 0.1382 = 0.9590$
5	$0.9590 + 0.0369 = 0.9959$
6	$0.9959 + 0.0041 = 1$

(c) Représentation graphique de la fonction de répartition de X :



18. Densité de probabilité uniforme continue

$$(a) f(x) = \begin{cases} 2 & \text{si } 1 \leq x \leq 1.5 \\ 0 & \text{sinon} \end{cases}$$

$$(b) P(X = 1.25) = 0$$

$$(c) P(1 \leq X \leq 1.25) = 0.25 \times 2 = 0.5$$

$$(d) P(1.2 < X < 1.5) = 0.3 \times 2 = 0.6$$

19. Probabilité d'une loi normale centrée réduite grâce à sa table

$$(a) \Phi(1.93) = 0.9732, \text{ directement grâce à la table}$$

$$(b) \Phi(2.22) = 0.9868, \text{ directement grâce à la table}$$

(c) $-1.65 < 0$ et ne trouve donc pas dans la table. Nous devons utiliser les propriétés remarquables de la loi normale centrée réduite :

$$\begin{aligned} \Phi(-1.65) &= P(Z \geq 1.65) \text{ par symétrie de } \mathcal{N}(0, 1) \\ &= 1 - P(Z < 1.65) \text{ par la règle du complémentaire} \\ &= 1 - P(Z \leq 1.65) \text{ car } Z \text{ est une loi continue} \\ &= 1 - 0.9505 \text{ grâce à la table de } \mathcal{N}(0, 1) \\ &= 0.0495 \end{aligned}$$

$$(d) \Phi(-1) = 0.1587 \text{ (à développer comme au (c))}$$

$$(e) \Phi(-3.48) = 0.0003 \text{ (à développer comme au (c))}$$

- (f) $P(Z > -1) = 1 - P(Z \leq -1)$ par la règle du complémentaire et par (d), nous avons :
 $1 - P(Z \leq -1) = 0.8413$
- (g) $P(Z \geq -1) = 0.8413$ car Z est une loi continue et grâce à (f)
- (h) $P(Z > 0.5) = 0.3085$
- (i) Il faut écrire la problème sous la forme : $P(Z \leq 0.51) - P(Z < -1)$ et calculer les deux probabilités comme pour les exercices précédents. On trouve : $P(-1 \leq Z \leq 0.51) = 0.5363$
- (j) $P(0.24 < Z < 1.87) = 0.3745$

20. Quantiles d'une loi normale centrée réduite grâce à sa table

- (a) $z_{77.34\%} = 0.75$
- (b) $z_{95.73} = 1.72$
- (c) $z_{51.4\%} \simeq 0.035$
- (d) $z_{31.24\%} \simeq -0.49$
- (e) $z_{13.57} = -1.1$

21. Loi normale (1)

- (a) $Z = \frac{X-10}{0.4}$
- (b) $P(X \leq 12) = 1$
- (c) $P(X \leq 8) = 0$
- (d) $P(8 \leq X \leq 12) = 1$

22. Loi normale (2)

- (a) $X \sim \mathcal{N}(11, 10.24)$
- (b) $P(X \leq 13) = 0.7341$
- (c) $P(X \leq 10) = 0.3783$
- (d) $P(X \geq 12) = 0.3783$

23. Loi normale (3)

On cherche $P(2.53 \leq X < 7.98)$, où $X \sim \mathcal{N}(5; 8)$.

- Nous avons $Z = \frac{X-5}{\sqrt{8}} \sim \mathcal{N}(0; 1)$ où $\sqrt{8} = 2.8284$ et donc :

$$\begin{aligned} 2.53 \leq X < 7.98 &\Leftrightarrow \frac{2.53 - 5}{2.8284} \leq Z < \frac{7.98 - 5}{2.8284} \\ &\Leftrightarrow -0.87 \leq Z < 1.0536 \end{aligned}$$

- Par conséquent, $P(2.53 \leq X < 7.98) = P(-0.87 \leq Z < 1.0536)$.

24. **Loi normale (4)**

0.1862

25. **Loi normale (5)**

0.1075

26. **I.C. du revenu moyen des habitants d'une ville.**

Notations :

- μ : revenu moyen population, c'est un paramètre inconnu
- $\sigma = 2000$ (euros) est l'écart-type population, il est connu
- $n = 100$ est la taille de l'échantillon
- $\bar{X} = 7348$ est la moyenne-échantillon
- $\alpha = 0.05$ est le niveau de signification

Statistique :

Si la variance σ^2 est connue, alors $\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$ donc $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$ et par conséquent :

$$\begin{aligned} -z_{1-\frac{\alpha}{2}} \leq Z \leq z_{1-\frac{\alpha}{2}} &\Leftrightarrow -z_{1-\frac{\alpha}{2}} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq z_{1-\frac{\alpha}{2}} \\ &\Leftrightarrow -z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \leq \bar{X} - \mu \leq z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \\ &\Leftrightarrow -\bar{X} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \leq -\mu \leq -\bar{X} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \\ &\Leftrightarrow \bar{X} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \geq \mu \geq \bar{X} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \\ &\Leftrightarrow \bar{X} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \end{aligned}$$

où $z_{1-\alpha/2}$ est le quantile d'ordre $1 - \alpha/2$ de la loi normale centrée réduite.

Calculs :

L'intervalle de confiance au niveau de confiance $1 - \alpha = 1 - 0.05 = 0.95$ pour le paramètre μ est :

$$IC(\mu) = \left[7348 - z_{1-\frac{0.05}{2}} \frac{2000}{\sqrt{100}}; 7348 + z_{1-\frac{0.05}{2}} \frac{2000}{\sqrt{100}} \right]$$

et on trouve dans la table de la loi normale : $z_{1-\frac{0.05}{2}} = z_{0.975} = 1.96$ donc on obtient, au niveau de

confiance $1 - \alpha = 0.95$:

$$\begin{aligned} IC(\mu) &= \left[7348 - 1.96 \frac{2000}{\sqrt{100}}; 7348 + 1.96 \frac{2000}{\sqrt{100}} \right] \\ &= [6956; 7740] \end{aligned}$$

Conclusion (interprétation) : Dans 95% des cas, le revenu moyen des habitants de cette ville est entre 6956 euros et 7740 euros.

Remarque :

Si on prélève 1000 E.A.S. de 100 habitants, la moyenne des revenus sera différente d'un échantillon à l'autre. On obtiendra donc 1000 I.C. différents. Environ 95% de ces I.C. devraient contenir la vraie valeur inconnue μ .

Le paramètre μ de la population est et reste constant et inconnu. Ce sont les bornes de l'intervalle qui sont aléatoires car $\bar{X}$ est une v.a.

27. I.C. de la durée des achats dans un grand magasin

Notations :

- μ : durée moyenne population, c'est un paramètre inconnu
 - $\sigma^2 = 256$ (minutes) est la variance population, elle est connue et donc l'écart-type population est $\sigma = \sqrt{256} = 16$
 - $n = 64$ est la taille de l'échantillon
 - $\bar{X} = 33$ est la moyenne-échantillon

Statistique :

Si la variance σ^2 est connue, alors $\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$ donc $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$ et par conséquent :

$$-z_{1-\frac{\alpha}{2}} \leq Z \leq z_{1-\frac{\alpha}{2}} \Leftrightarrow \bar{X} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}$$

où $z_{1-\alpha/2}$ est le quantile d'ordre $1 - \alpha/2$ de la loi normale centrée réduite.

(a) $\alpha = 0.05$ est le niveau de signification

Calculs :

L'intervalle de confiance au niveau de confiance $1 - \alpha = 1 - 0.05 = 0.95$ pour le paramètre μ est :

$$IC(\mu) = \left[33 - z_{1-\frac{0.05}{2}} \frac{16}{\sqrt{64}}; 33 + z_{1-\frac{0.05}{2}} \frac{16}{\sqrt{64}} \right]$$

et on trouve dans la table de la loi normale : $z_{1-\frac{0.05}{2}} = z_{0.975} = 1.96$ donc on obtient, au niveau de confiance $1 - \alpha = 0.95$:

$$\begin{aligned} IC(\mu) &= \left[33 - 1.96 \frac{16}{\sqrt{64}}; 33 + 1.96 \frac{16}{\sqrt{64}} \right] \\ &= [29.08; 36.92] \end{aligned}$$

Conclusion (interprétation) : Dans 95% des cas, la durée moyenne des achats dans ce grand magasin est entre 29.08 minutes et 36.92 minutes.

(b) $\alpha = 0.01$ est le niveau de signification

Calculs :

L'intervalle de confiance au niveau de confiance $1 - \alpha = 1 - 0.01 = 0.99$ pour le paramètre μ est :

$$IC(\mu) = \left[33 - z_{1-\frac{0.01}{2}} \frac{16}{\sqrt{64}}; 33 + z_{1-\frac{0.01}{2}} \frac{16}{\sqrt{64}} \right]$$

et on trouve dans la table de la loi normale : $z_{1-\frac{0.01}{2}} = z_{0.995} = 2.58$ donc on obtient, au niveau de confiance $1 - \alpha = 0.99$:

$$\begin{aligned} IC(\mu) &= \left[33 - 2.58 \frac{16}{\sqrt{64}}; 33 + 2.58 \frac{16}{\sqrt{64}} \right] \\ &= [27.84; 38.16] \end{aligned}$$

Conclusion (interprétation) : Dans 99% des cas, la durée moyenne des achats dans ce grand magasin est entre 27.84 minutes et 38.16 minutes.

(c) Les deux intervalles sont centrés en $\bar{X}$. Le second intervalle est plus grand que le premier intervalle. Cela est logique puisque dans le 2ème cas, environ 99% des I.C. devraient contenir la vraie valeur inconnue μ , il faut donc couvrir plus de valeurs que dans le premier cas.

28. I.C. pour les notes en statistiques des étudiants

Notations :

- μ : durée moyenne population, c'est un paramètre inconnu
 - $n = 4$ est la taille de l'échantillon
 - $\bar{X}$ est la moyenne-échantillon (à calculer)
 - S' est l'écart-type-échantillon corrigé (à calculer)

Statistique :

Puisque la variance population est inconnue, nous devons utiliser la statistique :

$$T = \frac{\bar{X} - \mu}{S'/\sqrt{n}} \sim t_{n-1}$$

où t_{n-1} est une loi de Student à $(n - 1)$ degrés de liberté et S' est l'écart-type-échantillon corrigé. Par conséquent,

$$\begin{aligned} -t_{n-1;1-\frac{\alpha}{2}} &\leq T \leq t_{n-1;1-\frac{\alpha}{2}} \\ \Leftrightarrow -t_{n-1;1-\frac{\alpha}{2}} &\leq \frac{\bar{X} - \mu}{S'/\sqrt{n}} \leq t_{n-1;1-\frac{\alpha}{2}} \\ \Leftrightarrow -t_{n-1;1-\frac{\alpha}{2}} \frac{S'}{\sqrt{n}} &\leq \bar{X} - \mu \leq t_{n-1;1-\frac{\alpha}{2}} \frac{S'}{\sqrt{n}} \\ \Leftrightarrow -\bar{X} - t_{n-1;1-\frac{\alpha}{2}} \frac{S'}{\sqrt{n}} &\leq -\mu \leq -\bar{X} + t_{n-1;1-\frac{\alpha}{2}} \frac{S'}{\sqrt{n}} \\ \Leftrightarrow \bar{X} + t_{n-1;1-\frac{\alpha}{2}} \frac{S'}{\sqrt{n}} &\geq \mu \geq \bar{X} - t_{n-1;1-\frac{\alpha}{2}} \frac{S'}{\sqrt{n}} \\ \Leftrightarrow \bar{X} - t_{n-1;1-\frac{\alpha}{2}} \frac{S'}{\sqrt{n}} &\leq \mu \leq \bar{X} + t_{n-1;1-\frac{\alpha}{2}} \frac{S'}{\sqrt{n}} \end{aligned}$$

L'intervalle de confiance au niveau de confiance $1 - \alpha = 1 - 0.05$ pour le paramètre μ est :

$$IC(\mu) = \left[\bar{X} - t_{n-1;1-\frac{0.05}{2}} \frac{S'}{\sqrt{n}}; \bar{X} + t_{n-1;1-\frac{0.05}{2}} \frac{S'}{\sqrt{n}} \right]$$

Calculs :

La moyenne-échantillon est : $\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{64+66+89+77}{4} = 74$

La variance-échantillon est :

$$\begin{aligned} S'^2 &= \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \\ &= \frac{1}{3} ((64 - 74)^2 + (66 - 74)^2 + (89 - 74)^2 + (77 - 74)^2) \\ &= 132.7 \end{aligned}$$

L'intervalle de confiance au niveau de confiance $1 - \alpha = 1 - 0.05 = 0.95$ pour le paramètre μ est :

$$IC(\mu) = \left[74 - t_{3;1-\frac{0.05}{2}} \frac{\sqrt{132.7}}{\sqrt{4}}; 74 + t_{3;1-\frac{0.05}{2}} \frac{\sqrt{132.7}}{\sqrt{4}} \right]$$

On trouve dans la table de la loi de Student : $t_{3;1-\frac{0.05}{2}} = t_{3;0.975} = 3.182$. Ainsi, au niveau de confiance $1 - \alpha = 1 - 0.05 = 0.95$:

$$IC(\mu) = \left[74 - 3.182 \frac{\sqrt{132.7}}{\sqrt{4}}; 74 + 3.182 \frac{\sqrt{132.7}}{\sqrt{4}} \right] \\ = [55.67; 92.33]$$

Conclusion (interprétation) : Dans 95% des cas, la note moyenne en statistique des étudiants de cette classe est entre 55.67 et 92.33 sur 100.

29. I.C. pour la taille des hommes en Belgique

Notations :

- μ : taille moyenne population, c'est un paramètre inconnu
 - $n = 50$ est la taille de l'échantillon, remarquons que $n \geq 50$.
 - $\bar{X} = 168$ cm est la moyenne-échantillon
 - $S' = 8.2$ cm est l'écart-type-échantillon corrigé

Statistique :

n est grand ($n \geq 30$) et il s'agit d'une population quelconque où la variance population est inconnue donc $\frac{\bar{X}-\mu}{S'/\sqrt{n}} \approx \mathcal{N}(0, 1)$ et donc l'intervalle de confiance au niveau de confiance $1 - \alpha$ pour le paramètre μ :

$$IC(\mu) \approx \left[\bar{X} - z_{1-\frac{\alpha}{2}} \frac{S'}{\sqrt{n}}; \bar{X} + z_{1-\frac{\alpha}{2}} \frac{S'}{\sqrt{n}} \right]$$

où $z_{1-\alpha/2}$ est le quantile d'ordre $1 - \alpha/2$ de la loi normale centrée réduite.

Calculs :

L'intervalle de confiance au niveau de confiance $1 - \alpha = 1 - 0.05 = 0.95$ pour le paramètre μ est :

$$IC(\mu) = \left[168 - z_{1-\frac{0.05}{2}} \frac{8.2}{\sqrt{50}}; 168 + z_{1-\frac{0.05}{2}} \frac{8.2}{\sqrt{50}} \right]$$

et on trouve dans la table de la loi normale : $z_{1-\frac{0.05}{2}} = z_{0.975} = 1.96$ donc on obtient, au niveau de confiance $1 - \alpha = 0.95$:

$$IC(\mu) = \left[168 - 1.96 \frac{8.2}{\sqrt{50}}; 168 + 1.96 \frac{8.2}{\sqrt{50}} \right] \\ = [165.36 : 170.27]$$

Conclusion (interprétation) : Dans 95% des cas, la taille moyenne des hommes adultes en Belgique est entre 165.35 cm et 170.27 cm.

30. Poids des alevins d'une population

Notations :

- μ : taille moyenne population, c'est un paramètre inconnu
 - $n = 45$ est la taille de l'échantillon, remarquons que $n \geq 30$.
 - $\bar{X} = 8.24$ cm est la moyenne-échantillon
 - $S' = 3$ gr est l'écart-type-échantillon corrigé
- (a) Statistique : n est grand ($n = 45 \geq 30$) et il s'agit d'une population quelconque où la variance population est inconnue donc $\frac{\bar{X}-\mu}{S'/\sqrt{n}} \approx \mathcal{N}(0, 1)$ et donc l'intervalle de confiance au niveau de confiance $1 - \alpha$ pour le paramètre μ :

$$IC(\mu) \approx \left[\bar{X} - z_{1-\frac{\alpha}{2}} \frac{S'}{\sqrt{n}}; \bar{X} + z_{1-\frac{\alpha}{2}} \frac{S'}{\sqrt{n}} \right]$$

Calculs :

L'intervalle de confiance, au niveau de confiance $1 - \alpha = 1 - 0.05 = 0.95$ pour le paramètre μ est :

$$\begin{aligned} IC(\mu) &= \left[8.24 - 1.96 \frac{3}{\sqrt{45}}; 8.24 + 1.96 \frac{3}{\sqrt{45}} \right] \\ &= [7.65 : 9.12] \end{aligned}$$

Conclusion (interprétation) : Dans 95% des cas, la poids moyen des alevins de cette population se situe entre 7.65gr et 9.12gr.

- (b) L'amplitude de l'intervalle est de maximum 1 gr si $2z_{1-\frac{\alpha}{2}} \frac{S'}{\sqrt{n}} \leq 1$ où n est la taille de l'échantillon.

Calculs :

Résolution de l'équation, niveau de signification $\alpha = 5\%$:

$$\begin{aligned} 2z_{1-\frac{\alpha}{2}} \frac{S'}{\sqrt{n}} &\leq 1 \Leftrightarrow 2 \times 1.96 \frac{3}{\sqrt{n}} \leq 1 \\ &\Leftrightarrow 2 \times 1.96 \frac{3}{\sqrt{n}} \leq 1 \\ &\Leftrightarrow 2 \times 1.96 \times 3 \leq \sqrt{n} \\ &\Leftrightarrow (2 \times 1.96 \times 3)^2 \leq n \\ &\Leftrightarrow 139 \leq n \end{aligned}$$

Conclusion (interprétation) : Au niveau de signification $\alpha = 5\%$, il faut observer au moins 139 alevins pour que le poids moyen des alevins soit déterminé avec une amplitude de 1gr au maximum.

31. Le problème de test $H_0 : \mu = 20 \leftrightarrow H_1 : \mu < 20$

(a) $z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} = \frac{19.4 - 20}{2/\sqrt{50}} = -2.1213$

(b) Il s'agit d'un test unilatéral à gauche donc p-valeur = $P(Z < -2.1213) = P(Z > 2.1213) = 1 - P(Z \leq 2.1213) = 1 - 0.9830 = 0.0170$

(c) La règle de rejet est : on rejette H_0 si p-valeur $< \alpha$. Nous avons p-valeur = 0.017 et $\alpha = 0.05$. Comme $0.017 < 0.05$, on rejette H_0 .

Conclusion : dans ce problème, la moyenne est inférieure à 20, avec un risque de se tromper de 1.7%.

32. Concession automobile

(a) Test d'hypothèse : $H_0 : \mu = 14 \leftrightarrow H_1 : \mu > 14$

(b) Il n'y a pas de preuve que le nouveau plan augmente les ventes.

(c) L'hypothèse $\mu > 14$ est soutenue : la nouveau plan permettrait d'augmenter les ventes.

33. Etiquette de jus d'orange

(a) Test d'hypothèse : $H_0 : \mu \leq 1 \leftrightarrow H_1 : \mu > 1$

Remarque : nous avons écrit $\mu \leq 1$ pour l'hypothèse nulle car il semble plus approprié vu le contexte plutôt qu'écrire $\mu = 1$, pour ce test statistique.

(b) Affirmer que $\mu > 1$, alors que c'est faux.

(c) Affirmer que $\mu \leq 1$, alors que c'est faux.

34. Nouvelle méthode de production

(a) Test d'hypothèse : $H_0 : \mu = 220 \leftrightarrow H_1 : \mu < 220$

(b) Affirmer que $\mu < 220$, alors que c'est faux.

(c) Affirmer que $\mu = 220$, alors que c'est faux.

35. Budget pour les vacances d'été

- Données, inconnues et notations : $n = 45$ est la taille de l'échantillon, remarquons que $n \geq 30$.

- $\bar{X} = \frac{1}{45} \sum_{i=1}^{45} x_i = 90639 = 2014.2$ est la moyenne-échantillon (budget vacances d'été 2020)
 $S^2 = \frac{1}{45} \sum_{i=1}^{45} x_i^2 - \bar{X}^2 = \frac{209949834.9}{45} - (2014.2)^2 = 608550.2467$ est la variance échantillon
- $(S')^2 = \frac{n}{n-1} S^2 = \frac{45}{44} 608550.246 = 622380.9341$ est la variance corrigée échantillon
- $S' = \sqrt{622380.9341} = 788.9112$ est l'écart-type corrigé échantillon
- Inconnues : μ : budget moyen que les belges comptent dépenser pour leurs vacances d'été 2020 et σ : écart-type population

(a) Le budget moyen des Belges pour les vacances d'été 2020 est inférieur à celui de l'été 2019 ?

- **Test d'hypothèse** : $H_0 : \mu = 2238 \leftrightarrow H_1 : \mu < 2238$
- **Loi de la statistique de test sous H_0** : Puisque $n > 30$ (grands échantillon), $Z_{obs} = \frac{\bar{X}-2238}{S'/\sqrt{n}} \sim \mathcal{N}(0, 1)$, (où Z_{obs} , désigne la statistique observée)
- **Règle de rejet** : on rejette H_0 si $Z_{obs} < z_\alpha$, où z_α est la quantile d'ordre α de la loi normale centrée réduite.
- **Décision.**

Calculs : la statistique de test est $Z = \frac{\bar{X}-2238}{S'/\sqrt{n}} = \frac{2014.2-2238}{788.9112/\sqrt{45}} = -1.9030$ et $z_\alpha = -z_{1-\alpha} = -z_{95} = -1.645$.

Comme $Z = -1.9030 < -1.645$, on rejette H_0 .

Conclusion : on peut affirmer, avec un risque de se tromper de 5%, que le budget moyen des Belges pour les vacances d'été 2020 est inférieur à celui de l'été 2019 c'est-à-dire inférieur à 2238 euros.

(b) Puisque $n > 30$ (grands échantillon), $Z_{obs} = \frac{\bar{X}-2238}{S'/\sqrt{n}} \sim \mathcal{N}(0, 1)$, (où Z_{obs} , désigne la statistique observée) et on peut construire (voir slides) l'intervalle de confiance, au niveau de confiance α ,

$$IC(\mu) = \left[\bar{X} - \frac{S'}{\sqrt{n}} z_{\alpha/2}; \bar{X} + \frac{S'}{\sqrt{n}} z_{1-\alpha/2} \right]$$

où $z_{\alpha/2}$ est la quantile d'ordre $\alpha/2$ de la loi normale centrée réduite, et $z_{1-\alpha/2}$ est la quantile d'ordre $1 - \alpha/2$ de la loi normale centrée réduite. Par symétrie de cette loi : $z_{\alpha/2} = -z_{1-\alpha/2}$.

Calculs : $z_{1-\alpha/2} = z_{97.5\%} = 1.96$ et $z_{\alpha/2} = -1.96$ donc, au niveau de confiance 0.95,

$$\begin{aligned} IC(\mu) &= \left[2014.2 - \frac{788.9112}{\sqrt{45}} 1.96; 2014.2 + \frac{788.9112}{\sqrt{45}} 1.96 \right] \\ &= [1783.6963; 2244.7037] \end{aligned}$$

Conclusion : Dans 95% des cas, le budget moyen des Belges pour les vacances d'été 2020 est entre 1783.6963 euros et 2244.7037 euros.

36. **Le problème de test** $H_0 : p = 0.75 \leftrightarrow H_1 : p < 0.75$

- Données : $n = 300$ (taille de l'échantillon)

- Statistique de test :

$$z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} \sim \mathcal{N}(0, 1)$$

où p_0 désigne la valeur hypothétique. Donc, sous H_0 , on obtient $z = \frac{\hat{p} - 0.75}{\sqrt{\frac{0.75(1-0.75)}{300}}}$

- Règle de rejet (méthode de la p-valeur) : on rejette H_0 si p-valeur $\leq \alpha$

(a) Si $\hat{p} = 0.68$, alors $z = \frac{0.68 - 0.75}{\sqrt{\frac{0.75(1-0.75)}{300}}} = -2.8$. La p-valeur $= P(Z \leq -2.8) = P(Z \geq 2.8) = 1 - P(Z < 2.8) = 1 - 0.9974 = 0.0026$. Par conséquent, $0.0026 \leq 0.05$.

Conclusion : on rejette H_0 .

(b) Si $\hat{p} = 0.72$, alors $z = \frac{0.72 - 0.75}{\sqrt{\frac{0.75(1-0.75)}{300}}} = -1.2$. La p-valeur $= P(Z \leq -1.2) = P(Z \geq 1.2) = 1 - P(Z < 1.2) = 1 - 0.8849 = 0.1151$. Par conséquent, $0.1151 \geq 0.05$.

Conclusion : on ne rejette pas H_0 .

(c) Si $\hat{p} = 0.7$, alors $z = \frac{0.7 - 0.75}{\sqrt{\frac{0.75(1-0.75)}{300}}} = -2$. La p-valeur $= P(Z \leq -2) = P(Z \geq 2) = 1 - P(Z < 2) = 1 - 0.9772 = 0.0228$. Par conséquent, $0.0228 \leq 0.05$.

Conclusion : on rejette H_0 .

(d) Si $\hat{p} = 0.77$, alors $z = \frac{0.77 - 0.75}{\sqrt{\frac{0.75(1-0.75)}{300}}} = 0.8$. La p-valeur $= P(Z \leq 0.8) = 0.7881$. Par conséquent, $0.7881 \geq 0.05$.

Conclusion : on ne rejette pas H_0 .

37. **Marques de ketchup**

(a) $H_0 : p = 0.64 \leftrightarrow H_1 : p \neq 0.64$

(b) - Statistique de test :

$$z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} \sim \mathcal{N}(0, 1)$$

où p_0 désigne la valeur hypothétique, $n = 100$ est la taille de l'échantillon et $\hat{p} = 52/100 = 0.52$ est l'estimation ponctuelle de la proportion.

- Règle de rejet (méthode de la p-valeur) : on rejette H_0 si p-valeur $\leq \alpha$

- Calculs : Sous H_0 , on obtient

$$z = \frac{0.52 - 0.64}{\sqrt{\frac{0.64(1-0.64)}{100}}} = -2.5$$

Comme $z = -2.5$ est négatif et que nous sommes dans le cadre d'un test bilatéral, p-valeur $= 2P(Z < -2.5) = 2P(Z > 2.5) = 2(1 - P(Z < 2.5)) = 2(1 - 0.9938) = 0.0124$

- (c) Comme p-valeur $= 0.0124 \leq \alpha = 0.05$, on rejette H_0 .

Conclusion : La proportion de consommateurs qui trouvent que le ketchup de la marque distributeur est aussi bonne que le ketchup de la marque connue, est différente de 64%, avec un risque de se tromper de 1.24%.

- (d) Oui, puisque les acheteurs interrogés sont 52% à penser que le ketchup de la marque distributeur est aussi bonne que le ketchup de la marque connue, donc une proportion de consommateurs inférieure au 64% de consommateurs annoncés par le groupe d'analystes.

38. Conséquences des publicités sur l'audience d'une nouvelle émission de divertissement

- (a) $\hat{p} = 414/1532 = 0.2702 = 27.02\%$

- (b) - Test d'hypothèse : $H_0 : p = 0.22 \leftrightarrow H_1 : p > 0.22$

- Statistique de test :

$$z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} \sim \mathcal{N}(0, 1)$$

où p_0 désigne la valeur hypothétique

- Règle de rejet (méthode de la p-valeur) : on rejette H_0 si p-valeur $\leq \alpha$

- Calculs : Sous H_0 , on obtient

$$z = \frac{0.2702 - 0.22}{\sqrt{\frac{0.22(1-0.22)}{1532}}} = 4.7432$$

Comme il s'agit d'un test unilatéral à droite, p-valeur $= P(Z > 4.7432) \simeq 0$.

Comme p-valeur $\simeq 0 \leq \alpha = 0.05$, on rejette H_0 .

Conclusion : Il y a une augmentation significative du nombre de téléspectateurs qui envisagent de regarder la nouvelle émission de divertissement après la diffusion des publicités pour ce programme.

- (c) Cette analyse permet d'évaluer l'efficacité des publicités.