









STRUCTURE DE DONNEES


Luleta Shabani

Cours 1

21/09/2026












HELLO THERE!

Quelques mots sur mon parcours

Email: luleta.shabani@gmail.com

UN PEU SUR MOI





PARLONS DE VOUS




PROPOSITION DE CONTRAT




- Une seule personne qui parle à la fois
- On rentre en cours à l'heure ou à la pause
- Feedback: si je ne sais pas quelque chose, je ne peux pas l'améliorer
- On construit le cours ensemble
- On ne parle pas de l'examen : il y aura un moment spécial pour ça
- Je n'aurai pas les réponses à toutes les questions
- « La répétition est la mère du savoir »
- Si vous le souhaitez, vous pouvez me tutoyer

OBJECTIFS DU COURS




Termes

- Vous familiariser avec certaines termes et concepts
→ utile pour vos stages



Méthodologies

- S'entraîner à poser des questions
- Définir des métriques et des KPI
- Nettoyer et modéliser des données
- Analyser et présenter des données



Découverte

- Vous donner envie d'explorer certains sujets plus en détail

Plan du cours

Le cours sera divisé en 3 parties :

1) Comprendre le business

Poser des questions business – Poser des questions data – Définir des métriques et des KPIs
– Choisir des KPIs critiques

2) Structure et modéliser

Nettoyer des données – Créer un modèle relationnel (normalisé) – Créer un schéma en étoile (dénormalisé) – Introduction SQL et Excel – Formats JSON et XML - NoSQL

3) Analyser, présenter ET convaincre

Faire ressortir ce qui compte - Raconter des histoires avec des données





AUJOURD'HUI

Introduction

Nettoyer des données

Modèle Entité/Association

Cardinalités







AUJOURD'HUI



Introduction

Nettoyer des données



Modèle Entité/Association

Cardinalités





**Pourquoi on a des données dans
une entreprise ?**



Quels métiers data connaissez-vous ?

Métiers Data




Phuong Nguyen Aug 19

Confondre data analyst, data engineer et data scientist, c'est comme confondre un architecte, un maçon et un décorateur.

Même mission : créer de la valeur.


Mais pas le même métier.





Phuong Nguyen
@phuongnguyen

Source: [Phuong Nguyen](#)

Types d'analyses de données





**Pourquoi il est important de « nettoyer »
les données avant de les analyser ?**





AUJOURD'HUI

Introduction

Nettoyer des données

Modèle Entité/Association

Cardinalités



Nettoyer des données

Framework CLEAN

C L E A N

C = Comprendre les données

L = Localiser les problèmes solubles

E = Evaluer l'ampleur des problèmes insolubles

A = Augmenter la qualité des données

N = Noter et documenter


Nettoyer des données

 Comment savoir quand mes données sont parfaites ?

- ➔ Quand vous nettoyez des données, vous ne visez pas des données 100% parfaites (on verra pourquoi)
- ➔ Visez des données suffisamment fiables pour être analysées, partagées et sur lesquelles itérer.



C = Comprendre les données



Nettoyer des données



C = Comprendre les données

➔ Avant de plonger dans le nettoyage, vous allez commencer par vous demander :

- Qu'est-ce que je regarde ?
- A quelles questions business et data je peux répondre grâce à ces données ?
- Quelle histoire ces données peuvent m'aider à raconter ?

L'objectif est de comprendre les données et ce qu'elles représentent.

Le fichier que j'utilise comme exemple est disponible sur Moodle (dossier LABO 1).

Nettoyer des données



C = Comprendre les données

Dans cette étape, votre objectif sera de répondre aux 3 questions suivantes :

- Que représente chaque ligne ? (granularité des données)
- Quelles sont les métriques clés ? (ce que vos données mesurent -> quantifiable)
- Quelles sont les dimensions clés ? (ce que vos données décrivent -> aspect qualitatif)

Une autre manière d'appeler les lignes et les colonnes ? → entités et attributs (on verra ça plus tard)

Nettoyer des données



C = Comprendre les données

Ici on va explorer un fichier avec 2 onglets : orders et regions.

Si c'était une base de données, on aurait appelé ça 2 tables.

Nettoyer des données



C = Comprendre les données

Ici, dans l'onglet orders, on voit que chaque ligne représente un ordre unique, chaque ordre est identifié avec un ID

	A	B	C	D	E	F	G	H	I	J	K
1	USER_ID	ORDER_ID	PURCHASE_TS	SHIP_TS	PRODUCT_NAME	PRODUCT_ID	USD_PRICE	PURCHASE_PLATFORM	MARKETING_CHANNEL	ACCOUNT_CREATION_METHOD	COUNTRY_CODE
2	2c06175e	0001328c3c220830	24/12/2020	26/12/2020	Nintendo Switch	e682	168	website	affiliate	unknown	US
3	ee8e5bc2	0002af7a5c6100772	01/10/2020	03/10/2020	Nintendo Switch	e682	160,61	website	direct	desktop	DE
4	9eb4efe0	0002b8350e167074	21/04/2020	26/04/2020	Nintendo Switch	8d0d	151,2	website	direct	desktop	US
5	cac7cbaf	0006d06b98385729	07/04/2020	09/04/2020	Sony PlayStation 5 Bundle	54ed	1132,82	website	direct	desktop	AU
6	6b0230bc	00097279a2f46150	24/11/2020	27/11/2020	Nintendo Switch	8d0d	33,89	website	direct	desktop	TR
7	046e7528	000f169e17f4941	20/08/2020	24/08/2020	Nintendo Switch	8d0d	168	website	direct	desktop	PH
8	94dfec76	000fdd9bfe463101	11/05/2020	14/05/2020	27in 4K gaming monitor	891b	390,59	website	direct	desktop	GB
9	8a328a1d	0010d31e3c058676	03/07/2020	07/07/2020	27in 4K gaming monitor	891b	480	website	direct	desktop	BR
10	46c57b58	0013ac51a8831707	24/03/2019	28/03/2019	JBL Quantum 100 Gaming H	ab0f	22,22	website	direct	desktop	BE
11	a2eaa1d1	001620ea42468912	01/11/2019	07/11/2019	Nintendo Switch	e682	168	website	direct	desktop	US
12	c7c492f8	0016654fc8584512	09/12/2019	11/12/2019	Nintendo Switch	8d0d	150,53	website	direct	desktop	FR
13	d71c06c6	00236994a0b90874	30/08/2019	03/09/2019	Nintendo Switch	8d0d	146,25	website	direct	desktop	KR
14	9933b602	002a0b04dd764807	16/02/2020	18/02/2020	Sony PlayStation 5 Bundle	54ed	1725,86	website	direct	desktop	US
15	bbbaa7ff	002f0b22bb379479	14/05/2020	20/05/2020	Nintendo Switch	e682	168	website	direct	desktop	US
16	68673786	003ed9bd3d71799	26/10/2020	29/10/2020	Nintendo Switch	8d0d	134,41	website	direct	desktop	ES
17	1802f1a0	004602d9c2d12771	13/10/2020	17/10/2020	Sony PlayStation 5 Bundle	54ed	1368,45	website	direct	desktop	AU

Nettoyer des données



C = Comprendre

Si on regarde la ligne 2, on voit :

- que l'utilisateur a passé une commande le 24 décembre 2020, qu'elle a été expédiée 2 jours plus tard.
- Qu'il a commandé une Nintendo Switch qui a un code produit.
- Que ça lui a coûté 168 dollars.
- Qu'il/elle a commandé via le site et qu'il est venu via une affiliation.
- Que sa méthode de création de son compte est inconnue.
- Que son pays est l'US.

	A	B	C	D	E	F	G	H	I	J	K
1	USER_ID	ORDER_ID	PURCHASE_TS	SHIP_TS	PRODUCT_NAME	PRODUCT_ID	USD_PRICE	PURCHASE_PLATFORM	MARKETING_CHANNEL	ACCOUNT_CREATION_METHOD	COUNTRY_CODE
2	2c06175e	0001328c3c220830	24/12/2020	26/12/2020	Nintendo Switch	e682	168	website	affiliate	unknown	US
3	ee8e5bc2	0002af7a5c6100772	01/10/2020	03/10/2020	Nintendo Switch	e682	160,61	website	direct	desktop	DE
4	9eb4efe0	0002b8350e167074	21/04/2020	26/04/2020	Nintendo Switch	8d0d	151,2	website	direct	desktop	US
5	cac7cbaf	0006d06b98385729	07/04/2020	09/04/2020	Sony PlayStation 5 Bundle	54ed	1132,82	website	direct	desktop	AU
6	6b0230bc	00097279a2f46150	24/11/2020	27/11/2020	Nintendo Switch	8d0d	33,89	website	direct	desktop	TR
7	046e7528	000f169e17f4941	20/08/2020	24/08/2020	Nintendo Switch	8d0d	168	website	direct	desktop	PH
8	94dfec76	000fdd9bfe463101	11/05/2020	14/05/2020	27in 4K gaming monitor	891b	390,59	website	direct	desktop	GB
9	8a328a1d	0010d31e3c058676	03/07/2020	07/07/2020	27in 4K gaming monitor	891b	480	website	direct	desktop	BR
10	46c57b58	0013ac51a8831707	24/03/2019	28/03/2019	JBL Quantum 100 Gaming Headset	ab0f	22,22	website	direct	desktop	BE
11	a2eaa1d1	001620ea42468912	01/11/2019	07/11/2019	Nintendo Switch	e682	168	website	direct	desktop	US
12	c7c492f8	0016654fc8584512	09/12/2019	11/12/2019	Nintendo Switch	8d0d	150,53	website	direct	desktop	FR
13	d71c06c6	00236994a0b90874	30/08/2019	03/09/2019	Nintendo Switch	8d0d	146,25	website	direct	desktop	KR
14	9933b602	002a0b04dd764807	16/02/2020	18/02/2020	Sony PlayStation 5 Bundle	54ed	1725,86	website	direct	desktop	US
15	bbbbaa7ff	002f0b22bb379479	14/05/2020	20/05/2020	Nintendo Switch	e682	168	website	direct	desktop	US
16	68673786	003ed9bd3d71799	26/10/2020	29/10/2020	Nintendo Switch	8d0d	134,41	website	direct	desktop	ES
17	1802f1a0	004602d9c2d12771	13/10/2020	17/10/2020	Sony PlayStation 5 Bundle	54ed	1368,45	website	direct	desktop	AU

Nettoyer des données



C = Comprendre les données

Si on revient à nos 3 questions :

- Que représente chaque ligne ?
- Quelles sont les métriques clés ?
- Quelles sont les dimensions clés ?

Nettoyer des données



C = Comprendre les données

Si on revient à nos 3 questions :

- Que représente chaque **ligne** ? → un ordre unique
- Quelles sont **les métriques clés** ? → USD_PRICE
- Quelles sont **les dimensions** ? → dimensions par rapport au temps (PURCHASE_TS, SHIP_TS), le produit (PRODUCT_NAME), la plateforme d'achat (PURCHASE_PLATFORM), le canal marketing (MARKETING_CHANNEL), la méthode de création de compte (ACCOUNT_CREATION_METHOD) et le code pays (COUNTRY_CODE)
- Pour la partie **clés**, cela dépendra de ce que voulez tirer de ces données (questions data)

Nettoyer des données



C = Comprendre les données

Justement : En regardant ces données, quelles questions data vous pouvez poser ?

	A	B	C	D	E	F	G	H	I	J	K
1	USER_ID	ORDER_ID	PURCHASE_TS	SHIP_TS	PRODUCT_NAME	PRODUCT_ID	USD_PRICE	PURCHASE_PLATFORM	MARKETING_CHANNEL	ACCOUNT_CREATION_METHOD	COUNTRY_CODE
2	2c06175e	0001328c3c220830	24/12/2020	26/12/2020	Nintendo Switch	e682	168	website	affiliate	unknown	US
3	ee8e5bc2	0002af7a5c6100772	01/10/2020	03/10/2020	Nintendo Switch	e682	160,61	website	direct	desktop	DE
4	9eb4efe0	0002b8350e167074	21/04/2020	26/04/2020	Nintendo Switch	8d0d	151,2	website	direct	desktop	US
5	cac7cbaf	0006d06b98385729	07/04/2020	09/04/2020	Sony PlayStation 5 Bundle	54ed	1132,82	website	direct	desktop	AU
6	6b0230bc	00097279a2f46150	24/11/2020	27/11/2020	Nintendo Switch	8d0d	33,89	website	direct	desktop	TR
7	046e7528	000f169e17f4941	20/08/2020	24/08/2020	Nintendo Switch	8d0d	168	website	direct	desktop	PH
8	94dfec76	000fdd9bfe463101	11/05/2020	14/05/2020	27in 4K gaming monitor	891b	390,59	website	direct	desktop	GB
9	8a328a1d	0010d31e3c058676	03/07/2020	07/07/2020	27in 4K gaming monitor	891b	480	website	direct	desktop	BR
10	46c57b58	0013ac51a8831707	24/03/2019	28/03/2019	JBL Quantum 100 Gaming H	ab0f	22,22	website	direct	desktop	BE
11	a2eaa1d1	001620ea42468912	01/11/2019	07/11/2019	Nintendo Switch	e682	168	website	direct	desktop	US
12	c7c492f8	0016654fc8584512	09/12/2019	11/12/2019	Nintendo Switch	8d0d	150,53	website	direct	desktop	FR
13	d71c06c6	00236994a0b90874	30/08/2019	03/09/2019	Nintendo Switch	8d0d	146,25	website	direct	desktop	KR
14	9933b602	002a0b04dd764807	16/02/2020	18/02/2020	Sony PlayStation 5 Bundle	54ed	1725,86	website	direct	desktop	US
15	bbbaa7ff	002f0b22bb379479	14/05/2020	20/05/2020	Nintendo Switch	e682	168	website	direct	desktop	US
16	68673786	003ed9bd3d71799	26/10/2020	29/10/2020	Nintendo Switch	8d0d	134,41	website	direct	desktop	ES
17	1802f1a0	004602d9c2d12771	13/10/2020	17/10/2020	Sony PlayStation 5 Bundle	54ed	1368,45	website	direct	desktop	AU

Nettoyer des données



C = Comprendre les données

Cette première partie du processus sert à :

- **identifier ce dont vous devez réellement vous soucier** et
- **savoir quoi prioriser** dans votre processus de nettoyage de données

C'est encore mieux si vous connaissez déjà les questions business et data auxquelles vous voulez répondre



➔ Cela vous permettra de vous concentrer que sur les parties des données dont vous avez besoin

Exemple : Vous voulez savoir quelles sont **les tendances de ventes dans les différentes régions.**

Alors, vous allez vouloir vous concentrer sur le prix en tant que métrique clé et sur des dimensions autour de la géographie (en tout cas dans un premier temps).



**L = Localiser les problèmes
solubles**



Nettoyer des données



L = Localiser les problèmes solubles

L'étape suivante du nettoyage des données consiste **à identifier et à traiter les problèmes solubles**.

Exemples de problèmes solubles :

- ☐ incohérences dans les formats de données
- ☐ incohérences dans l'orthographe ou les catégorisations
- ☐ des valeurs de type « null » (= l'absence de données) → parfois soluble, parfois pas
- ☐ des doublons

➔ Les problèmes résolubles sont des problèmes liés aux données que **vous pouvez résoudre vous-mêmes, sans avoir à consulter une partie prenante** du business pour obtenir du contexte plus approfondi.

Nettoyer des données



L = Localiser les problèmes solubles

Comment s'y prendre :

- 1) **Dupliquez** l'onglet original et renommez-le (ex : orders_cleaned; clients_nettoyé)
- 2) Scrollez dans les données pour détecter **des premiers problèmes évidents**
- 3) **Filtrez** pour vérifier **les valeurs distinctes pour chaque colonne**
- 4) Pour chaque colonne examinée, **documentez dans un onglet dédié aux problèmes** (issues log)
- 5) Pour chaque colonne où il y a des problèmes, notez **le nombre de lignes impactées**, **le %** des lignes totales que cela représente, si le problème est **directement soluble** ou pas et **le type de résolution**
- 6) Si vous commencez à 'nettoyer' des colonnes, **créez une colonne supplémentaire** à droite de la colonne originale (ex: Product_name_cleaned) pour garder une trace de l'original et mettre en place des solutions long terme

Nettoyer des données

L = Localiser les problèmes solubles

Exemples :

Si toutes vos données suivent **un certain format** (ici le USER_ID est un mix entre des chiffres et des lettres, un USER_ID contenant uniquement des chiffres saute aux yeux.

Le nombre de caractères peut aussi compter (ex: si tous les id font 8 caractères et un qui en fait 3 => ce n'est pas forcément une erreur mais ça mérite d'être noté)



USER_ID
2c06175e
ee8e5bc2
9eb4efe0
cac7cbaf
6b0230bc
046e7528
94dfec76
8a328a1d
46c57b58
a2eaa1d1
c7c492f8
d71c06c6
9933b602
bbbaa7ff
68673786
1802f1a0
2abdb1d2


Nettoyer des données



L = Localiser les problèmes solubles

Exemples :

Pour les product_name, on va regarder s'il y a des produits qui semblent être similaires mais écrits différemment, en 2 ou plusieurs variantes.



Nettoyer des données



L = Localiser les problèmes solubles


Exemples :

Pour les dates, on va regarder s'il y a pas des formats différents (date vs timestamp),

ou bien **des valeurs manquantes**.

La valeur manquante n'est pas toujours un problème (importance contexte)

Mais pour une date d'achat, on s'attend à ce qu'elle soit présente.



Nettoyer des données


L = Localiser les problèmes solubles

Exemples :

Pour les métriques comme le prix, **une valeur manquante ou égale à zéro** est à signaler (peut-être pas une erreur mais on le note).

De manière générale, que ce soit pour les métriques ou les dimensions, on va se demander quelles sont les valeurs attendues.

Ex: Si c'est un resto qui sert que des pizzas traditionnelles, ça serait bizarre de voir une valeur de plat = sushi.



A magnifying glass icon with a dark blue frame and an orange handle, set against a light blue background.

Exemples :

En plus on remarque que dès que c'est vide pour la colonne canal marketing, c'est vide pour la méthode de création aussi.

[illegible]

Nettoyer des données



L = Localiser les problèmes solubles

Exemples :

On va faire ces vérifications pour toutes les tables/onglets.

Ici, dans la table région, on voit des incohérences au niveau de la classification des région, des valeurs qui ne sont pas logiques et des valeurs manquantes.

COUNTRY_	REGION
AW	NA
BB	North America
BM	North America
BZ	North America
CA	North America
IE	
LB	
MH	X.x
PG	X.x

Nettoyer des données



L = Localiser les problèmes solubles

Exemples :

Il est aussi recommandé de vérifier les doublons.
Pour le faire, vous allez avoir besoin de créer un
tableau croisé dynamique (pivot table)

Ici, on a des doublons au niveau des ORDER_ID →
une commande est partagée par 2 utilisateurs

Row Labels	Count of USER_ID
f9f79885a0c20722	2
fd433d0794388662	2
fb5220308668297	2
f2834cfcefa99132	2
fef061c2a1499684	2
f28b830630316352	2
faeed02734f17950	2
f2bff88d2085179	2
fc4afe0b63e9140	2
f2c837f2c7926688	2
fe46937234d46760	2
f2d14b5d31779690	2
f8d857ace8767915	2
f2d17cd140264273	2
fa0867509e13974	2
f2e8de6c9ee93149	2
fba5524539894589	2

Nettoyer des données



L = Localiser les problèmes solubles

Exemples :

Au-delà de vérifier chaque colonne individuelles, il est aussi important de vérifier **la cohérence entre plusieurs colonnes**.

Ex: si vous avez des dates, une date d'achat et une date d'expédition du produit, vous pouvez vérifiez si la date d'expédition est bien après la date d'achat.

USER_ID	ORDER_ID	PURCHASE_TS_ CLEANED	SHIP_TS	check si date ship > purchase
1962fd4e	00617fd9ac813297	23/03/2019	08/03/2019	FALSE
6ee318a8	0064a61f5e347824	06/12/2020	30/08/2020	FALSE
0d688544	006b12955f18514	01/04/2020	29/11/2019	FALSE
eb7713b2	006e82641e899478	06/09/2020	08/05/2020	FALSE
fbe55d88	006f6e37919106394	25/06/2020	10/06/2020	FALSE
44b1b815	00740cb808130885	18/09/2020	24/04/2020	FALSE
4f91bdc5	0076d16bf5a35309	07/05/2020	02/02/2020	FALSE
7aaa16c9	0077b0c58a652405	24/10/2020	20/09/2020	FALSE
fab63d82	0078e0a047f105931	15/06/2020	07/02/2020	FALSE
6967b8ad	007d7cc247b45508	23/12/2020	31/10/2020	FALSE
0548e915	007de4bffd25269	26/08/2019	08/08/2019	FALSE
08c6e99f	007ecf8f7136611	03/11/2019	13/10/2019	FALSE
9ac1cd5e	0080c27c2f965438	23/05/2019	14/02/2019	FALSE

Nettoyer des données



L = Localiser les problèmes solubles

En résumé, vous allez vérifier :

- ☐ les incohérences dans les formats de données
- ☐ les incohérences dans l'orthographe ou les catégorisations
- ☐ les valeurs de type « null » (= l'absence de données)
- ☐ Les incohérences entre plusieurs colonnes (logique business)
- ☐ les doublons

⚠ Pour chaque erreur trouvée, vous allez l'enregistrer dans **une liste des problèmes identifiés**
N'oubliez pas d'enlever vos filtres après chaque vérification (pour ne pas vous retrouver avec un double filtrage)

Nettoyer des données



L = Localiser les problèmes solubles

Voici à quoi va ressembler cette liste :

table	colonne	problème	# de lignes	% de total lignes	soluble ?	solution			# total lignes
orders	PURCHASE_TS	incohérence format des dates	10	0,05%	Oui				21864
orders	PURCHASE_TS	date manquante	1	0,005%	Non				
orders	PRODUCT_NAME	incohérence de l'ortographe entre "27in 4K gaming monitor" et "27inches 4k gaming monitor"	61	0,28%	Oui				
orders	USD_PRICE	prix manquant ou 0	34	0,16%	Non				
orders	MARKETING_CHANNEL	marketing channel manquant	83	0,38%	Oui				
orders	ACCOUNT_CREATION_METHOD	account creation method manquant - même nombre de mkt channel ?	83	0,38%	Oui				
orders	COUNTRY_CODE	code pays manquant	37	0,17%	Non				
region	REGION	incohérence ou données manquantes	9	0,04%	Oui				
orders	toutes	doublons	145	0,66%	Non				
orders	PURCHASE_TS & SHIP_TS	la date d'envoi est AVANT la date d'achat	1974	9,03%	Non				

Nettoyer des données





L = Localiser les problèmes solubles

Une fois que vous avez créé votre liste de problèmes, vous pouvez aller résoudre les problèmes solubles.


table	colonne	problème	# de lignes	% de total lignes	soluble ?	solution			# total lignes
orders	PURCHASE_TS	incohérence format des dates	10	0,05%	Oui				21864
orders	PURCHASE_TS	date manquante	1	0,005%	Non				
orders	PRODUCT_NAME	incohérence de l'ortographe entre "27in 4K gaming monitor" et "27inches 4k gaming monitor"	61	0,28%	Oui				
orders	USD_PRICE	prix manquant ou 0	34	0,16%	Non				
orders	MARKETING_CHANNEL	marketing channel manquant	83	0,38%	Oui				
orders	ACCOUNT_CREATION_METHOD	account creation method manquant - même nombre de mkt channel ?	83	0,38%	Oui				
orders	COUNTRY_CODE	code pays manquant	37	0,17%	Non				
region	REGION	incohérence ou données manquantes	9	0,04%	Oui				
orders	toutes	doublons	145	0,66%	Non				
orders	PURCHASE_TS & SHIP_TS	la date d'envoi est AVANT la date d'achat	1974	9,03%	Non				



**E = Evaluer l'ampleur des
problèmes insolubles**



Nettoyer des données




E = Evaluer l'ampleur des problèmes insolubles

Principaux types de problèmes insolubles (insolubles par vous directement) :

- ☐ des valeurs de type « null » (= l'absence de données pour lesquelles vous ne pouvez pas déduire les valeurs)
- ☐ des anomalies et outliers (qui pourraient représenter de vrais événements ou pas, vous n'êtes pas sûrs)
- ☐ violation de la logique business (ex: avoir une date d'expédition AVANT la date de commande)

- ➔ Pour résoudre ces problèmes, vous allez devoir **échanger avec d'autres équipes** : techniques et/ou business pour comprendre les données plus en détail.
- ➔ L'important est surtout de **documenter ces problèmes et d'en évaluer l'ampleur** (est-ce qu'on parle de 0,5% ou de 25% des données qui sont impactées ?)

Nettoyer des données




E = Evaluer l'ampleur des problèmes insolubles

Principaux types de problèmes insolubles (insolubles par vous directement) :

- ☐ des valeurs de type « null » → si vous n'avez pas l'info (et que vous avez cherché), évitez d'imaginer des valeurs et laissez tels quels (surtout si l'ampleur est non-significative)
- ☐ des anomalies et outliers → généralement, vous allez comprendre plus sur ces valeurs lors de l'analyse et en échangeant avec d'autres métiers
- ☐ violation de la logique business → ici, vous allez plus loin que les simples vérifications et vous vérifiez si les valeurs des colonnes entre elles ont du sens (ex: date d'achat et d'expédition)

Nettoyer des données





E = Evaluer l'ampleur des problèmes insolubles

Que faire avec les problèmes insolubles ?

- Les documenter (dans votre liste à problèmes ou issues log)
- Noter leur ampleur (quel % des données totales elles représentent ?)
- Noter si vous pouvez parler à d'autres équipes pour les résoudre



**A = Augmenter la qualité
des données**



Nettoyer des données



A = Augmenter la qualité des données

Exemples :

- Créer de **nouvelles granularités pour vos périodes de temps** (si vous avez une date précise, vous pouvez ajouter des semaines, des mois, des années)
- **Ajouter d'autres dimensions** pour explorer davantage (ex: ajouter la région de notre autre onglet)
- **Calculer de nouvelles métriques** (ex: la différence entre la date d'achat et la date d'expédition nous donnera une idée sur le nombre de jours que l'entreprise prend pour expédier un produit)

Nettoyer des données



A = Augmenter la qualité des données

Exemples :

- Créer de **nouvelles granularités pour vos périodes de temps** (si vous avez une date précise, vous pouvez ajouter des semaines, des mois, des années)
- Ex: ici on peut extraire **l'année d'achat** à partir de la date d'achat
(faites attention **au format**, si c'est date, vous pouvez avoir des valeurs bizarres)

PURCHASE_YEAR						
D	E	F	G	H		
PURCHASE_TS_CLEANED	SHIP_TS	PURCHASE_YEAR	check si date ship > purchase	PRODUCT_NAME		PRO
24/12/2020	26/12/2020	2020	TRUE	Nintendo Switch		e68
01/10/2020	03/10/2020	2020	TRUE	Nintendo Switch		e68
21/04/2020	26/04/2020	2020	TRUE	Nintendo Switch		8d0
07/04/2020	09/04/2020	2020	TRUE	Sony PlayStation 5 Bundle		54e
24/11/2020	27/11/2020	2020	TRUE	Nintendo Switch		8d0
20/08/2020	24/08/2020	2020	TRUE	Nintendo Switch		8d0
11/05/2020	14/05/2020	2020	TRUE	27in 4K gaming monitor		891
03/07/2020	07/07/2020	2020	TRUE	27in 4K gaming monitor		891
24/03/2019	28/03/2019	2019	TRUE	JBL Quantum 100 Gaming Headset		Hab0
01/11/2019	07/11/2019	2019	TRUE	Nintendo Switch		e68
09/12/2019	11/12/2019	2019	TRUE	Nintendo Switch		8d0
30/08/2019	03/09/2019	2019	TRUE	Nintendo Switch		8d0

Nettoyer des données



A = Augmenter la qualité des données

Exemples :

- **Ajouter d'autres dimensions** pour explorer davantage (ex: ajouter la région de notre autre onglet)
- Ici, on avait le code pays dans l'onglet orders et aussi dans l'onglet région
- On peut donc ramener l'info sur la région en faisant une recherche V sur le pays

USER_ID	ORDER_ID	ACCOUNT_CREATION_METHOD	COUNTRY_CODE	REGION
2c06175e	0001328c3c220830	unknown	US	NA
ee8e5bc2	0002af7a5c6100772	desktop	DE	EMEA
9eb4efe0	0002b8350e167074	desktop	US	NA
cac7cbaf	0006d06b98385729	desktop	AU	APAC
6b0230bc	00097279a2f46150	desktop	TR	EMEA
046e7528	000f169e17f4941	desktop	PH	APAC
94dfec76	000fdd9bfe463101	desktop	GB	EMEA
8a328a1d	0010d31e3c058676	desktop	BR	LATAM
46c57b58	0013ac51a8831707	desktop	BE	EMEA
a2eaa1d1	001620ea42468912	desktop	US	NA
c7c492f8	0016654fc8584512	desktop	FR	EMEA
d71c06c6	00236994a0b90874	desktop	KR	APAC
9933b602	002a0b04dd764807	desktop	US	NA

Nettoyer des données



A = Augmenter la qualité des données




Exemples :

- **Calculer de nouvelles métriques** (ex: la différence entre la date d'achat et la date d'expédition nous donnera une idée sur le nombre de jours que l'entreprise prend pour expédier un produit)

USER_ID	ORDER_ID	PURCHASE_TS_CLEANED	SHIP_TS	Time from purchase to shipping
2c06175e	0001328c3c220830	24/12/2020	26/12/2020	2
ee8e5bc2	0002af7a5c6100772	01/10/2020	03/10/2020	2
9eb4efe0	0002b8350e167074	21/04/2020	26/04/2020	5
cac7cbaf	0006d06b98385729	07/04/2020	09/04/2020	2
6b0230bc	00097279a2f46150	24/11/2020	27/11/2020	3
046e7528	000f169e17f4941	20/08/2020	24/08/2020	4
94dfec76	000fdd9bfe463101	11/05/2020	14/05/2020	3
8a328a1d	0010d31e3c058676	03/07/2020	07/07/2020	4
46c57b58	0013ac51a8831707	24/03/2019	28/03/2019	4
a2eaa1d1	001620ea42468912	01/11/2019	07/11/2019	6
c7c492f8	0016654fc8584512	09/12/2019	11/12/2019	2
d71c06c6	00236994a0b90874	30/08/2019	03/09/2019	4
9933b602	002a0b04dd764807	16/02/2020	18/02/2020	2
bbbaa7ff	002f0b22bb379479	14/05/2020	20/05/2020	6



N = Noter et documenter



Nettoyer des données



N = Noter et documenter

Dans cette étape, vous allez vous assurer que vous avez noté les différents problèmes que vous avez identifié ainsi que documenté la solution ou la non résolution.

table	colonne	problème	# de lignes	% de total lignes	soluble ?	solution
orders	PURCHASE_TS	incohérence format des dates	10	0,05%	Oui	corrigé les dates erronées
orders	PURCHASE_TS	date manquante	1	0,005%	Non	laissé tel quel : peu d'impact
orders	PRODUCT_NAME	incohérence de l'ortographe entre "27in 4K gaming monitor" et "27inches 4k gaming monitor"	61	0,28%	Oui	recatégorisé tous les produits concernés en tant que "27in 4K gaming monitor"
orders	USD_PRICE	prix manquant ou 0	34	0,16%	Non	laissé tel quel : pas de moyen direct de savoir quelle valeur mettre, besoin de vérifier avec les équipes business
orders	MARKETING_CHANNEL	marketing channel manquant	83	0,38%	Oui	recatégorisé en tant que "unknown"
orders	ACCOUNT_CREATION_METHOD	account creation method manquant - même nombre de mkt channel ?	83	0,38%	Oui	recatégorisé en tant que "unknown"
orders	COUNTRY_CODE	code pays manquant	37	0,17%	Non	laissé tel quel : pas de moyen direct de savoir quelle valeur mettre, besoin de vérifier avec les équipes business
region	REGION	incohérence ou données manquantes	9	0,04%	Oui	ajouté les valeurs correctes en effectuant des recherches
orders	toutes	doublons	145	0,66%	Non	laissé tel quel, on pourrait supprimer les doublons mais pas assez d'info dessus et pas d'ampleur importante
orders	PURCHASE_TS & SHIP_TS	la date d'envoi est AVANT la date d'achat	1974	9,03%	Non	laissé tel quel , il sera important d'explorer si on fait des analyses au niveau des dates

Nettoyer des données



N = Noter et documenter

Il n'est pas important de résoudre TOUTES les erreurs et incohérences de suite.

Il est surtout essentiel de les documenter pour :

- Pouvoir vous rappeler de ce que vous avez trouvé
- Pouvoir échanger avec d'autres équipes si besoin
- Avoir une idée de l'ampleur du problème pour décider quoi en faire

Nettoyer des données

En résumé :


C → Comprendre les données, ce qu'elle représentent (lignes, métriques, dimensions, questions business/data)

L → Localiser les problèmes solvables (faire une copie, explorer colonne par colonne et aussi l'ensemble)


E → Evaluer l'ampleur des problèmes insolubles (combien de lignes sont impactées par rapport au total ?)

A → Augmenter la qualité des données (quelles infos extra je peux ajouter et qui seront utiles ?)

N → Noter et documenter (documenter tous les problèmes, leur ampleur, et la solution s'il y en a ou les étapes à poursuivre)



Qu'est ce que vous avez retenu
jusqu'ici ?







AUJOURD'HUI

Introduction

Nettoyer des données

Modèle Entité/Association

Cardinalités



Modèle Entité/Association (E/A)



- **On commence par l'évaluation des besoins**
 - Quelles sont les activités générant des données ?
 - Quelles sont les données à stocker ?
 - Est-ce qu'il y a des règles que les données doivent respecter ?

La finalité de cette étape est souvent enregistrée sous forme de texte, exemple:

L'ECAM est divisé en plusieurs unités d'enseignement.

Chaque unité est désignée par un code unique et un nom (ex: Génie Electronique et Informatique).

Chaque enseignant.e à l'ECAM est affecté .e à une seule unité.

Un.e enseignant.e sera désigné.e par son matricule unique, son nom et prénom et sa fonction au sein de l'ECAM

Modèle Entité/Association (E/A)



L'ECAM est divisé en plusieurs unités d'enseignement.

Chaque unité est désignée par un code unique et un nom (ex: Génie Electronique et Informatique).

Chaque enseignant à l'ECAM est affecté à une seule unité.

Un/e enseignant sera désigné/e par son matricule unique, son nom et prénom et sa fonction au sein de l'ECAM

- On peut détecter un certain nombre d'activités (du monde réel) → ces activités vont générer un certain nombre de données
- Quelles sont les données qu'on peut vouloir **enregistrer** ?
- On va ensuite procéder à la **modélisation des données** (= exprimer ce qui est décrit dans le texte sous un format de graphe composé de symboles → forme symbolique)

Modèle Entité/Association (E/A)



L'ECAM est divisé en plusieurs unités d'enseignement.

Chaque unité est désignée par un code unique et un nom (ex: Génie Electronique et Informatique).

Chaque enseignant à l'ECAM est affecté à une seule unité.

Un/e enseignant sera désigné/e par son matricule unique, son nom et prénom et sa fonction au sein de l'ECAM

- Le modèle qu'on va utiliser s'appelle **Modèle Entité/Association (E/A)** → on va suivre la notation Merise (il existe d'autres notations qu'on verra plus tard)

1 Etape 1: Identifier les objets pour lesquels on veut conserver des informations

→ On appelle ces objets **des entités** = Quelque chose (objet abstrait/concret de la réalité) pour laquelle on veut stocker des données

Modèle Entité/Association (E/A)



L'ECAM est divisé en plusieurs unités d'enseignement.

Chaque unité est désignée par un code unique et un nom (ex: Génie Electronique et Informatique).

Chaque enseignant à l'ECAM est affecté à une seule unité.

Un/e enseignant sera désigné/e par son matricule unique, son nom et prénom et sa fonction au sein de l'ECAM

■ Questions à se poser:

- Quels sont les objets/notions/concepts sur lesquels le texte se **concentre** ?
- Quels sont les objets qui représentent un intérêt pour **stocker leurs données dans la BD** ?

Ces objets correspondent **aux entités**

Modèle Entité/Association (E/A)



L'ECAM est divisé en plusieurs unités d'enseignement.

Chaque unité est désignée par un code unique et un nom (ex: Génie Electronique et Informatique).

Chaque enseignant à l'ECAM est affecté à une seule unité.

Un/e enseignant sera désigné/e par son matricule unique, son nom et prénom et sa fonction au sein de l'ECAM

- Ici, on se focalise sur **2 notions**: Unité et Enseignant
- On relève **2 entités**: Unité et Enseignant

Modèle Entité/Association (E/A)



L'ECAM est divisé en plusieurs unités d'enseignement.

Chaque unité est désignée par un code unique et un nom (ex: Génie Electronique et Informatique).

Chaque enseignant à l'ECAM est affecté à une seule unité.

Un/e enseignant sera désigné/e par son matricule unique, son nom et prénom et sa fonction au sein de l'ECAM

2 ■ Ensuite, on va s'intéresser **aux attributs** (rappel = propriété, caractéristique, qualité d'une entité)

■ 2 entités: Unité et Enseignant

■ Pour chaque entité → on doit déterminer les attributs et ses caractéristiques

■ Unité: "désignée par un code unique et un nom"

■ Enseignant: "désigné par son matricule unique, son nom et prénom et sa fonction au sein de l'ECAM"

Modèle Entité/Association (E/A)



L'ECAM est divisé en plusieurs unités d'enseignement.

Chaque unité est désignée par un code unique et un nom (ex: Génie Electronique et Informatique).

Chaque enseignant à l'ECAM est affecté à une seule unité.

Un/e enseignant sera désigné/e par son matricule unique, son nom et prénom et sa fonction au sein de l'ECAM

- Unité: “désignée par un code unique et un nom”
- Enseignant: “désigné par son matricule unique, son nom et prénom et sa fonction au sein de l'ECAM”

Attributs de l'Unité	Attributs de l'Enseignant
- Code Unité	- Matricule Enseignant
- Nom Unité	- Nom
	- Prénom
	- Fonction

Modèle Entité/Association (E/A)



Attributs de l'Unité	Attributs de l'Enseignant
- Code Unité - Nom Unité	- Matricule Enseignant - Nom - Prénom - Fonction

- Domaine de l'attribut = Ensemble de valeurs acceptables pour un attribut
- **Exemple Valeurs de l'Attribut "Fonction"**
{Enseignant en Mathématiques, Enseignant en Informatique, Enseignant en Structure de données, Enseignant en Architecture Web}
- **Exemple Valeurs de l'Attribut "Nom Unité"**
{Génie Electronique et Informatique, Génie Construction et Géomètre, Génie Mécanique et Thermique, Génie Electrique et Automatique, Formation Générale et Scientifique}

Modèle Entité/Association (E/A)



- Classe d'entité = la classe de toutes les entités qui sont de même nature et qui jouent le même rôle

■ Exemple

Enseignant
Mathématiques

Enseignant
Informatique

Enseignant Structure de
données

Enseignant Architecture
Web

Peuvent être regroupé dans l'entité **"Enseignant"**

Partagent les mêmes caractéristiques

Modèle Entité/Association (E/A)



- **Occurrence d'une entité** = un individu particulier qui fait partie de l'entité
- **Clé/Identifiant** = attribut ou ensemble d'attributs qui permettent d'identifier de manière unique est sans ambiguïté les occurrences d'une entité (on verra ceci plus en détail dans le prochain cours)


- Dubois
- Nathalie
- Enseignante Mathématiques

Même nom, prénom et fonction

- Dubois
- Nathalie
- Enseignante Mathématiques

Pour éviter l'ambiguïté, on ajoute une clé qui distingue une occurrence d'une entité des autres occurrences de la même entité, dans notre cas: **Matricule**

Modèle Entité/Association (E/A)



- Représentation d'une entité dans le schéma Entité/Association

Nom Entité

Identifiant

Attribut

Unité	Enseignant
- <u>Code Unité</u>	- <u>Matricule Enseignant</u>
- Nom Unité	- Nom - Prénom - Fonction

Nom Entité

Identifiant

Attributs

Modèle Entité/Association (E/A)



- 3 ■ Association = un lien entre plusieurs entités traduisant une réalité → on va chercher le verbe entre **2 entités**

L'ECAM est divisé en plusieurs unités d'enseignement.


Chaque unité est désignée par un code unique et un nom (ex: Génie Electronique et Informatique).

Chaque **enseignant** à l'ECAM est affecté à une seule **unité**.


Un/e enseignant sera désigné/e par son matricule unique, son nom et prénom et sa fonction au sein de l'ECAM

- Le verbe constitue la liaison entre les entités

Modèle Entité/Association (E/A)



■ Représentation d'une association



On fera un point sur les cardinalités et on revient aux E/A après.





AUJOURD'HUI

Introduction

Nettoyer des données

Modèle Entité/Association

Cardinalités



Cardinalités




- Les cardinalités sont des couples de valeurs que l'on trouve entre chaque entité et ses associations liées:
 - Trois valeurs typiques: 0, 1 et N (= plusieurs)
- **Cardinalité d'une association** = nombre minimum et nombre maximum de participants d'une occurrence d'une entité dans l'association
 - Cardinalité minimale peut être de 0 ou de 1
 - Cardinalité maximale peut être de 1 ou de N
- En d'autres termes, lorsqu'il s'agit de bases de données et leur modélisation, la cardinalité désigne si une relation est (plus de détails dessus dans les prochains cours):
 - 1-1 (one to one)
 - 1- M (one to many)
 - M-N (many to many)

Cardinalités



Pour les cardinalités, tout dépend des règles de gestion de l'entreprise et en absence de règles: de notre compréhension et interprétation de la réalité

Cardinalités : notations




Différences notations

- Aujourd'hui, on a vu la notation Merise

1

MERISE


Utilise des **associations** à la place des relations



2

CHEN.


Modéliser les bases des entités et relations. Utile pour des cas simples.



3

CROW'S FOOT

Pour illustrer une relation entre des entités, des modèles plus complexes



Différences notations




- Reprenons un exemple où un enseignant est affecté à une et une seule unité

→ MERISE : on met les cardinalités de l'enseignant par rapport à l'unité du côté enseignant



→ CROW'S FOOT: on met les cardinalités de l'enseignant par rapport à l'unité du côté unité




Différences notations




- Reprenons un exemple où un enseignant est affecté à une et une seule unité

→ CHEN : on met les cardinalités de l'enseignant par rapport à l'unité du côté unité



Cardinalités : exemples





Cardinalités

- Imaginons une école. Dans cette école, pour rester inscrit, un étudiant doit suivre **au moins un** cours. Un cours peut être suivi **par personne, par 1 ou par plusieurs étudiants**.

Etudiant
- <u>Matricule Etudiant</u>
- Nom
- Prénom



Cours
- <u>Code Cours</u>
- Nom Cours




Cardinalités minimales: 0 ou 1
Cardinalités maximales: 1 ou N



Cardinalités

- Commençons par le côté étudiant. On va se poser 2 questions:
 - Question 1: Un étudiant peut suivre combien de cours au **minimum**?
 - Question 2: Un étudiant peut suivre combien de cours **maximum** ?

Etudiant
- <u>Matricule Etudiant</u> - Nom - Prénom



Cours
- <u>Code Cours</u> - Nom Cours



Cardinalités minimales: 0 ou 1
Cardinalités maximales: 1 ou N



Cardinalités


■ Côté étudiant: Cardinalité Minimale (Etudiant qui suit des cours)

- **Question 1**: Un étudiant peut suivre combien de cours au **minimum** ?

→ On peut reformuler cette question comme ceci: Est-ce obligatoire qu'un étudiant suive un cours ?

→ On a lu dans le texte que pour rester inscrit, un étudiant **DOIT** suivre **AU MOINS UN COURS**.

Etudiant
- <u>Matricule Etudiant</u>
- Nom
- Prénom



Cours
- <u>Code Cours</u>
- Nom Cours

Cardinalités minimales: 0 ou 1





Cardinalités

■ Côté Etudiant: Sens de la lecture

→ La cardinalité MINIMALE entre étudiant et cours sera de 1

→ Comment on place la cardinalité: sens de la lecture

→ Un Etudiant (étape 1) Suit (étape 2) au moins 1 (étape 3) Cours (étape 4)

1

2

3

4

Etudiant
- <u>Matricule Etudiant</u>
- Nom
- Prénom



1

1

3

Suivre

2

Cours

- Code Cours
- Nom Cours

4




Cardinalités

■ Côté Etudiant

- La cardinalité MINIMALE entre étudiant et cours sera de 1
- Comment on place la cardinalité: sens de la lecture

 La Cardinalité qui permet de préciser quel est le lien entre un étudiant et un cours est du côté de l'étudiant (on revient en arrière) → étape 3





Cardinalités

■ Continuons avec le côté étudiant et la Cardinalité Maximale. On va se poser la question suivante:

- **Question 2**: Un étudiant peut suivre combien de cours **Maximum** ?

→ On a lu dans le texte que pour rester inscrit, un étudiant **DOIT** suivre **AU MOINS UN COURS**. Il n'est pas précisé le nombre max de cours, on va donc dire que c'est N

→ Alors, la cardinalité MAXIMALE entre étudiant et cours sera de N

Etudiant
- <u>Matricule Etudiant</u>
- Nom
- Prénom

1, N

Suivre

Cours
- <u>Code Cours</u>
- Nom Cours






Cardinalités

■ Côté Etudiant

- La cardinalité MAXIMALE entre étudiant et cours sera de N
- Maintenant qu'on ait la cardinalité Mix et Max, comment on lit le tout ?
- Un étudiant suit au moins 1 cours et au maximum N nombre de cours.






Cardinalités


- Côté Etudiant est prêt, passons du côté cours

On va se poser 2 questions:

- Question 1: Un cours peut être suivi par combien d'étudiants au minimum ? (= nombre minimal)?
- Questions 2: Un cours peut être suivi par combien d'étudiants au maximum? (= nombre maximal)?



Cardinalités minimales: 0 ou 1
Cardinalités maximales: 1 ou N






Cardinalités

■ Côté cours: Cardinalité Minimale

- **Question 1:** Un cours peut être suivi par combien d'étudiants au minimum (= nombre minimal)?
- Notre texte dit: un cours peut être suivi par personne (=0), par 1 ou par plusieurs étudiants.

→ La cardinalité minimale sera alors 0 (car un cours peut être suivi par personne)







Cardinalités

■ Passons maintenant à la dernière Cardinalité: Cardinalité Maximale Côté Cours

- **Question 2:** Un cours peut être suivi par combien de personnes au maximum ? (= nombre maximal)
- On relit notre texte: un cours peut être suivi par personne (=0), par 1 **ou par plusieurs étudiants.**
- La cardinalité maximale sera alors N (car un cours peut être suivi par plusieurs personnes)







Cardinalités

■ Côté Cours; Regardons le sens de lecture

- La cardinalité MINIMALE entre cours et étudiant sera de 0
- La cardinalité MAXIMALE entre cours et étudiant sera de N

→ Un Cours (étape 1) est Suivi (étape 2) par aucun ou plusieurs (étape 3) Etudiants (étape 4)





Cardinalités: Exemples

■ IMPORTANT: La cardinalité va dépendre des règles de gestion de l'entreprise

- Regardons ceci avec un exemple de clients qui peuvent commander des produits
- **Cardinalité Minimale Client vers Produit**

- Questions:

- Un client commande combien de produits au minimum ?
- Ou encore: **est-il obligatoire** qu'un client effectue une commande de produit ?





Cardinalités: Exemples

■ IMPORTANT: La cardinalité va dépendre des règles de gestion de l'entreprise

- Regardons ceci avec un exemple de clients qui peuvent commander des produits

- **Cardinalité Minimale Client vers Produit**

- **Question:** Un client commande combien de produits au minimum ?

→ **Scénario 1:** Chaque client doit effectuer AU MOINS une commande, sinon ce n'est pas un client

→ Alors, la cardinalité minimale sera de 1

Client
- <u>Id Client</u>
- Nom
- Prénom

1

Commander

Produit
- <u>Numéro Produit</u>
- Nom Produit



Cardinalités: Exemples

■ IMPORTANT: La cardinalité va dépendre des règles de gestion de l'entreprise


- Regardons ceci avec un exemple de clients qui peuvent commander des produits

- **Cardinalité Minimale Client vers Produit**

- **Question:** Un client commande combien de produits au minimum ?


→ **Scénario 2:** On a une entreprise qui enregistre aussi les prospects dans l'entité client (clients qui n'ont encore rien commandé)

→ Alors, la cardinalité minimale sera de 0



0

Commander





Cardinalités: Exemples

■ IMPORTANT: La cardinalité va dépendre des règles de gestion de l'entreprise

- Regardons ceci avec un exemple de clients qui peuvent commander des produits

- **Cardinalité Maximale Client vers Produit**

- **Question:** Un client commande combien de produits maximum?

→ **Scénario 3:** Un client peut commander autant de produits qu'il/elle veut

→ Alors, la cardinalité maximale sera de N





Cardinalités: Exemples

■ IMPORTANT: La cardinalité va dépendre des règles de gestion de l'entreprise

- Regardons ceci avec un exemple de clients qui peuvent commander des produits
- **Cardinalité Maximale Client vers Produit**

- **Question:** Un client commande combien de produits au maximum ?

→ **Scénario 4:** Imaginons une entreprise où un client peut commander un seul produit. Pas considéré client si aucun Produit commandé.

→ Alors, la cardinalité maximale sera de 1



Si un client peut commander **aucun** OU un seul produit, alors la cardinalité sera 0,1



Cardinalités: Exemples

■ IMPORTANT: La cardinalité va dépendre des règles de gestion de l'entreprise

- Cardinalité Minimale Produit vers Client

- Questions : Un produit peut être commandé par combien de clients au minimum ?

- Est-ce obligatoire qu'un produit soit commandé pour être enregistré dans la BD ?

→ (Peut-il exister dans la base de données des produits qui n'ont jamais été commandés ?)

→ **Scénario 5:** Imaginons qu'on enregistre TOUS les produits: commandés ou pas (exemple nouveaux produits dans un catalogue qui n'ont jamais été commandés)

→ Alors, la cardinalité minimale sera de 0





Cardinalités: Exemples

■ IMPORTANT: La cardinalité va dépendre des règles de gestion de l'entreprise

- Cardinalité Minimale Produit vers Client

- Questions : Un produit peut être commandé par combien de clients au minimum ?
- Est-ce obligatoire qu'un produit soit commandé pour être enregistré dans la BD ?
- Peut-il exister dans la base de données des produits qui n'ont jamais été commandés ?

→ **Scénario 6:** On fabrique les produits à la commande (ex: menuiserie), donc chaque produit dans la base de données a déjà été commandé

→ Alors, la cardinalité minimale sera de 1






Cardinalités: Exemples


■ **IMPORTANT:** La cardinalité va dépendre des règles de gestion de l'entreprise



- Un client commande au moins **1 produit** (au moins un OU plusieurs)
- Et un produit peut ne **pas encore avoir été commandé**, comme il peut avoir été commandé plusieurs fois





Qu'est ce que vous avez retenu du
cours d'aujourd'hui ? 😊





Fin Cours 21/09/26