

STRUCTURE DE DONNEES

LABO 1 : NETTOYER DES DONNEES

INTRODUCTION

Avant de créer votre modèle de données et analyses vos données, vous devez vous assurer que vos données soient prêtes à être utilisées.

Dans ce labo, vous allez vous exercer à repérer les inconsistances dans un fichier contenant des données et à les corriger.

EXERCICE : SUIVRE LE FRAMEWORK CLEAN

Sur Moodle, vous allez trouver 1 set de données, concernant l'entreprise Loop Earplugs.

Ensuite, appliquez la procédure (CLEAN) qu'on a vue en cours hier.

Pour vous aider, vous pouvez vous consulter la section « Résultat attendu » et vous servir de la checklist disponible plus bas.

Si vous n'avez pas coché toutes les cases de la checklist, votre travail n'est pas fini et donc : **pas présentable pour correction.**

Les travaux sont acceptés pour correction **uniquement pendant les heures de laboratoire et doivent être remis en personne.**

Aucun envoi par e-mail ne sera accepté.

Effectuez le travail dans Excel.

Si vous n'avez pas Excel, vous pouvez utiliser Google Sheets.

Bon nettoyage 😊

STRUCTURE DE DONNEES

LABO 1 : NETTOYER DES DONNEES

RESULTAT ATTENDU

Une liste détaillée des problèmes que vous avez trouvés dans le fichier, en suivant le format qu'on a vu en cours.

Merci de traiter l'ensemble des pages (tables) du fichier proposé.

table	colonne	problème	# de lignes	% de total lignes	soluble ?	solution
orders	PURCHASE_TS	incohérence format des dates	10	0,05%	Oui	corrigé les dates erronées
orders	PURCHASE_TS	date manquante	1	0,005%	Non	laissé tel quel : peu d'impact
orders	PRODUCT_NAME	incohérence de l'ortographe entre "27in 4K gaming monitor" et "27inches 4k gaming monitor"	61	0,28%	Oui	recatégorisé tous les produits concernés en tant que "27in 4K gaming monitor"
						laissé tel quel : pas de moyen direct de savoir quelle valeur mettre, besoin de vérifier avec les équipes business
orders	USD_PRICE	prix manquant ou 0	34	0,16%	Non	
orders	MARKETING_CHANNEL	marketing channel manquant	83	0,38%	Oui	recatégorisé en tant que "unknown"
orders	ACCOUNT_CREATION_METHOD	account creation method manquant - même nombre de mkt channel ?	83	0,38%	Oui	recatégorisé en tant que "unknown"
						laissé tel quel : pas de moyen direct de savoir quelle valeur mettre, besoin de vérifier avec les équipes business
orders	COUNTRY_CODE	code pays manquant	37	0,17%	Non	
region	REGION	incohérence ou données manquantes	9	0,04%	Oui	ajouté les valeurs correctes en effectuant des recherches
						laissé tel quel, on pourrait supprimer les doublons mais pas assez d'info dessus et pas d'ampleur importante
orders	toutes	doublons	145	0,66%	Non	
orders	PURCHASE_TS & SHIP_TS	la date d'envoi est AVANT la date d'achat	1974	9,03%	Non	laissé tel quel, il sera important d'explorer si on fait des analyses au niveau des dates

CHECKLIST CLEAN

C = Comprendre les données

- ☐ Avant de plonger dans le nettoyage, je me demande quelle sorte de données je regarde
- ☐ A quelles questions business et data je peux répondre grâce à ces données ?
- ☐ Quelle histoire ces données peuvent m'aider à raconter ?
- ☐ Que représente chaque ligne ? (granularité des données)
- ☐ Quelles sont les métriques ? (ce que les données mesurent → quantifiable)
- ☐ Quelles sont les dimensions ? (ce que les données décrivent → aspect qualitatif)
- ☐ Quelles sont les métriques clés ?
- ☐ Quelles sont les dimensions clés ?

STRUCTURE DE DONNEES

LABO 1 : NETTOYER DES DONNEES

L = Localiser les problèmes solubles

- ☐ Avant toute exploration, je commence par faire une copie de mes onglets/tables que je renomme Nom de l'onglet_Cleaned (ex : orders_cleaned)
- ☐ Avant d'effectuer des changements dans une colonne, je la duplique et je la renomme en ajoutant _cleaned à la fin (ex : Purchase date_cleaned)
- ☐ Je crée un onglet dédié à la documentation des problèmes (issues log)
- ☐ Je commence par regarder le fichier dans son entièreté, sans filtrer. Est-ce qu'il y a des choses qui me sautent aux yeux ?
- ☐ J'applique des filtres à chaque colonne et je vérifie ses valeurs distinctes
- ☐ Pour chaque colonne examinée où je trouve un problème, je documente dans mon onglet dédié en notant le nombre de lignes impactées, le % des lignes totales que cela représente, si le problème est directement soluble ou pas et le type de résolution
- ☐ Je vérifie le formatage, exemple : si j'ai une colonne avec des ID et : si tous les id font 8 caractères et un qui en fait 3 => ce n'est pas forcément une erreur mais cela mérite d'être noté)
- ☐ Pour les dates, je vérifie s'il n'y a pas des formats différents (année vs timestamp par exemple)
- ☐ Je vérifie les incohérences dans les classifications (ex : un Produit qui s'appelle Nintendo 24in et un qui s'appelle Nintendo 24inches ; ou une région NA et une région North America)
- ☐ Je vérifie les incohérences au niveau de l'orthographe (ex : un produit qui s'appelle Nintendo 24 in et un qui s'appelle Nintenod 24 in)
- ☐ Je vérifie les incohérences au niveau du formatage minuscules/majuscules (ex : un produit qui s'appelle NINTENDO 24 IN et un qui s'appelle Nintendo 24 in)
- ☐ Je vérifie s'il n'y a pas de valeurs vides
- ☐ Je vérifie s'il n'y a pas de valeurs qui semblent illogiques d'un point de vue business (ex : un prix négatif)
- ☐ Au-delà des vérifications de chaque colonne individuelle, je vérifie s'il n'y a pas des doublons (via un tableau croisé dynamique)
- ☐ Au-delà des vérifications de chaque colonne individuelle, je vérifie la cohérence entre les différentes colonnes (ex : une date d'envoi qui est avant la date d'achat mérite d'être noté et exploré)
- ☐ Je vérifie s'il n'y a pas des anomalies ou des outliers (ex : valeur du panier entre 5 et 15 euros et une valeur de 7000 euros)
- ☐ Avant de passer à la suite, je m'assure d'avoir documenté tous les problèmes que j'ai pu observer
- ☐ Je m'assure d'avoir divisé mes problèmes en problèmes solubles vs insolubles

STRUCTURE DE DONNEES

LABO 1 : NETTOYER DES DONNEES

- ☐ Je résous les problèmes solubles (ce sont des problèmes pour lesquelles je n'ai pas besoin de l'intervention d'une personne supplémentaire)
- ☐ Dès que je résous un problème, je documente le type de résolution que j'ai mis en place

E = Evaluer l'ampleur des problèmes insolubles

- ☐ Pour chaque problème, j'ai noté l'ampleur (nb de lignes concernées, nb de lignes au total et ratio entre les deux → % de données concernées par le problème par rapport au total nb de lignes)
- ☐ Pour chaque problème insoluble, je note si c'est essentiel de le résoudre et à qui je pourrais en parler

A = Augmenter la qualité des données

- ☐ J'observe mes données et j'identifie si je peux créer de nouvelles granularités ou classification (ex : si j'ai une date complète, je peux créer des champs spécifiques pour l'année, le mois)
- ☐ J'identifie si je peux ajouter d'autres dimensions (d'une autre table par exemple ; comme l'ajout de la région qu'on a vu en cours)
- ☐ J'identifie si je peux calculer de nouvelles métriques (ex : la différence en jours entre la date d'achat et la date d'expédition)

N = Noter et documenter

- ☐ Je m'assure d'avoir noté et documenté tous les problèmes identifiés, leur ampleur, si c'est un problème soluble ou pas, quelle solution j'ai mis en place (si problème soluble) et quelle est la prochaine action à faire (si c'est un problème insoluble)