

Correction des exercices sur R.

1. Compute $\log(\sqrt{(10 * x + 1)})$ when $x=2$.

```
x <- 2
log(sqrt(10*x+1))
```

2. Let

$$A = \begin{pmatrix} 1 & 0 & -1 \\ 2 & 1 & 0 \\ 3 & 0 & 1 \end{pmatrix}.$$

```
A <- matrix(c(1,2,3,0,1,0,-1,0,1), nrow = 3)
```

- (a) Compute $|A|$.

```
det(A)
```

- (b) Compute A^{-1} .

```
solve(A)
```

- (c) Verify that $A \cdot A^{-1} = I$, where I is the unit matrix.

```
A %*% solve(A) %
```

- (d) Compute A^t (A^T , A').

```
t(A)
```

- (e) Compute eigenvalues and eigenvectors for A^2 .

```
eigen(A^2)
```

- (f) Solve

$$A \cdot \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} -1 \\ 0 \\ -1 \end{pmatrix}.$$

```
solve(A, c(-1,0,-1))
```

- (g) Compute $C = A \cdot (B^t)^{-1}$ with

$$B = \begin{pmatrix} 1 & 1 & 1 \\ 0 & 1 & 0 \\ -3 & 0 & 1 \end{pmatrix}.$$

```
B <- matrix(c(1,0,-3,1,1,0,1,0,1), ncol = 3)
C <- A %*% solve(t(B))
```

3. Compute the mean, variance and standart deviation of the following size of a production :
0.25, 0.70, 0.99, 1.20, 1.01, 0.45.

```

production <- c(0.25, 0.70, 0.99, 1.20, 1.01, 0.45)
mean(production)
[1] 0.7666667
var(production)
[1] 0.1337067
sd(production)
[1] 0.3656592
sqrt(var(production))
[1] 0.3656592

```

4. Compute the probability that two students share a birthday in this classroom.

```

pbirthday(48, 365, coincident = 2)
[1] 0.960598

```

5. Compute the probability that a coin tossed 20 times gives at most the same number of heads and tails.

```

pbinom(10, 20, 0.5)
[1] 0.5880985

```

6. For a normal law $N(3, 1)$ (i.e. with mean equal to 3 and a standard deviation equal to 1) compute :

— $P(X \leq 2) = F_{N(3,1)}(2)$

```

pnorm(2, mean=3, sd=1)
[1] 0.1586553

```

— $P(2 \leq X \leq 4) = F_{N(3,1)}(4) - F_{N(3,1)}(2)$

```

pnorm(4, mean=3, sd=1) - pnorm(2, mean=3, sd=1)
[1] 0.6826895

```

— $f_{N(3,1)}(3)$

```

dnorm(3, mean=3, sd=1)
[1] 0.3989423

```

— $f_{N(3,1)}(1)$

```

dnorm(1, mean=3, sd=1)
[1] 0.05399097

```

— $f_{N(3,1)}(5)$

```

dnorm(5, mean=3, sd=1)
[1] 0.05399097

```

— $F^{-1}(0.25)$

```

qnorm(0.25, mean=3, sd=1)
[1] 2.32551

```

— $F^{-1}(0.95)$

```

qnorm(0.95, mean=3, sd=1)
[1] 4.644854

```

— 10 random numbers that follow this law.

```

rnorm(10, mean=3, sd=1)
[1] 3.038545 3.393174 5.367761 4.143062 3.593761 0.650562 2.36

```

Evidemment, la réponse sera différente à chaque exécution :

```
rmnorm(10, mean=3, sd=1)
[1] 3.499285 3.560851 4.193636 2.616394 3.460339 3.083193 3.38
```

7. Générer 10 échantillons de 10 variables aléatoires suivant une loi normale de moyenne 0 et de variance 1, et créer un vecteur de taille 10 dans lequel l'entrée i correspond à la moyenne de l'échantillon i ($i = 1, \dots, 10$). Faire un plot de ce vecteur de moyenne. En principe, si vous déterminez la moyenne de ce vecteur de moyenne, cette valeur devrait être proche de quelle valeur ?


```
#je construis une matrice 10*10 dans laquelle je stocke mes échantillons
table <- matrix(rep(0,100), ncol =10)
```

```
for(i in 1:10){
  for(j in 1:10){
    table[i, j]=rmnorm(1, mean=0, sd =1)
  }
}
```

```
moyenne <- rep(0,10)
for(i in 1:10){
  moyenne[i]=mean(table[i, ])
}
```

```
plot(moyenne)
```

Voilà le résultat :



La théorie nous enseigne que $E[\bar{X}] = \mu$, il faudrait donc que les différentes valeurs des moyennes échantillon se retrouvent autour de la moyenne $\mu = 0$.

8. Refaire la même chose avec 10 échantillons de taille 1000. Illustrer le résultat vu au cours : $Var[\bar{X}] = \frac{\sigma^2}{n}$.

On refait la même chose qu'à la question précédente, mais en changeant la taille de l'échantillon :


```
table <- matrix(rep(0,10000), nrow =10)
```

```
for(i in 1:10){
  table[i,]=rnorm(1000,mean=0,sd =1)
}
```

```
moyenne <- rep(0,10)
for(i in 1:10){
  moyenne[i]=mean(table[i,])
}
```

```
plot(moyenne)
```

Voilà le résultat :



On voit bien sur ce plot que, comme l'annonçait la formule $Var[\bar{X}] = \frac{\sigma^2}{n}$, la variance doit diminuer quand la taille de l'échantillon augmente. On voit donc bien que, par rapport au plot de la questions précédente, les valeurs des moyennes échantillons se sont rapprochées de la valeur $\mu = 0$.

9. Faire une illustration du théorème central limite. Pour cela, générer 1000 échantillons aléatoires de 100 variables suivant une loi chi carrée à 25 degrés de liberté, et créer un vecteur de taille 1000 dans lequel l'entrée i correspond à la moyenne de l'échantillon i ($i = 1, \dots, 1000$). Faire un histogramme de ce vecteur.


```
table <- matrix(rep(0,100000), nrow =1000)
```

```
for(i in 1:1000){
  table[i,]=rchisq(100,25)
}
```

```
moyenne <- rep(0,1000)
for(i in 1:1000){
  moyenne[i]=mean(table[i,])
}
```

```
hist(moyenne)
```

Voilà le résultat :



L'histogramme semble bien confirmer que les moyennes suivent bien une loi normale, comme annoncé par le théorème central limite.


10. Faites une table de la loi student à 3 degrés de liberté pour les quantiles 0.6 à 1 par étape de 0.1.

```
quantile <- seq(0.6, 1, by=0.1)
table <- qt(quantile, 3)
```

11. Plotting the graph for $F_{N(1.80,0.5)}(x)$ and $f_{N(1.80,0.5)}(x)$ in black and grey, with the y axis labeled "Y", using the title "Normal Law". The graph must be centered on the mean.

```
x <- seq(from = 0.8, to = 2.8, by=0.1)
plot(x, pnorm(x, mean=1.8, sd = 0.5), type = "l", col="black", main="Law ")
lines(x, dnorm(x, mean=1.8, sd=0.5), col = "grey")
```


Voici le résultat de ces commandes



12. For $N(1.80, 0.5)$ plot the histogram of 500 random values.

```
x <- rnorm(500, 1.8, 0.5)
hist(x)
```

Voici le résultat de ces commandes



13. (a) Load and display the data frame called "USArrest" using the function "data()".

```
data("USArrests")
USArrests
```

- (b) Read the file "USACensus.csv" which can be downloaded from directory "Data_Sets" on the ICHEC MOODLE website. Display it on screen.

```
setwd("C:/etu/documents/")
census <- read.csv("USACensus.csv", header = TRUE)
View(census)
```

- (c) Download the file "abalone.data" from the UCI Repository website : <http://archive.ics.uci.edu/ml/machine-learning-databases/abalone/>. Load it in R, then using colnames() give the right names to its columns. Column names can be found in the file "abalone.names". Display the first lines, and then display the last lines.

```
abalone <- read.csv("abalone.data", header=FALSE)
colnames(abalone) <- c("Sex", "Length", "Diameter", "Height",
  "WholeWeight", "ShuckedWeight", "VisceraWeight",
  "ShellWeight", "Rings")
head(abalone)
tail(abalone)
```

14. For USArrests, for the column "Assaults" :

- (a) Compute the mean.

```
meanA <- mean(USArrests[, "Assault"])
meanA
[1] 170.76
```

(b) Compute the median.

```
medA <- median(USArrests[, "Assault"])
medA
[1] 159
```


(c) Compute the standard deviation.

```
sdA <- sd(USArrests[, "Assault"])
sdA
[1] 83.33766
```

(d) Plot the histogram.

```
hist(USArrests[, "Assault"])
```


Ce qui donne ceci :



(e) Plot a boxplot.

```
boxplot(USArrests[, "Assault"])
```

Ce qui donne ceci :



(f) Bonus : Is the distribution of Assaults following a normal distribution ?


Compare in the same graph the histogram and the density of normal distribution with mean and standard deviation computed in previous points.

```
xmin <- min(USArrests[, "Assault"])
xmax <- max(USArrests[, "Assault"])
x <- seq(0, xmax, length.out = 200)
```

```
plot(x, dnorm(x, mean=meanA, sd=sdA), type="l", col="red",
     xlab="Nbr of assaults", ylab="Density", main="Assaults")

hist(USArrests[, "Assault"], add=TRUE, freq=FALSE)
```

Ce qui donne ceci :




15. For abalone data :

(a) Plot a pie chart of groups (I,M,F)

```
#reprendre le fichier abalone
setwd("C:\\Users\\ceng\\Dropbox\\Ichee\\AD")
abalone <- read.csv("abalone.data", header = FALSE)

#les groupes I,M,F sont dans la première colonne : on regroupe
table(abalone[,1])
pie(table(abalone[,1]))
```

Ce qui donne ceci :



(b) For the number of ring : compute the mean, plot the histogram and the boxplot :

i. For the group of infants (Sex=="I")



```
#on sélectionne les lignes avec l'entrée "I" dans
colonne "Sex"
indexI <- abalone[, "Sex"]=="I"
# on fait la moyenne de la colonne "Rings" pour ce
mean(abalone[indexI, "Rings"])
[1] 7.890462

#l'histogramme :
hist(abalone[indexI, "Rings"])

#le boxplot
```

Ce qui donne ceci :

Histogram of abalone[index1, "Rings"]



ii. For all adults

```

#on repère les lignes ayant "M" dans la colonne "Sex"
indexM <- abalone[, "Sex"]=="M"
#idem pour les lignes "F" dans la colonne "Sex"
indexF <- abalone[, "Sex"]=="F"
#on sélectionne l'ensemble des deux
indexA <- indexM|indexF


mean(abalone[indexA, "Rings"])
[1] 10.90088


hist(abalone[indexA, "Rings"])
boxplot(abalone[indexA, "Rings"])

```

Ce qui donne ceci :

Histogram of abalone[indexA, "Rings"]





16. List objects in the R environment.

```
ls ()
```


17. Remove the matrice B , and list again objects in the R environment.

```
rm(B)
ls ()
```

18. For abalones, compute the means, the covariance, the correlation and plot a pairs plot for all numeric variables, except Rings.

```
colMeans(abalone[,c(-1,-9)])
cov(abalone[,c(-1,-9)])
cor(abalone[,c(-1,-9)])

pairs(abalone[,c(-1,-9)])
```



19. For USArrests, plot a boxplot for the comparable variables (not all variables).

