

Exercices sur les ACP.

Exercice numéro 1 : Les iris de Fisher

- a) Prenez les données concernant les iris de Fisher (données disponibles dans R).
- b) Sélectionnez les lignes correspondant à l'espèce "setosa", et conservez ces numéros de lignes dans la variable "Espece1", et faites de même pour les espèces "versicolor" et "virginica" que vous nommerez "Espece2" et "Espece3" respectivement.
- c) Déterminez la moyenne et l'écart-type des longueurs des sépales de tous les iris, et ensuite pour chacune des trois espèces séparément.
- d) Recopiez les 4 premières colonnes des data iris dans une variable X. Centrez et réduisez les variables.
- e) Faites une représentation des 150 individus en fonction de leurs caractéristiques 3 et 4 et nommez judicieusement les axes.
- f) Sur le graphe précédent, donnez une couleur différente en fonction de l'espèce. Pour cela, utilisez la fonction "factor" sur la colonne 5 des iris (celle-ci va attribuer un facteur pour chaque entrée différente de cette colonne). Ensuite, utilisez la fonction "rainbow" pour attribuer une couleur pour chaque level. Enfin, rajoutez les couleurs sur le plot précédent.
- g) Faites une ACP avec le package FactoMineR, avec deux composantes principales. Cette ACP vous semble-t-elle suffisamment représentative des données d'origine ?
- h) Faites le graphe des individus en attribuant une couleur en fonction de la variable 4 "Petal Width".
- i) Faites le graphe des individus en attribuant une couleur en fonction de la variable 2 "Sepal Width".
- j) Faites le graphe des individus en attribuant une couleur en fonction des espèces.
- k) Évaluez la représentativité des variables d'origine par les composantes principales.
- l) Cherchez les coordonnées des individus et en faire un plot.
- m) Donnez une interprétation de cette ACP

Exercice numéro 2 : Villes de France

- a) Allez chercher le fichier "villes_france.csv" sur Moodle et enregistrez-le dans une variable "villes" (attention, la première ligne correspond au noms des variables). Prenez connaissance du fichier.
- b) Faites un boxplot des tailles des populations de 2010 (variable "Population.2010"). Déterminez également la moyenne et l'écart-type de cette variable.
Le boxplot est assez particulier. Repérez les deux lignes du fichier dont la population en 2010 est supérieure à 500 000 habitants. Créez un nouveau tableau "ville2" sans ces valeurs extrêmes et refaites un boxplot.
Ce boxplot est toujours particulier. Pour le comprendre, déterminez la valeur du troisième quartile et comparez-le à la moyenne.
- c) Faites un boxplot des tailles des populations de 2010 (variable "Population.2010") en excluant les valeurs extrêmes à l'aide de la commande "outline=False".
- d) Faites une ACP en deux dimensions avec les 9 variables quantitatives. Évaluez si la part d'inertie des deux composantes correspondantes est satisfaisante.
- e) Observez le cercle des corrélations. Conjecturez quelles seraient les deux variables qu'il faudrait retirer afin d'améliorer la qualité de la représentation ?
- f) Faites une nouvelle ACP sans les deux variables "latitudes" et "longitudes". Comparez la part d'inertie des deux composantes correspondantes avec celle de l'ACP à 9 variables.
- g) Faites une dernière ACP avec les 5 premières variables quantitatives et évaluez une nouvelle fois la qualité de cette représentation.
- h) Sélectionnez aléatoirement 10 villes dont Paris et gardez les lignes correspondantes dans une variable "cityToDisplay".
- i) Faites un plot de ces villes.
Comment expliquez-vous le positionnement de Paris ?
- j) Identifiez la ville ayant la plus grande contribution pour chacune des composantes.
- k) Reprenez toutes les variables. Faites un plot des individus en ne tenant compte que de la longitude et de la latitude. Que constatez-vous ?
- l) Refaites l'ACP à 9 variables en supprimant les villes de Corse (pour les repérer, déterminez à partir de quelle longitude vous êtes forcément en Corse).

Exercice numéro 3 : Les données de Decathlon

Etudiez à l'aide d'une ACP les données "decathlon" disponible dans R et interprétez les résultats. (pour la correction, visitez la page <http://factominer.free.fr/factomethods/analyse-en-composantes-principales.html>)