

Exercices sur le clustering.

Exercice numéro 1 : Les iris de Fisher

1. Chargez les données sur les iris de Fisher.
2. Réalisez une ACP en précisant que la cinquième variable est une variable qualitative. Rajoutez dans le dataframe "iris" les coordonnées de chaque individu dans les deux premières composantes principales.
3. Réalisez un clustering des iris (attention, seulement sur les 4 premières variables) à l'aide d'un Kmeans avec 3 clusters et 10 itérations. Utilisez la distance euclidienne. Regardez la taille des clusters. Faites tourner plusieurs fois pour voir s'il y a une stabilité dans les résultats et vérifiez s'il y a bien convergence.
4. Faites une représentation des iris grâce à l'ACP, en donnant une couleur en fonction des espèces et un symbole en fonction des clusters afin de regarder si le clustering donné "respecte" les espèces.
5. Refaites les points c et d avec la distance "maximum".
6. Refaites les points c et d avec la distance "manhattan".
7. Refaites les points c et d avec la distance euclidienne et 5 clusters.
8. Réalisez un clustering des iris à l'aide d'un clustering hiérarchique avec le package "dendextend". Commencez par déterminer les distances entre chaque paire d'iris avec une distance euclidienne. Ensuite, faites le clustering hiérarchique avec une distance "average". Tracez le dendrogramme résultant. Comme on ne voit pas grand chose, mettez des couleurs en fonction des espèces.
9. Retracer le dendrogramme en mettant des couleurs correspondant au cluster de chaque iris quand on divise les données en deux clusters.
10. Représentez le résultat obtenu par le clustering hiérarchique du point h avec 3 clusters dans le plan des deux axes principaux.
11. Recommencez les points h et suivant avec d'autres distances.

Exercice numéro 2 : Les villes de France

1. Reprendre le fichier des villes de France disponible sur Moodle, et réalisez un Kmeans pour $K = 2$ avec la distance de votre choix.

Exercice numéro 3 : data aléatoire

- Créez un échantillon de 500 individus de deux variables générés aléatoirement avec une loi uniforme entre -1 et 1.
- Faites des clusterings (Kmeans et hiérarchique) sur cet échantillon.
- Refaites les deux points précédents en générant aléatoirement avec une loi normale de moyenne 0 et de variance 1.